第四部分

波动率作为一种资产

波动率不再只是一个参数，本身也成了直接交易的对象。本部分讨论能够重现曲面的模型、直接提供方差敞口的工具，以及这些工具所需的对冲大到足以推动市场时对市场结构的影响。第21章带剑号；第22与23章不带，其中描述的事件（2018年2月的平仓、当日到期期权的兴起），关注财经新闻的读者已经见过。本部分各章均设有中国市场一节。

21 **波动率建模：局部、随机、跳跃与粗糙**
各类模型，以及每一类各自以哪种缺陷为代价

22 **波动率产品：VIX、方差互换与离散度**
直接交易方差

23 **短期限期权、交易商头寸与市场反馈**
对冲交易何时会推动标的价格

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

第 21 章　波动率建模：局部、随机、跳跃与粗糙 †

第 19.4 节介绍了三类模型，用以化解“公式只有一个波动率，市场却报出许多个”这一矛盾，并说明了每一类得到什么、付出什么。这足以把它们区分开，却不足以据此选定其中一类并说明理由。本章逐一展开，说明每一类如何构建、如何校准、其特有的失效代价多大，并加上第四类，即粗糙波动率。这是最新的进展，约在 2015 年之后才变得可用。数学推导放在 [技术附注 21]；正文只讨论每个模型刻画了什么、在哪里失效，以及如何识别失效。

贯穿全章的问题不是“哪个模型是对的”，因为没有哪个模型是对的。要问的是，哪个模型的错误对眼前这笔交易无关紧要；回答它，需要确切知道每个模型错在哪里。

本章按逻辑而不是按历史顺序展开（历史见第 21.14 节）。只要要求精确拟合今天的曲面，局部波动率就是必然的答案，所以第 21.2 节先讲它，第 21.3 节再说明这种拟合在动态上付出的代价；随后依次是 Heston 随机波动率、Merton 跳跃，以及二者结合的 Bates 模型。第 21.7 节用一个可测量的事实检验这三类模型，即股指偏斜所遵循的幂律 $T^{-0.4}$，三者都再现不了它。第四类模型正是为解释这一事实而提出的；其后各节转向交易台实际使用的混合模型、校准，以及模型分歧的代价。

本章所有算例都采用同一约定：$S_0 = 100$，$r = q = 0$。于是远期等于即期，各期限的“平值”都指执行价 100，数值反映的是模型差异而不是持有成本。方程中保留 r 与 q，因为实际使用模型时需要它们；算例中略去，因为它们只会干扰比较。

21.1　波动率模型必须做到什么

波动率模型面临两项要求，几乎每个模型都是牺牲其中一项来满足另一项。

拟合今天的曲面。模型若不能复现市场报出的普通期权价格，任何交易普通期权的人都可以对它套利。这是硬约束，不是偏好。

动态正确。模型还必须说明曲面将如何变动，因为任何路径依赖产品的价值都取决于此。第 19.11 节已在小范围内说明了这一点：即使是普通看涨期权的 delta，也取决于微笑是粘在执行价上还是粘在价值状态上，而这是动态问题，不是今天价格的问题。

普通期权市场无法确定动态。今天的曲面只是各期限风险中性分布的快照；能产生同一组终端分布的过程有无穷多个，它们在中间时刻的行为却截然不同。这种自由度正是本章的主题，第 21.11 节将度量它的价值。表 21.1 列出了四类模型各自的取舍，值得在阅读后面各节之前先看一遍。没有哪一行能同时满足两项要求，所以本章最后给出的是一种选择方法，而不是一个胜出者。

21.2　局部波动率

令波动率是价格与时间的确定性函数：

$$dS = (r - q)\,S\,dt + \sigma_{\text{loc}}(S,t)\,S\,dW \tag{21.1}$$

表 21.1: 每一类得到什么、付出什么代价。

类别	得到	代价
局部波动率	精确拟合任何无套利曲面；保持市场完备	动态错误：模型的前向微笑（未来某日报出的微笑）会变平，市场的不会
随机波动率	动态符合现实，前向微笑近似平稳	拟合不了短端；市场不完备
跳跃	扩散模型产生不了的短期限偏斜	偏斜随期限衰减过快；本质上无法对冲
粗糙波动率	由一个参数给出观察到的偏斜期限结构	非马尔可夫；模拟昂贵

Dupire 证明：对任何无套利的看涨期权价格曲面 $C(K,T)$，式 (21.1) 中恰好存在一个函数 σ_{loc} 能复现曲面上的每个价格，而且可以直接读出（在 $S=K$、$t=T$ 处取值）：

$$\sigma_{\text{loc}}^2(K,T) = \frac{\dfrac{\partial C}{\partial T} + (r-q)K\dfrac{\partial C}{\partial K} + qC}{\frac{1}{2}K^2\dfrac{\partial^2 C}{\partial K^2}} \tag{21.2}$$

式 (21.2) 有三点容易忽略。

*分母就是隐含概率密度。*它等于式 (19.1) 的 Breeden–Litzenberger 密度乘以 $\frac{1}{2}K^2e^{-rT}$。所以局部波动率是曲面中已有的两个量之比，它存在的充要条件正是密度为正且分子不为负。第 19.5 节的蝶式条件与日历条件在这里再次出现，成了模型的存在性条件。

*模型是完备的。*只有一个布朗运动和一个可交易资产，所以第 13.4 节的复制论证完全成立，每份期权都能用标的资产对冲。这是实实在在的优势：局部波动率账簿的 delta 有明确含义。

*拟合由构造保证精确，*不是校准出来的。不需要搜索任何参数。正因如此，对任何只由今天曲面决定的收益（例如没有报价的欧式期权），局部波动率至今仍是基准模型。

最简单的局部波动率是价格的单一幂函数，即 Cox（1975）的常弹性方差模型，$\sigma_{\text{loc}}(S) = \sigma S^{\beta-1}$（$\sigma$ 为尺度常数）：$\beta<1$ 时波动率随价格下跌而上升，一个参数就产生了偏斜；$\beta=1$ 与 $\beta=0$ 分别是对数正态与正态的情形。它拟合不了任何具体的曲面，但它的幂次作为 SABR 的 β 保留了下来（第 29.10 节）。

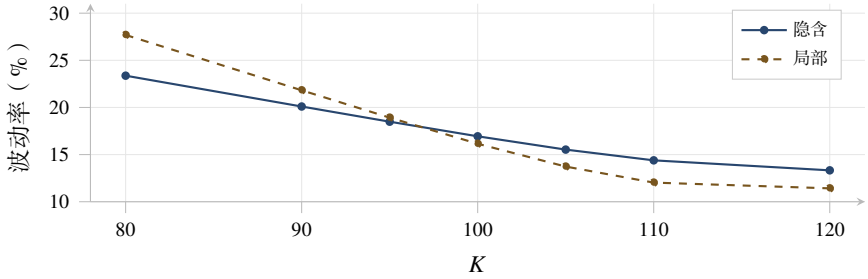


图 21.1: 同一 Heston 曲面上 1 年期的局部波动率与隐含波动率。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

例 21.1　局部波动率的陡度约是隐含的两倍

取 Heston 模型（第 21.4 节）在图 21.2 基准情形下给出的曲面（任何无套利曲面都可以），应用式 (21.2)。看涨期权价格由 Heston 半解析公式算出，对执行价的导数取对数执行价 $y = \log K$ 上的中心差分（$C_y = \partial C/\partial y$，$K^2\,\partial^2 C/\partial K^2 = C_{yy} - C_y$），两翼的数值因而稳定；时间导数 $\partial C/\partial T$ 取期限上的中心差分。这些价格由公式算出，不是报价，所以对真实报价作差分产生的噪声（[技术附注 21]）在这里不会出现。两个函数都在同一个自变量 K 处取值，但 K 的含义不同：对 σ_{impl}，它是 1 年后到期的期权的执行价；对 σ_{loc}，它是 1 年后该波动率所适用的价格水平。按本章约定，取 $S_0 = 100$、$r = q = 0$：

执行价	隐含波动率	局部波动率
80	23.37%	27.69%
90	20.10%	21.82%
95	18.49%	18.92%
100	16.94%	16.15%
105	15.53%	13.73%
110	14.39%	12.03%
120	13.33%	11.42%

用平值处对 $k = \log(K/S_0)$ 的斜率度量，取 ±5% 执行价对（即式 (21.3) 规定的度量方式），隐含波动率每单位 k 的斜率为 −0.296（从 95 到 105 约 3 个波动率点），局部波动率为 −0.518，比值为 **1.75**。

图 21.1 把两条曲线画在一起。这就是所谓“二倍法则”，其原因在于平均化。隐含波动率是能复现执行价为 K 的期权价格的单一数字，因此它是价格路径走向 K 途中所经历的局部波动率的平均。平均会抹平陡峭程度，要让平均值具有给定的斜率，底层函数必须陡峭约一倍。

所以局部波动率曲面再陡、两翼看上去再极端，也不是校准失败，而是数学上的必然结果。

21.3　局部波动率错在哪里

第 19.4 节说局部波动率精确拟合今天的价格，却拙于预测价格的演化。下面说明其机制与量级。

由于 σ_{loc} 是 S 与 t 的固定函数，模型校准之后就没有剩余的自由度。特别是，它对**前向微笑**（将来某一日期为从该日起算的期权所报出的微笑）给出确定的预测，而这一预测的偏差有明确的方向。

先约定度量方式，因为从这里起本章报出的偏斜是数值而不是形状。第 19.1 节所说的“偏斜”指形状：隐含波动率随执行价上升而下降。若要度量，它就是隐含波动率对**对数价值状态**在平值处的斜率；下面各表还同时报出二阶导数：

$$\text{skew}(T) = \left.\frac{\partial \sigma_{\text{impl}}}{\partial k}\right|_{k=0}, \qquad \text{curvature}(T) = \left.\frac{\partial^2 \sigma_{\text{impl}}}{\partial k^2}\right|_{k=0} \tag{21.3}$$

其中 $k = \log(K/F)$，F 是标的资产在期权到期日的远期价格，对连续股息率为 q 的资产，$F = S_0 e^{(r-q)T}$。按本章约定 $r = q = 0$，所以全章 $F = S_0$，“平值”与“执行价等于远期价”指同一个执行价。**曲率**是微笑对同一变量的凸性：微笑为直线时为零，两翼都高于平值处切线时为正。二者通常用远期价两侧一对执行价（曲率还要加上远期价本身）上的有限差分估计：表中注明扰动幅度 h 时，两点关于 k 对称，即 Fe^{-h} 与 Fe^{h}；未注明时取 95 与 105，即“±5% 执行价对”。

本章每张表都会报出偏斜，所以有三条性质需要在此说明。*用对数价值状态而不用执行价，可使这个数与价格尺度无关：两个分别在 40 与 4,000 交易的标的，只要微笑形状相同，偏斜就相同。股票曲面的偏斜为负，偏斜越陡，这个数越负。偏斜的取值还取决于两个执行价相距多远，因为微*

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

笑的斜率离开平值后会变化：第 21.4 节基准情形的 1 年期微笑用 ±5% 执行价对量得 −0.296，用 $h = 0.10$ 量得 −0.282。每张表都注明所用的扰动幅度；偏斜应在同一列内比较，不应跨表比较。

例 21.2　前向微笑会变平

取例 21.1 的曲面，在远期价上下 ±5% 处度量两种偏斜，局部波动率取各期限对应日期的值：

期限	隐含偏斜	局部波动率偏斜
3 个月	−0.479	−0.981
6 个月	−0.403	−0.770
1 年	−0.296	−0.518
2 年	−0.196	−0.320
3 年	−0.148	−0.231

局部波动率函数本身的偏斜从 3 个月到 3 年衰减到原来的四分之一以下。从第 3 年起算的 1 年期期权由第 3 到第 4 年之间的局部波动率定价，其偏斜从 −0.231 开始，而今天的 1 年期期权所用的偏斜是 −0.98 到 −0.52；模型于是预测 3 年后的前向微笑比今天的即期微笑平坦得多。

市场并非如此。远期起始期权（在未来某日才按当时平值设定执行价的期权）与棘轮期权（一串依次重置的远期起始期权，详见第 34.12 节）的成交偏斜与今天相当，即微笑按价值状态计大致平稳，并不衰减。因此局部波动率模型会把任何在未来偏斜变陡时获益的产品（虚值的远期起始看跌期权、买入看跌并卖出看涨的远期起始风险逆转）估得过低，把与之相反的产品估得过高；更糟的是，还会用错误的 vega 分布去对冲两者。

两笔产品可以有完全相同的普通期权对冲组合，前向微笑敞口却相差甚远；局部波动率只有一条变平了的前向微笑，区分不出两者。

还有一个更细微的后果。局部波动率把 σ 绑定在 S 上，即期下跌会沿着校准出的函数机械地抬高波动率。这使模型的 delta 系统性地偏离布莱克–斯科尔斯 delta，偏离方向可以用第 19.11 节的术语说明：即期上涨在粘性 delta 下会抬高固定执行价的隐含波动率，在局部波动率下则会压低它，因此局部波动率的 delta 甚至低于粘性执行价下的（布莱克–斯科尔斯）delta。第 19.11 节所述的股指实测行为介于布莱克–斯科尔斯与局部波动率之间：低于前者，但没有后者给出的那么低。

21.4　随机波动率

令波动率是与价格相关的第二个随机过程：

$$dS = (r - q)S\,dt + \sqrt{v}\,S\,dW_1, \qquad dv = \kappa(\theta - v)\,dt + \sigma_v\sqrt{v}\,dW_2, \qquad dW_1\,dW_2 = \rho\,dt \tag{21.4}$$

方差 v 以速率 κ 向长期水平 θ 均值回复，其波动率为 σ_v，与价格的相关系数为 ρ。扩散项中的平方根使 v 保持非负，但除非 $2\kappa\theta \geq \sigma_v^2$（即 Feller 条件），$v$ 可能触及零；拟合出的股票参数通常不满足这一条件（全章所用的基准情形 $v_0 = \theta = 0.04$、$\kappa = 1.5$、$\sigma_v = 0.6$、$\rho = -0.7$ 中 $2\kappa\theta = 0.12$，而 $\sigma_v^2 = 0.36$），这影响的是模拟（离散化的方差可能变负），而不是定价公式。平方根也使模型可解：特征函数 $\varphi(u) = \mathbb{E}\left[e^{iu\log S_T}\right]$（风险中性期望，$i = \sqrt{-1}$）有闭式表达，看涨期权价格可以由它经傅里叶反演得到，不必借助模拟：

$$C = S_0 e^{-qT}P_1 - Ke^{-rT}P_2, \qquad P_j = \frac{1}{2} + \frac{1}{\pi}\int_0^\infty \mathrm{Re}\left[\frac{e^{-iu\log K}\varphi_j(u)}{iu}\right]du \tag{21.5}$$

其中 $\varphi_2 = \varphi$，$\varphi_1(u) = \varphi(u - i)/\varphi(-i)$，即以股票本身为计价单位的测度下的同一函数；这里 P_2 是看涨期权到期为实值的风险中性概率，P_1 是该股票测度下的同一概率，相当于 Heston 模型中的

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

$N(d_2)$ 与 $N(d_1)$。特征函数 φ 本身是初等函数。记 $b = \kappa - \rho\sigma_v iu$，并令

$$d = \sqrt{b^2 + \sigma_v^2\left(u^2 + iu\right)}, \qquad g = \frac{b-d}{b+d}$$

则特征函数为

$$\varphi(u) = \exp\left\{ iu\left(\log S_0 + (r-q)T\right) + A(T) + B(T)\, v_0 \right\}$$

其中

$$B(T) = \frac{b-d}{\sigma_v^2} \cdot \frac{1 - e^{-dT}}{1 - g e^{-dT}}, \qquad A(T) = \frac{\kappa\theta}{\sigma_v^2}\left[(b-d)T - 2\log\frac{1 - g e^{-dT}}{1-g} \right]$$

以上就是全部：对每个 u，只需计算一个平方根、一个指数和一个对数，既没有积分，也没有递推。这就是“半闭式解”的含义：价格本身没有公式，但也不需要，因为除了上面的一维积分，其余部分都已显式写出。正因如此，整个曲面能在几秒内校准完毕。需要提醒的是，d 与上式中的对数都是复数，而代数只确定了 d^2：两个平方根都满足它，给出的 A 与 B 在代数上也等价。取上面写出的主根，对数保持连续；取另一个根，对数会跳跃 $2\pi i$，长期限的定价积分随之失效。[技术附注 21] 给出了完整推导，并把这种失效称为“小 Heston 陷阱”。

Heston 模型之所以成为标准模型，有三个与是否贴近现实关系不大的理由。第一是半闭式解。第二，它有五个参数（v_0、θ、κ、σ_v、ρ），多到足以拟合一条微笑，又少到可以解释。第三，每个参数都对应交易员本来就在关注的某种曲面特征。

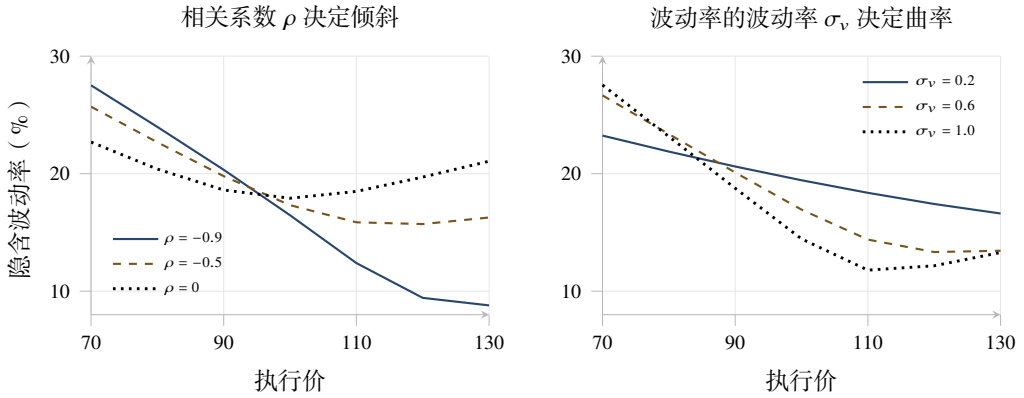


图 21.2: 1 年期 Heston 微笑。基准情形 $v_0 = \theta = 0.04$、$\kappa = 1.5$、$\sigma_v = 0.6$、$\rho = -0.7$；每一图各变动一个参数。

图 21.2 展示了交易员最常调整的两个参数。表 21.2 量化了五个参数中四个的作用；第五个参数 v_0 始终取 0.04。表中的偏斜与曲率为隐含波动率对对数价值状态取 $h = 0.10$ 的一阶与二阶中心差分。

相关系数产生偏斜，而且产生的机理是对的。当 $\rho = 0$ 时偏斜为零，微笑精确到三位小数都是对称的，即第 19.1 节所说的外汇市场形状。相关系数 ρ 取负值会使微笑倾斜，其经济含义就是第 19.9 节的杠杆解释，只是写成了一个参数：波动率随价格下跌而上升时，低执行价期权就会变贵。

波动率的波动率产生曲率。当 $\sigma_v = 0.2$ 时曲率为 -0.01，精确到两位小数，微笑是一条直线；$\sigma_v = 1.0$ 时曲率为 1.40，两翼都翘起。这就是第 19.9 节的机制：波动率本身的不确定性加厚了终端分布的两侧尾部。

两者相互影响，这正是实际校准的难点。把 σ_v 从 0.2 提高到 1.0，偏斜同时从 -0.112 变陡到 -0.340，平值水平也从 19.44% 降到 14.45%。把 ρ 从 0 调到 -0.9，曲率则从 1.27 变为 -0.58：同样

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

表 21.2: 自基准情形变动各参数时，1 年期平值水平、偏斜与曲率的变化。

	平值（%）	偏斜	曲率
基准（$\rho=-0.7$，$\sigma_v=0.6$，$\kappa=1.5$，$\theta=0.04$）	16.94	−0.282	0.36
$\rho=-0.9$	16.46	−0.398	−0.58
$\rho=0$	17.91	0.000	1.27
$\sigma_v=0.2$	19.44	−0.112	−0.01
$\sigma_v=1.0$	14.45	−0.340	1.40
$\kappa=5$	18.94	−0.155	0.03
$\theta=0.09$	22.70	−0.227	0.08

的波动率的波动率被用于倾斜微笑，而不是同时抬高两翼。没有哪个参数只影响一项特征，所以校准是真正的多维优化，而不是一串一维拟合；拟合出的参数之间相关性很强，单独报告其中任何一个都会产生误导。

*均值回复会抹平各种特征。*当 $\kappa=5$ 时偏斜降到 −0.155，曲率降到 0.03：均值回复很快，方差来不及偏离，终端分布因而更接近对数正态。这是一种平均化作用：在第 19.1 节所说的度量单位换算之外，它使偏斜随期限变平；这也说明了为什么仅凭单一期限的微笑很难识别 κ：它的作用看上去就像期限变长。

*扩散型的方差在短端失效。*方差是扩散过程，在趋于零的时间区间内来不及变动，所以无论参数如何设定，平值偏斜在 $T\to 0$ 时都趋于有限的极限，不会像市场那样不断变陡。在基准情形下，1 个月偏斜是 1 年偏斜的 1.77 倍（$h=0.01$ 的斜率），市场的幂律则约为 2.7 倍。第 21.7 节度量这一差距；第 21.5 与 21.6 节是经典的两种替代：单独的跳跃，以及加在 Heston 上的跳跃。利率市场则以 SABR 为标准，它着眼于重新拟合的速度：其波动率同样是随机的，但渐近展开直接给出隐含波动率的公式，因此整个互换期权微笑网格一天可以重新拟合许多次（第 29.10 节）。

21.5　跳跃

允许价格不连续地变动。在 Merton 模型中，以强度 λ 到达的跳跃会打断扩散过程，每次跳跃把价格乘以一个对数正态因子 Y：

$$\frac{dS}{S}=(r-q-\lambda\bar{k})\,dt+\sigma\,dW+(Y-1)\,dN,\qquad \bar{k}=\mathbb{E}[Y]-1 \tag{21.6}$$

其中 N 是强度为 λ 的泊松过程（在随机时刻逐次加一的跳跃计数，平均每年增加 λ 次），$\log Y$ 服从均值为 $\mu_J=\log(1+\bar{k})-\delta^2/2$、方差为 δ^2 的正态分布。漂移中的 $-\lambda\bar{k}$ 是补偿项：它减去跳跃的期望贡献，使平均为负的跳跃不会把价格拉到远期价以下，$e^{-(r-q)t}S_t$ 仍是鞅。

在恰好发生 n 次跳跃的条件下，到期价格又服从对数正态分布，所以期权价格是布莱克–斯科尔斯–默顿价值的泊松加权和，模型因此有闭式解：

$$C=\sum_{n=0}^{\infty}\frac{e^{-\lambda^*T}(\lambda^*T)^n}{n!}\,C_{\mathrm{BSM}}(\sigma_n,r_n),\qquad \lambda^*=\lambda(1+\bar{k})$$

其中 $\sigma_n^2=\sigma^2+n\delta^2/T$、$r_n=r-\lambda\bar{k}+n\log(1+\bar{k})/T$。每一项是恰好跳跃 n 次的路径上的价格；强度取 λ^* 而不取 λ，是因为整个和按 r 贴现，而每一项按各自的 r_n 贴现。

Merton 的跳跃次数少、幅度大，按下文的 $\lambda=0.5$，平均约两年一次。Madan、Carr 与 Chang（1998）的方差伽马模型，以及 Carr、Geman、Madan 与 Yor（2002）对它的推广（称为 CGMY 模

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

型），走向了另一个极端：无穷多次小跳跃，通常没有扩散。它们能很好地拟合短期限偏斜，也与Heston 一样用傅里叶反演定价，但偏斜同样像Merton 模型那样随期限变平，主要用于拟合普通期权微笑并在其间插值。引入跳跃，理由全在短期限。

例 21.3　跳跃能做到而扩散做不到的事

取Merton 模型，$\sigma = 17\%$，跳跃强度 $\lambda = 0.5$（每年），平均跳幅 $\bar{k} = -10\%$，跳跃波动率 $\delta = 13\%$：

执行价	1 个月	3 个月	1 年
85	30.99%	23.82%	21.21%
90	25.07%	21.78%	20.81%
95	20.57%	20.35%	20.47%
100	18.77%	19.49%	20.18%
105	18.25%	18.99%	19.94%
110	18.42%	18.73%	19.74%

期限为1 个月时，微笑从85 处的31.0% 降到105 处的最低点18.2%，再往外又翘起，跨度12.7 个波动率点。期限为1 年时，微笑在整个执行价范围内单调下降，从85 处的21.2% 降到110 处的19.7%，跨度仅1.5 个点。

期限从1 个月延长到1 年，微笑的跨度缩小到原来的八分之一以下。扩散做不到这一点：在很短的时间内，连续路径根本走不了那么远，虚值15% 的看跌期权因而几乎没有价值；只有不连续的跳跃才能做到。

这同时也是跳跃模型受批评之处。以平值偏斜度量（$h = 0.01$ 的斜率），跳跃模型1 个月与1 年的比值为**3.7**；股指偏斜所遵循的幂律（第 21.7 节）约为**2.7**。跳跃在短端偏陡，高出三分之一以上，扩散则不足。拟合1 个月期权的模型会给1 年期权定错价，除非允许跳跃参数随期限变化，但那等于放弃这个模型。

第 19.4 节已经指出跳跃对完备性的破坏比随机波动率更严重：大小未知的跳跃无法用任何事先建立的头寸对冲。随机波动率留下的风险只是标的资产本身对冲不了，再加一份期权就能对冲，即像例 18.7 那样消去第 18 章展开式（式 (18.1)）中的 vega 项；跳跃风险则无法由标的资产与任何有限份期权对冲，因为这样的组合都不能对每一种可能的跳幅给出恰好匹配的收益。跳跃的幅度大到该展开式无法描述，所以无论把其中各项消得多彻底，都对付不了它。第 13.4 节的论证表明不完备市场没有唯一价格；有跳跃时，也不存在完美对冲：期权可以降低敞口，但任何有限份期权都消除不了它。

谁因承担跳跃风险而获得补偿。 这项风险既然无法对冲，就必须有人持有，而持有者要求补偿：第 19.10 节的波动率风险溢价，一部分补偿 delta 对冲者无法完全对冲掉的扩散型方差，另一部分补偿任何对冲都覆盖不了的不连续变动。后一部分集中在两翼与短期限，即例 21.3 中跳跃模型起作用的区域。这对校准很方便，对推断却很危险：陡峭的短期限看跌翼，既可以解释为真实世界中跳跃的概率高，也可以解释为承担跳跃风险的溢价高；期权价格是风险中性的，无法区分两者。

对交易台而言，后果是一条关于“谁该做空”的规则。delta 对冲的账簿可以持有扩散型方差风险并赚取其溢价。跳跃风险则无法跨标的分散，因为跳跃会跨标的聚集（第 23 章在日内数据中看到同样的聚集），所以系统性卖出短期限虚值期权的账簿，持有的是相互关联的尾部；第 22 章 2018 年 2 月 5 日的案例，正是大批做空波动率的头寸遭遇这种尾部时的情形。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

21.6　带跳跃的随机波动率

一种机制在短端不足，另一种过度，自然的做法就是同时使用两者。Bates（1996）正是如此：在 Heston 的方差过程之外，再给价格加上 Merton 的跳跃：

$$\frac{dS}{S} = (r - q - \lambda\bar{k})\,dt + \sqrt{v}\,dW_1 + (Y-1)\,dN, \qquad dv = \kappa(\theta - v)\,dt + \sigma_v\sqrt{v}\,dW_2 \tag{21.7}$$

其中 $dW_1\,dW_2 = \rho\,dt$，N、Y 与 $\bar{k}$ 的含义同式 (21.6)。跳跃假定与两个布朗运动都独立。

正是这一独立性使模型可用：对数价格 $\log S_T$ 是相互独立的几部分之和，所以它的特征函数是乘积：

$$\varphi_{\text{Bates}}(u) = \varphi_{\text{Heston}}(u)\cdot\exp\left\{\lambda T\left(e^{\,iu\mu_J - u^2\delta^2/2} - 1\right) - iu\lambda\bar{k}T\right\}, \qquad \mu_J = \log(1+\bar{k}) - \frac{\delta^2}{2}$$

其中 φ_{Heston} 即第 21.4 节给出的特征函数。价格仍由反演式 (21.5) 给出，关于 d 取哪个根的警告同样适用。只需一个积分就能定价，所以 Bates 模型广泛用于短期限偏斜；[技术附注 21] 推导了这个乘积，并从中还原出 Merton 级数。

Bates 模型在 Heston 的五个参数之外增加了三个，作用于 Heston 覆盖不到的地方：

- λ，到达强度，决定微笑中有多少来自跳跃而不是扩散。
- $\bar{k}$，平均跳跃幅度，使短期限微笑倾斜；短期限看跌期权变贵，正是因为它取负值。
- δ，跳跃波动率，使短期限的两翼张开。

例 21.4 直接用微笑展示了这种分工。

例 21.4　两套机制各在何处起作用

取 Heston 基准情形，把扩散方差降到 $v_0 = \theta = 0.025$，再加上例 21.3 的跳跃（$\lambda = 0.5$，平均跳幅 −10%，跳跃波动率 13%），使两套机制共同承担基准情形每年 0.04 的方差率：

执行价	1 个月	3 个月	1 年
85	31.57%	26.08%	21.67%
90	26.52%	23.58%	20.36%
95	21.67%	20.68%	19.00%
100	17.17%	17.33%	17.55%
105	13.74%	14.08%	16.03%
110	15.06%	13.21%	14.57%

期限为 1 个月时，微笑从 85 处的 31.6% 降到 105 处的 13.7%，跨度 17.8 个波动率点，再往外又翘起。同一组执行价下，Heston 本身的 1 个月微笑跨度为 11.1 个点，跳跃模型为 12.7 个点：组合比任何一个成分都陡，因为跳跃产生的翼部现在叠加在本身就有偏斜的扩散之上。期限为 1 年时跨度为 7.1 个点，Heston 为 7.3，跳跃模型为 1.5。

期限为 1 个月时，微笑的形状（看跌翼部以及 105 之外的上翘）来自跳跃模型；期限为 1 年时，微笑来自 Heston，连倾斜程度都一样。每套机制各自负责另一套覆盖不到的期限。

图 21.3 画出了这一对比。左图中，Bates 曲线沿看跌翼部紧贴跳跃曲线下行，过了 105 又随之翘起，只是从平值开始位置偏低，因为其扩散方差较小（0.025，跳跃模型为 $0.17^2 = 0.029$）；右图中，它与 Heston 曲线几乎重合，跳跃曲线则近乎平坦。表 21.3 量化了三个新参数各自对图形的影响。每一行都重设 $v_0 = \theta$，使方差率保持基准水平；偏斜与曲率为 $h = 0.10$ 的中心差分，最后一列是 1 个月与 1 年平值斜率之比（$h = 0.01$，同图 21.4），所以不是两个偏斜列之商。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

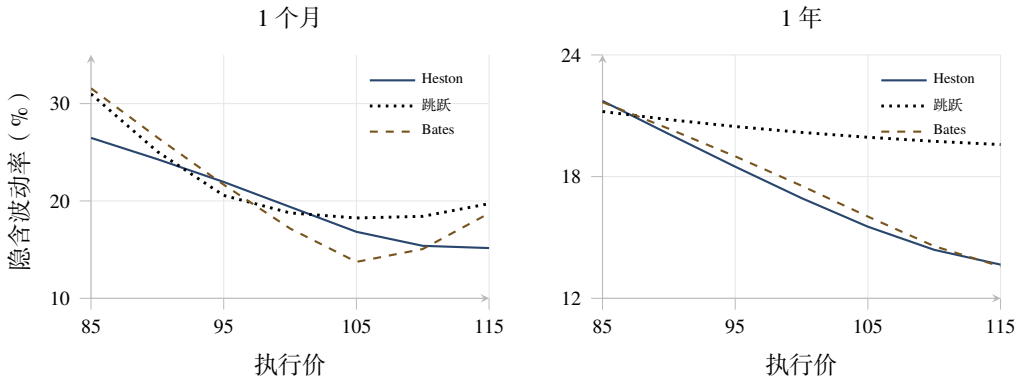


图 21.3: Heston、Merton 跳跃与 Bates 的 1 个月与 1 年期微笑，参数同例 21.3 与例 21.4。

表 21.3: 自 Bates 基准情形（$\lambda = 0.5$，$\bar{k} = -0.10$，$\delta = 0.13$）变动各跳跃参数时，1 个月与 1 年的平值水平、偏斜与曲率。

		1 个月			1 年			
	$v_0 = \theta$	平值（%）	偏斜	曲率	平值（%）	偏斜	曲率	比值
基准	0.0250	17.17	−0.531	7.11	17.55	−0.289	−0.44	2.92
$\lambda = 0.25$	0.0325	18.35	−0.495	3.42	17.23	−0.287	−0.02	2.23
$\lambda = 1.0$	0.0101	13.96	−0.584	17.02	18.19	−0.287	−1.28	6.20
$\bar{k} = -0.05$	0.0297	18.07	−0.380	6.34	17.35	−0.253	0.17	2.55
$\bar{k} = -0.15$	0.0169	15.19	−0.703	10.33	17.75	−0.346	−1.36	3.63
$\delta = 0.05$	0.0330	18.92	−0.538	1.29	17.49	−0.246	0.01	2.77
$\delta = 0.20$	0.0121	13.13	−0.400	19.15	16.64	−0.359	−0.13	3.18

先看 1 年期的几列。各行的偏斜都在 −0.24 与 −0.36 之间，曲率的绝对值不超过约 1.4，相对于 1 个月期的 1.3 至 19.2 不算大，所以期限为 1 年及更长时，三个跳跃参数几乎不起作用，微笑就是表 21.2 所描述的那样。而期限为 1 个月时，微笑几乎完全由它们决定。

*强度决定微笑中有多少来自跳跃。*强度 λ 加倍到 1.0，扩散中只剩下四分之一的方差，1 个月平值水平从 17.2% 降到 14.0%，曲率从 7.1 升到 17.0：原本遍及整个分布的方差，现在集中到了尾部，而 1 年期几乎没有变化。

*平均跳幅决定倾斜。*平均跳幅 $\bar{k}$ 从 −0.05 变到 −0.15，1 个月偏斜从 −0.380 变陡到 −0.703，1 个月与 1 年的比值从 2.55 升到 3.63。这个参数使短期限看跌期权变贵，也是校准看跌翼部时最先确定的参数。

*跳跃波动率决定两翼。*跳跃波动率 δ 从 0.05 变到 0.20，1 个月曲率从 1.3 升到 19.2，而在这一范围的上端，偏斜反而变平到 −0.400，因为很宽的跳跃分布加厚的是两侧尾部，而不只是左尾。

组合的效果体现在最后一列。基准情形 1 个月的平值斜率是 1 年的 **2.92** 倍，市场为 2.70，单独的 Heston 只有 1.77，单独的跳跃模型为 3.70；第 21.7 节把这四条曲线按期限画在一起。两个方向相反的误差叠加，短端的偏差大部分相互抵消。

长端却更差，而不是更好。到 3 年期，偏斜为 1 年期值的 0.372，市场为 0.644，几乎与跳跃模型的 0.367 相同，比 Heston 本身的 0.494 偏离得还多。把方差从扩散转移到跳跃上，并不会把期限结构整体抬高，而是让它转了一个角度：跳跃偏斜集中在短期限，在长期限上可以忽略，因此短

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

端的改善是以长端为代价的。调低强度只是两端此消彼长（$\lambda = 0.25$ 时 3 年比值改善到 0.42，1 个月却降到 2.23，低于市场）；调高强度则两端都偏得更远（$\lambda = 1.0$ 时为 6.20 与 0.317）。

八个参数足以让拟合满足某一本账簿的需要，所以许多股票交易台都用 Bates 的某种版本为短期限普通期权定价。但这些参数给不出市场偏斜随期限变化所遵循的幂律（第 21.7 节）：两套互不相关、各自拟合曲面不同部分的机制，只是补丁，而不是解释。

21.7　偏斜的期限结构与三个模型的失败

第 21.4、21.5 与 21.6 节分别对偏斜随期限缩短的变化作了论断。把三者与市场并列，这些论断归结为一种明确而可度量的失效，下一节将最终给出解释。

记 $\psi(T)$ 为平值偏斜 (21.3) 的绝对值，

$$\psi(T) = -\left.\frac{\partial \sigma_{\text{impl}}}{\partial k}\right|_{k=0}$$

它在股票曲面上为正，偏斜变陡就是 ψ 上升。问题是 $T \to 0$ 时它如何变化。

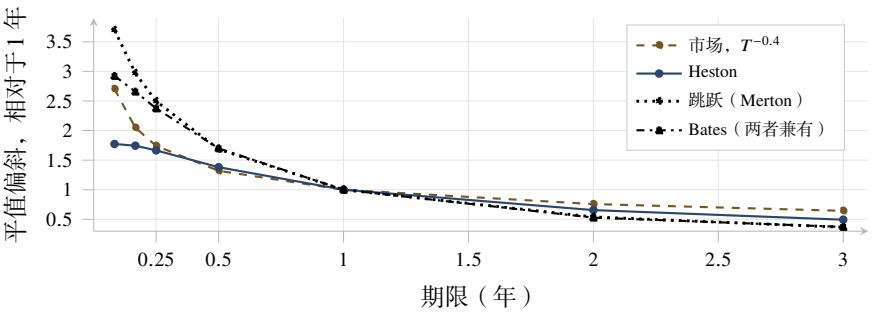


图 21.4: 平值偏斜随期限的变化，以 1 年期为 1 归一化：Heston 基准情形、例 21.3 的跳跃、例 21.4 的 Bates，以及幂律 $T^{-0.4}$；平值处的斜率，$h = 0.01$。

经验上看，它服从幂律。对各个股指，$\psi(T)$ 大致与 $T^{-\alpha}$ 成正比，α 约为 0.4（Bayer、Friz 与 Gatheral 2016），至少在约 1 个月到几年的期限上如此：期限越短，偏斜越陡。短于 1 个月时是否仍继续变陡，尚有争议，第 21.8 节将回到这一点。

经典随机波动率模型做不到这一点。原因第 21.4 节已经说过：方差是扩散过程，所以无论参数如何设定，$\psi(T)$ 在 $T \to 0$ 时都趋于有限常数。在图 21.4 中，从 1 年到 1 个月，Heston 的偏斜只升至 1.77 倍，市场则升至 2.70 倍。

长端的失效方向正好相反。到 3 年期，Heston 的偏斜衰减到 1 年期值的 0.494，市场则为 0.644。短端太平，长端又衰减太快，两者同时出现，这不是参数问题，而是结构问题。所以用 Heston 拟合整个曲面，结果是处处都拟合得不好，而不是某处拟合得好。

跳跃修复了短端，却又矫枉过正，如例 21.3 所示：比值为 3.7，市场为 2.7，即图 21.4 中的第三条曲线。Bates 是第四条曲线，它在短端取了折中（2.92，市场为 2.70），在长端则继承了跳跃模型的结果（0.372，市场为 0.644），原因正如第 21.6 节所述。

三个模型都再现不了这条幂律。它们的方差要么是常数，要么是马尔可夫扩散，价格上有没有附加跳跃都一样；任何这类模型的短端偏斜，要么趋于饱和，要么只能靠跳跃参数逐个期限手工设定。市场曲线并不是另外三条曲线的某种折中，而是另一种形状，要拟合它，要么需要另一

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

类过程，要么需要几个速度相差悬殊的普通过程。二十年来的情况一直如此：短期限问题打上了补丁，却从未得到解释。

21.8 粗糙波动率

Gatheral、Jaisson 与 Rosenbaum 在一篇 2014 年发布、2018 年正式发表的论文中，直接用股指与高流动性期货的高频数据估计已实现波动率的光滑程度，发现了一个一直存在于数据之中的规律。对数波动率的行为类似第 14.13 节的分数布朗运动，Hurst 参数 $H \approx 0.1$。普通布朗运动的 $H = 0.5$；$H = 0.1$ 时路径粗糙得多，锯齿更密，相邻增量的相关系数为 -0.43 而不是零。图 14.5 中的粗糙路径就是这类数据的样子。这一估计非常稳定：二十一个股指以及德国国债（Bund）、原油与黄金期货的 H 大致相同，样本期一分为二后仍在 0.06 到 0.20 之间，远离 0.5；后来的研究（Bennedsen、Lunde 与 Pakkanen 2022）又在近两千只美国个股上得到了同样的粗糙度。有两点使它不只是经验上的奇特现象。

它无需任何额外设定，就能产生观察到的偏斜期限结构。波动率由 Hurst 参数为 H 的分数布朗运动驱动的模型给出

$$\psi(T) \sim T^{H-1/2} \quad (T \to 0) \tag{21.8}$$

其中 $\sim$ 表示在该极限下成正比。取 $H = 0.1$ 得 $\psi(T) \sim T^{-0.4}$，正是观察到的幂律，而且只用了一个参数；$H = 0.5$ 则回到经典模型在短端趋于平坦的行为。图 21.4 中的“市场”曲线就是 $H = 0.1$ 时的式 (21.8)。

而且两个测度下得到的 H 大致相同。由物理测度（即生成这些数据的真实世界概率）下的已实现波动率估计出的值，与风险中性测度下由期权价格隐含出的值大致一致。从时间序列数据估计的参数，未必与从横截面价格估计的参数一致；两者一致时，这是关于过程本身的证据，而不只是拟合的结果。

案例 21.1 粗糙波动率如何变得可用

粗糙波动率起初是一个没人能用的模型。分数布朗运动不是马尔可夫过程：波动率未来路径的期望取决于全部历史，因此没有可用树表示的状态变量，也没有可解的偏微分方程。每个价格都需要一次模拟，而与价格联合精确模拟该模型的波动率，在 Cholesky 分解之后，每条路径的计算量是时间步数的 $O(n^2)$，普通扩散只是 $O(n)$。大约在 2015 到 2021 年间，三项进展改变了这一局面。

*快速模拟。*混合格式对权重最大的最近冲击作精确计算，对较早冲击的权重作近似处理，把生成粗糙路径的成本降到与普通蒙特卡洛相当。

*马尔可夫近似。*对过去冲击的粗糙加权可以用少数几个速度相差悬殊的普通均值回复因子之和来逼近。这样就恢复了状态向量（通常为四到八维），随之也恢复了普通蒙特卡洛，维数不高时还可用第 20 章的偏微分方程方法。这是近似，但误差可控，多数实现都采用这种做法。

*神经网络校准。*靠反复模拟来校准粗糙模型，成本无法承受。离线训练一个从参数映射到隐含波动率曲面的网络，运行时再对它求逆，就能把需要数小时的校准缩短到数毫秒。这个网络并不预测什么，只是对一个已知但求值昂贵的函数作插值，所以它取代反复模拟时并不改变被校准的模型。

各方采用这类模型的进度并不一致。最先采用的是非银行做市商与部分对冲基金，用于

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

短期限指数期权以及 SPX 与 VIX 期权之间的相对价值交易；银行的步伐较慢，多数奇异期权账簿仍使用第 21.9 节的局部–随机波动率。

这件事揭示了建模约束的本质。二十年来，业界假定波动率必须建模为马尔可夫扩散，短端的大多数失效都靠加入跳跃来修补。马尔可夫假定从来不是经济学主张，而是计算上的主张；一旦计算变得可以承受，人们就放弃了这个假定。值得一问的是：今天的建模惯例中，哪些是经济学，哪些只是因为计算还不够廉价才保留下来的权宜之计。

标准实现是 Bayer、Friz 与 Gatheral (2016) 的**粗糙 Bergomi** 模型。值得把它写出来，因为它的三个参数各有一项主要作用：

$$\begin{aligned} \frac{dS}{S} &= (r-q)\,dt + \sqrt{v_t}\,dW_{1,t}, \qquad dW_1\,dW_2 = \rho\,dt \\ v_t &= \xi_0(t)\exp\left\{\eta\sqrt{2H}\int_0^t (t-s)^{H-1/2}\,dW_{2,s} - \frac{\eta^2}{2}\,t^{2H}\right\} \end{aligned} \tag{21.9}$$

由外向内读。最外层的 $\xi_0(t)$ 是**远期方差曲线**，即今天对将来 t 时刻实现的方差所定的价格，由第 19.3 节从普通期权曲面复制出的方差互换利率推出，第 22 章讨论它的交易。它是输入而不是参数：指数项的均值为一，所以 $\mathbb{E}[v_t] = \xi_0(t)$，无论另外三个参数如何取值，这条曲线都能精确复现。积分是第 14.13 节分数布朗运动的一种形式（Riemann–Liouville 形式：粗糙度同为 H，但增量不平稳），写成过去冲击的加权和：每个 $dW_{2,s}$ 的权重为 $(t-s)^{H-1/2}$，即第 14.13 节所说的**核**（Heston 的核为 $e^{-\kappa(t-s)}$），$\sqrt{2H}$ 把方差归一化为 t^{2H}，所以 $-\frac{1}{2}\eta^2 t^{2H}$ 使指数项的均值保持为一。参数 η 决定对数方差波动的幅度，ρ 是相关系数，作用与 Heston 的 σ_v 和 ρ 相同。

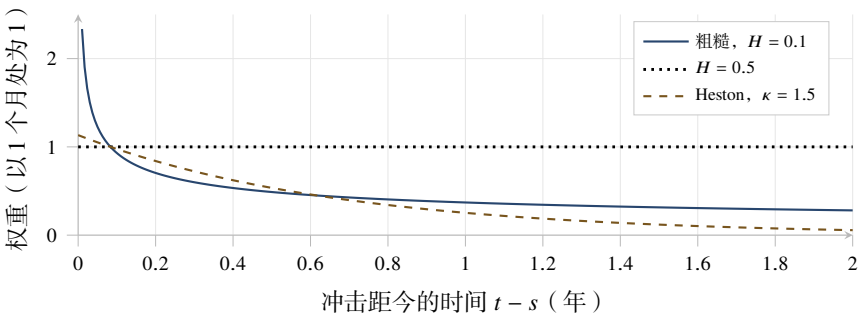


图 21.5: 过去一次方差冲击的权重随距今时间的变化，以 1 个月处为 1 归一化。

核是这个模型与以往所有模型的根本区别，图 21.5 把它与 Heston 的核画在一起。当 $H < 1/2$ 时幂次为负，权重在 $s \to t$ 时无限增大：最近的冲击占主导，这就是粗糙。但权重按幂函数而不是指数衰减，所以 2 年前的冲击仍保有 1 个月前冲击 28% 的权重，而 $\kappa = 1.5$ 时 Heston 的 $e^{-\kappa(t-s)}$ 只给它留下 6%。粗糙波动率比均值回复扩散更呈锯齿状，记忆也更长，而单一指数核无法兼顾这两点：要在短时间内变动那么大，Heston 需要很大的 σ_v；要记忆那么久，又需要很小的 κ；两种设定在同一条 1 年期微笑上相互冲突。表 21.4 按表 21.2 与表 21.3 的格式量化了三个参数的作用。表中数字由模拟得到（混合格式，200,000 条路径），偏斜的精度约为 ±0.01，比值约为 ±0.05；偏斜与曲率为半宽 $h = 0.10$ 的中心差分，比值则取自 ±5% 执行价对，因为蒙特卡洛噪声不允许采用表 21.3 的 $h = 0.01$，所以它同样不是两个偏斜列之商。

三个参数中有两个的作用与 Heston 完全相同。*相关系数 ρ 决定倾斜*：$\rho = 0$ 时两个期限的偏

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

表 21.4: 自粗糙 Bergomi 基准情形（$H = 0.10$，$\eta = 1.9$，$\rho = -0.9$，平坦的 $\xi_0 = 0.04$）变动各参数时，1 个月与 1 年的平值水平、偏斜与曲率。

	1 个月			1 年			
	平值（%）	偏斜	曲率	平值（%）	偏斜	曲率	比值
基准	17.8	−0.63	4.3	16.3	−0.31	0.0	2.6
$H = 0.25$	18.6	−0.73	0.1	15.1	−0.39	−0.3	2.0
$H = 0.45$	19.5	−0.47	−0.3	15.3	−0.36	−0.2	1.3
$\eta = 1.0$	19.3	−0.51	−0.1	18.6	−0.19	−0.1	2.7
$\eta = 3.0$	15.2	−0.47	13.3	12.8	−0.30	2.1	2.1
$\rho = -0.5$	18.3	−0.34	5.9	17.1	−0.17	0.9	2.4
$\rho = 0$	18.6	0.00	6.7	17.7	0.00	1.2	—

斜都为零，微笑是对称的。*波动率的波动率* η *决定曲率*，并像 σ_v 那样带动水平一起变化：η 从 1.0 变到 3.0，1 个月曲率从 −0.1 升到 13.3，平值水平从 19.3% 降到 15.2%。

第三个参数在 Heston 中没有对应。Hurst 参数 H 从 0.10 变到 0.45，1 个月与 1 年的偏斜比值从 2.6 降到 1.3，式 (21.8) 预测的 $12^{1/2-H}$ 则为 2.70、1.86 与 1.13。式 (21.8) 描述的是期限趋于零时的偏斜，在 1 个月与 1 年之间只是近似（Heston 作为 $H = 1/2$ 的扩散型方差模型，给出 1.77 而不是 1），考虑到这一点，两者已经很接近。同时，这三行的 1 年偏斜始终在 −0.31 与 −0.39 之间。可见 H 是期限结构参数：它决定偏斜在各期限之间如何分配，而不是 1 年期有多少偏斜；Heston 没有任何参数起这种作用。关于这张表，还有两点。其一，参数之间会相互影响：时间长度 t 上对数方差的标准差为 ηt^H，所以 η 相同时，越粗糙的过程在一个月内波动越大，1 个月平值水平随 H 下降而降低；而在一年内这些波动大多相互抵消，最粗糙一行的平均方差最不分散，1 年平值水平因而最高。其二，在指数曲面上，三个参数（远期方差曲线取自市场）的拟合优于 Heston 五个参数的拟合（Bayer、Friz 与 Gatheral，2016），这是支持该模型的最有力论据。

估计 H。 这个数字不是从期权价格得来的。Gatheral、Jaisson 与 Rosenbaum 用五分钟收益率构造已实现方差的日序列，取其平方根得到第 t 日的已实现波动率 σ_t，再取对数，然后对 1 天到大约 30 天的每个滞后 Δ，计算该滞后上变动的 p 次方的平均值

$$m(p,\Delta) = \frac{1}{n}\sum_t \left|\log\sigma_{t+\Delta} - \log\sigma_t\right|^p$$

（对样本中的 n 对日期取平均，p 约从 0.5 取到 3）。对不同起始日取平均度量的是同一个量，因为他们所拟合的过程（分数布朗运动及其缓慢均值回复的变体）增量平稳：任意 Δ 天内的变动无论从哪一天开始，分布都相同。再由自相似性得 $m(p,\Delta) \propto \Delta^{pH}$，所以 $\log m$ 对 $\log\Delta$ 回归的斜率为 pH；回归所得斜率正如模型要求的那样与 p 成正比，而且对所考察的每个指数，H 都在 0.1 的量级，远离 0.5。对这个数字有两点需要提醒。第一，已实现方差是方差的估计值而不是方差本身，其中的测量噪声会使序列看起来比实际更粗糙；测得的粗糙度中有多少来自噪声，至今仍有争论，本节末尾将说明这一点。第二，这一估计是在物理测度下做的；为期权定价的 H 是在风险中性测度下从偏斜的期限结构中读出的，二者大致一致（即本节开头所说）是证据，而不是假定。

研究前沿。 2019 年以来有两项进展值得了解。粗糙 Heston 用幂函数核取代 Heston 中方差冲击的指数衰减（图 21.5）。由于该模型仍是仿射的（特征函数的对数关于今天的远期方差曲线是线性的，正如 Heston 的对数特征函数关于上面的 v_0 那样），特征函数得以保留：它满足一个分数 Riccati 方程，没有闭式解，需要数值求解，但只用一个积分仍可为普通期权定价，第 21.4 节的方法可以

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

整套沿用。另一项是联合校准问题，即用一个模型同时拟合股指微笑与第 22 章的 VIX 微笑。经典模型长期解决不了它，粗糙波动率缩小了差距，但没有消除。在能同时拟合两者的模型中，路径依赖波动率把今天的波动率设为股指自身过去路径（近期收益率及其平方）的加权函数，而不是某个独立因子的函数。这是从建模角度看到的第 19.9 节的杠杆效应。

有两点需要提醒。第一，粗糙模型对普通期权曲面拟合得很好，它在奇异期权定价上的优势确实存在，但没有普通期权拟合所显示的那么大。第二，对任何在极短端敏感的产品而言，H 的选择都很重要，因为那里恰恰是模型预测最有特点、市场数据又最稀少的地方。

仍有争议之处。 2022 年以来，支持粗糙性的每一条论据都受到了质疑。El Amrani 与 Guyon（2023）用标普 500、欧洲斯托克 50 与 DAX 的曲面发现，幂律在约 1 个月到 3 年之间拟合良好，短于 1 个月则不然，那里趋向有限极限的偏斜拟合得更好。Cont 与 Das（2024）表明，由并不粗糙的过程估计出的已实现波动率，测量起来仍可能显得粗糙，所以由时间序列估计的 H 可能部分是估计误差造成的假象。Abi Jaber、Illand 与 Li（2023）的五次 Ornstein–Uhlenbeck 模型（一个均值回复高斯因子的多项式）只用一个马尔可夫因子、不含粗糙路径，就能联合拟合 SPX 与 VIX 微笑，其陡峭的短端偏斜来自快速均值回复与很大的波动率的波动率。粗糙波动率仍是对偏斜期限结构最简洁的解释；波动率是否真的粗糙，尚无定论。

21.9　局部–随机波动率

交易台对模型有所分工。只由普通期权曲面决定的收益用局部波动率，跳跃模型主要用于短期限偏斜；对路径依赖的股票与外汇奇异期权，交易台使用的既不是第 21.2 节的模型，也不是第 21.4 节的模型，而是两者的结合：

$$dS = (r - q)S\,dt + L(S,t)\sqrt{v}\,S\,dW_1 \tag{21.10}$$

其中 v 服从式 (21.4) 那样的随机波动率过程。函数 $L(S,t)$ 称为**杠杆函数**，其取法使模型精确复现普通期权曲面。

随机部分提供符合现实的动态，杠杆函数吸收其余全部差异，使拟合精确。下面说明 L 是什么、这一构造中唯一的自由选择会如何影响价格，以及由谁来作这个选择。

杠杆函数是什么。 模型能复现普通期权曲面，当且仅当瞬时方差在每个日期给定即期价格下的条件均值等于该处的 Dupire 局部方差。这是 [技术附注 21] 由 Gyöngy 定理推出的结果；因此局部方差本身也是一个平均值，即经过 (S,t) 的各条路径上瞬时方差的平均。对式 (21.10)，瞬时方差为 $L^2 v$，于是

$$L^2(S,t) = \frac{\sigma_{\text{loc}}^2(S,t)}{\mathbb{E}\left[\, v_t \mid S_t = S \,\right]} \tag{21.11}$$

分子是曲面在 (S,t) 处要求的方差，分母是随机因子在该处平均提供的方差。杠杆函数就是微笑中随机因子未能解释的部分：随机模型提供不足处它大于一，提供过多处它小于一，随机模型已经拟合的地方它恰好等于一。这个方程是循环的：右边的条件期望取决于路径，而路径又取决于 L。求解时沿时间逐步向前推进，可以用前向偏微分方程，也可以用粒子方法，即在模拟路径推进的同时从路径本身估计这一期望。[技术附注 21] 给出这个不动点问题以及求解它的两种方法。

混合参数。 把波动率的波动率按 $\sigma_v \to \zeta\,\sigma_v$ 缩放，$\zeta \in [0,1]$，并对每个取值重新校准 L。当 $\zeta = 0$ 时方差是确定性的，式 (21.11) 的分母就是 $v(t)$，$L = \sigma_{\text{loc}}/\sqrt{v}$，即纯局部波动率。当 $\zeta = 1$ 时随机因子尽可能多地解释微笑，L 只承担残差。每个取值都能精确复现普通期权，这正是 ζ 与本章其

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

他参数的不同之处：它不是拟合参数，而是关于动态的选择，普通期权市场无法代为作出。图 21.6 显示了它对 L 的影响。图中的普通期权曲面，是 Heston 模型在图 21.2 基准情形下给出的整个隐含波动率曲面（所有执行价与期限），随机因子也正是这一基准情形的方差过程，所以 $\zeta = 1$ 时随机模型已经完成拟合，算出的 L 处处等于一，这验证了构造运作正常。当 $\zeta = 0$ 时杠杆函数承担了局部波动率的全部形状，从即期价格 75 处的 1.51 降到 115 处的 0.57；$\zeta = 0.5$ 时更平坦，但并不居中：在略低于平值处它低于另两条曲线，因为半强度的随机因子在平值处提供的方差多于曲面所需。

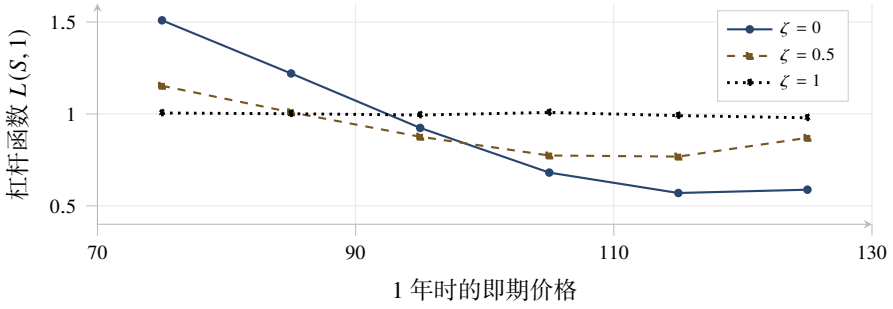


图 21.6: Heston 自身曲面上 1 年期的杠杆函数，混合参数取三个值。

例 21.5　作为调节旋钮的混合参数

用 Heston 基准情形生成普通期权曲面；对 ζ 的五个取值，以粒子方法把局部–随机模型 (21.10) 校准到该曲面，并为 1 年期向上敲出看涨期权定价：执行价 100，障碍 110，每日监测，即期价格首次触及 110 即作废；存活概率为从未触及障碍的路径所占比例。采用粒子方法蒙特卡洛，80,000 条路径；普通期权检验比较模型对三个执行价给出的 1 年期隐含波动率与 Heston 的 23.37%、16.94% 与 13.33%。

	1 年期普通期权拟合				
混合参数 ζ	$K = 80$	$K = 100$	$K = 120$	向上敲出 110	存活概率
0	23.35%	16.96%	13.30%	0.420	44.8%
0.25	23.34%	16.94%	13.29%	0.463	45.7%
0.5	23.27%	16.89%	13.28%	0.572	47.7%
0.75	23.21%	16.85%	13.23%	0.707	50.2%
1	23.24%	16.85%	13.23%	0.845	52.7%

普通期权各列几乎不变。每一行与目标的差都在 0.2 个波动率点以内，这正是模拟以及按即期价格区间取平均带来的噪声：正如构造所保证的，对每个取值，拟合都是精确的。障碍期权一列翻了一倍。从 $\zeta = 0$ 到 1，同一份期权、同一个普通期权曲面，价格从 0.420 单调上升到 0.845，因此两者之间的任何一个值都对应旋钮的某个位置。两端都是合法且已校准的模型，普通期权市场的任何报价都无法区分它们。这两端正是例 21.7 的两个模型，那里的独立模拟给同一份期权定价为 0.4244 与 0.8402，与这里的 0.420 和 0.845 之差在两次模拟的标准误差（约 0.005 与 0.008）之内。

第 21.11 节将回到这份期权，解释价差的方向：终点落在执行价与障碍之间的随机波动率路径，途中未触及障碍的可能性要大得多。

所以混合参数并不是一个麻烦。它就是做成旋钮的模型风险：交易台在旋钮两端为同一份障碍期权定价，无需搭建第二个模型，就能度量自身对建模选择的敞口。应该提交风险委员会的，是这个区间（这里高端约为低端的两倍），而不是区间的任何一端。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

由谁、如何设定旋钮。 这个模型是两类交易台的标准模型，但它们设定 ζ 的方式不同。在外汇市场上，局部–随机波动率自 2000 年代中期起就是障碍与触碰类产品的标准模型，单触期权与双边无触碰期权（汇率在到期前触及某一水平、或始终不离开某一区间时，支付一笔固定金额）的交易活跃到足以用于校准：交易台选取能复现其价格的 ζ，等于市场已经为旋钮定了价。股票市场没有这样的工具。障碍期权、自动赎回结构与棘轮都在场外交易，为它们定价的恰恰是需要以它们为输入的交易台，所以 ζ 只能靠判断设定，依据隐含波动率的历史波动率、前向微笑的历史表现或公司政策；第 21.11 节将论证，此时如实的输出应当是区间而不是单一数值。对这一设定最敏感的，是价值取决于前向微笑的产品：自动赎回结构与第 35 章的雪球，其敲入看跌期权的障碍位于期权的实值一侧，正是例 21.7 表明两个模型分歧所在的反向障碍情形。境内的情形更突出：没有流动性好的长期限期权，也没有远期起始市场，ζ 无法校准，只能假定，第 21.13 节将回到这一点。

实际使用中的问题。 式 (21.11) 带来两个实际后果。第一，L 是今天曲面的函数，不能校准一次就一直沿用；曲面一变就要重新推导，实际上就是每天一次，而重新校准正是运行这个模型的主要成本。第二，分母是由有限条路径估计的条件期望，所以 L 在两翼噪声最大，因为那里路径最少。两翼的锯齿是估计方法的产物而非新发现，使用前会先作平滑。这个模型给出的 delta 与 vega 也介于局部波动率与 Heston 之间，所以随 ζ 变化的不只是价格，还有对冲。

21.10　校准实务

上述每个模型在使用之前都必须先拟合，而实际造成损失的，多半恰恰是拟合这一步。有三项决策比模型选择更重要。

拟合什么。 一个曲面包含数百条质量悬殊的报价：1 个月平值期权连续成交，5 年期 10 delta 看跌期权每月只成交两次。对所有报价一视同仁地拟合，会让最不可靠的报价决定参数。

标准的补救办法是拟合隐含波动率而不是价格（等价地，把每个价格误差除以该期权的 vega），并按流动性（买卖价差宽度或未平仓量）为各报价加权。除以 vega 是最常见的做法，因为它以波动率点度量每个误差，而期权正是以波动率点报价、买卖价差也以它设定，所以翼部期权的误差与平值期权的同样重要。反过来乘以 vega 为波动率误差加权，就把它们又变回了价格误差，而价格误差由平值期权主导。

拟合质量与参数稳定性。 每天对整个曲面重新拟合的模型，会给出剧烈跳动的参数。其中一部分变动是真实的；更多的则是优化器沿目标函数的平坦方向用一个参数替代另一个，而表 21.2 中参数作用的相互重叠正是其来源。

其后果并非无关痛痒。用跳动的参数重估账簿，会产生虚假盈亏，交易台无法区分真实的市值变动与校准造成的假象。因此标准做法是对偏离前一日参数的变动施加惩罚（即正则项），以稍差的拟合换取在时间上有意义的参数。

校准服务于哪项风险。 拟合了整个曲面的模型，对其中任何一部分都拟合得不算特别好。如果账簿的敞口集中在 1 年期 25 delta 看跌期权上，就应以它为校准目标，其他地方的拟合就不那么重要。

校准目标应当与对冲相匹配：模型即便复现了每条报价，只要把账簿上唯一的头寸对冲错了，就是失败的。例 21.6 表明仅目标函数就会改变拟合结果。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

例 21.6　同一曲面，两种拟合

用Heston 拟合例 21.3 中跳跃模型生成的曲面（任何Heston 参数都无法复现它），期限为1 个月、3 个月与1 年，执行价 80 至 120。一种拟合最小化价格误差平方和；另一种先把每个价格误差除以该期权的 vega，一阶近似下这就是隐含波动率误差。

价格误差主要来自平值期权，因为它们的 vega 最大，同样的波动率误差在那里代价最高。执行价 80 的 1 个月期看跌期权只值0.05 美元，所以第一种拟合使其隐含波动率低了 7.08 个点，而 1 个月平值期权只差 0.12 个点。第二种拟合把这一翼部误差降到4.01 个点，代价是平值处差 0.19 个点，1 个月期的平均绝对误差从 1.72 个点降到 1.11 个点。若改为乘以 vega 为波动率误差加权，结果又接近第一种拟合（翼部6.67 个点）。

两者都不是普遍正确的。第一种适合账簿以平值跨式为主的交易台；第二种适合账簿集中在两翼的交易台，例如第 19.8 节的结构化产品发行方。目标函数隐含着对账簿的假定，应当有意识地选定，而不是沿用软件的默认设置。

21.11　量化模型风险

第 19.12 节指出两个都完美拟合今天曲面的模型可以给同一份障碍期权定出相差甚远的价格。现在可以验证这一断言了，因为第 21.2 与 21.4 节给出了两个由构造保证在每一份普通期权上都一致的模型。

例 21.7　同样的普通期权，两个障碍价格

取图 21.2 的Heston 参数，由 Heston 自身的普通期权价格经式 (21.2) 导出局部波动率曲面。这样两个模型在每一份欧式期权上都一致：用模拟定价，1 年期执行价 100 的看涨期权在Heston 下为6.766，在局部波动率下为6.767，半解析值为6.751，在蒙特卡洛误差范围内相等。

现在在两个模型下为1 年期、按日观察的障碍期权定价，两个模型使用同一批随机数，以便直接度量两者之差，而不是用两个含噪声的价格相减。这正是第 20.10 节引入共同随机数的目的。

障碍	Heston	局部波动率	差额（± 标准误差）	相对
向下敲出看涨期权，执行价 100				
80	6.5286	6.5821	+0.053 ± 0.015	+0.8%
85	6.2180	6.2962	+0.078 ± 0.015	+1.3%
90	5.5388	5.6138	+0.075 ± 0.015	+1.4%
向上敲出看涨期权，执行价 100				
130	5.8138	5.5787	−0.235 ± 0.015	−4.0%
120	4.0046	3.4193	−0.585 ± 0.013	−14.6%
115	2.4071	1.7138	−0.693 ± 0.010	−28.8%
110	0.8402	0.4244	−0.416 ± 0.005	**−49.5**%

对向下敲出期权，两个模型相差不到百分之一点五，交易台可以忽略。对向上敲出期权，两者相差将近价格的一半。

所以模型风险并不是“障碍期权”这类产品本身的属性，而取决于收益产生的区域与模型分歧所在区域的相对位置。平值向下敲出看涨期权的收益产生在远高于障碍的区域，在那里，普通期权已经确定了分布，两个模型的描述几乎相同。反向敲出期权（即第 19.12 节描述的情形，这里的向上敲出看涨期权正是如此）只在执行价与障碍之间的窄带中产生收益，而这条窄带恰恰是曲面对模型约束最弱的地方：任何单个普通期权都无法刻画“到期落在带内”与“从未触及带顶”这两个事件的联合行为。

价差的方向值得仔细说明，因为一个听上去合理的论证会得出相反的结论。有人可能这样推理：局部波动率在即期价格较高处很低（例 21.1 给出 1 年时即期价格 110 处为 12.0%，100 处为 16.2%），所以路径接近上方障碍的速度较慢，敲出较少，期权应当更值钱。实际上它反而更便宜，而且前提不成立：局部波动率

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

路径敲出得更多（例 21.5 中存活 44.8%，Heston 下为 52.7%）。两个模型给出的终端价格分布相同，所以关键在于给定终点位置时的存活概率。终点落在 108 与 110 之间的路径中，Heston 下有 39% 从未触及 110，局部波动率下只有 14%；终点在 100 与 102 之间的路径中，二者为 77% 对 57%。Heston 下既有平静路径也有剧烈路径，平静路径不触及障碍也能到达这条窄带；局部波动率对每个即期价格与日期只给出一个波动率，用它复现同样的终端分布，便没有平静路径可言。

所以普通期权市场并没有为这类产品定价，重新校准也无济于事。应当报告的是例 21.5 的混合参数给出的区间；只有区间很宽的产品才需要这样做，而这张表在交易之前就指出了这类产品。

案例 21.2　模型选择体现在盈亏上

自动赎回结构是本章模型选择造成实际亏损的最明显例子。

第 12.12 节与第 35 章描述的这类结构，内嵌一份由投资者卖给发行方的向下敲入看跌期权，并设有一系列离散观察日。其价值取决于普通期权曲面无法确定的三个因素：微笑在观察日之间如何演化，波动率在障碍附近如何变化，以及（对挂钩多个标的的票据而言）标的之间的相关性在下跌中如何上升。

发行方对这些账簿作动态对冲，对冲比率由模型算出。2010 年代，许多发行方用局部波动率为这些产品定价，因为它能精确拟合普通期权，而且拟合结果可以复核。例 21.2 已经指出了这一假定的缺陷。发行方持有敲入看跌期权的多头，同时是票息与提前赎回支付的空头，这些支付都是数字期权，而前向偏斜变陡会同时抬高两者的价值，所以净敞口的符号取决于障碍与票息。在许多票据上数字期权占主导，前向偏斜变陡时发行方亏损，而预测前向微笑会变平的局部波动率就低估了发行方的负债；无论哪种票据，局部波动率都会把 vega 分布放在错误的期限上。

市场平静时，这一后果看不出来；指数跌向敲入区域时才会显现，那时前向微笑最为关键，设定错误的对冲必须迅速调整。第 18.12 节描述了由此产生的对冲流（发行方在下跌中买入股指期货，到障碍处转而卖出，此后买入随之减弱）；模型层面的问题是：为什么对冲恰恰需要在那一刻调整，而不是更早。

此后，交易台转而用局部–随机波动率管理这些账簿，第 21.9 节的混合参数如今是一阶风险指标，而不是技术设定。交易台改用它，是因为简单模型的错误有代价，而这个代价在一次回撤中才暴露出来。

一般性的教训是：模型的失效方式决定了它能为什么定价。局部波动率能拟合但预测错误，随机波动率预测正确却拟合不上，同时取决于两者的产品就需要把两者结合，剩余的不确定性则体现为结合中的自由参数。

21.12　如何选择模型

这一决策的依据不是模型是否贴近现实，而是这笔交易的价值会受哪一种失效影响。

为普通期权账簿估值 → 不用模型。用第 19.12 节的曲面插值即可。

为障碍期权或自动赎回结构定价 → 局部–随机波动率，并报告混合参数取值范围内的价格区间，因为在这种情形下，模型选择关系到实实在在的金额。

远期起始产品、棘轮 → 随机或粗糙波动率。局部波动率在结构上就把前向微笑弄错了（例 21.2），而前向微笑正是这类产品的核心。

极短期限期权 → 按业务时间计时直接拟合的微笑（第 23.9 节），再用粗糙波动率或跳跃检验是否有某个过程能够产生它。经典随机波动率产生不了这种偏斜，而第 23 章的 0DTE 市场完全处

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

于这一区域。

互换期权与利率微笑 → SABR，设定与校准见第 29.10 节。

另有两个习惯，与第 20 章的两个习惯相对应。

校准到实际用于对冲的工具上。拟合效果也应在这些工具上而不是在总体上检查。

用不同模型各定价一次。两者的价差不是应当平均掉的噪声，它正是这笔交易模型风险的度量；例 21.7 表明两个在所有可观察量上一致的模型可以相差多远。

21.13 中国市场的若干差异

本章的模型是普适的。境内的差别在于*数据是否足以支撑校准*，以及*哪些产品确实需要这些模型*。

自由度多于数据点

第 19.13 节指出了境内曲面的两项限制：挂牌执行价范围窄，成交高度集中于少数标的与少数期限。结合本章的模型，就会出现一个具体的问题。

用五参数的 Heston 模型拟合只有五到七个可靠报价的微笑，会得到近乎完美的拟合和毫无意义的参数。拟合良好并不是好消息：报价太少，许多参数组合拟合得同样好，因此拟合优度不包含关于参数的信息。第 21.10 节所说的平坦方向，在境内不是“很多”，而是占据主导。其后果有三：

*参数无法解释。*报告境内标的上校准出的 κ 或 θ，多半只是在报告优化器的初值。

*参数不稳定。*逐日重新拟合会得到剧烈跳动的参数，第 21.10 节的正则化在这里不是锦上添花，而是结果可用的前提。

*模型比较无法进行。*第 21.12 节建议“用不同模型各定价一次”。两个模型都在过度拟合同一组稀疏报价时，这个价差度量的是过度拟合程度的差异，而不是模型风险。

*务实的做法是减少参数，而不是增加数据。*按历史数据固定 κ 与 θ，只逐日校准 v_0、σ_v 与 ρ，所得模型拟合较差，但参数更有意义。在境内，这通常是正确的取舍。

偏斜方向翻转意味着 ρ 会变号

第 19.13 节指出，境内偏斜的方向并不稳定：平静与上涨行情中微笑往往较为对称，甚至向右偏，下跌行情中则迅速翻转到看跌一侧。用本章的术语说，这意味着*校准出的 ρ 会变号*。这里的 ρ 是式 (21.4) 中价格与波动率的相关系数，决定偏斜的方向；它从 −0.6 变到 +0.2，描述的是价格与波动率之间两种不同的关系。

逐日重新校准的流程却把它们当作同一模型的两次校准。这在两方面造成实际损害：账簿的 vanna 与 volga（第 18.6 节）会随符号翻转而改变方向；任何依赖 ρ 的对冲，在翻转的那几天会指向相反方向。

稳妥的处理办法是把行情状态作为模型的一部分：分别维护上涨与下跌两组参数，并明确记录切换的时点与依据。这比假定一个模型在各种行情下都有效更符合实际，也更便于复核。

雪球最需要的，恰是境内最缺数据的量

第 21.11 节的结论在境内比在国际市场更重要，原因是一个不幸的巧合。雪球与自动赎回结构对*前向偏斜*敏感，即例 21.2 讨论的量。而境内几乎没有可用于校准前向偏斜的数据：没有流动性好的长期限期权，没有远期起始期权市场，棘轮产品也没有可观察的报价。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

因此，第 21.9 节的混合参数在境内无法用市场数据校准，只能假定。国际外汇交易台可以用触碰类期权的报价拟合它，国际股票交易台也只能靠判断设定；在境内，它同样是建模者自行选定的数值，并直接决定发行方认为自己做空了多少前向偏斜。境内雪球定价中最大的不确定性不在模型选择，而在一个无法观察的参数，因此第 21.12 节“报告区间”的建议在境内是必需的：让混合参数遍历全部取值范围，并把由此得到的价格区间作为定价的一部分记录下来。

涨跌停与停牌可能使 H 估计偏高

粗糙波动率的经验基础，是用高频数据估计已实现波动率的光滑程度。境内有高频数据，但有两项制度特征可能系统性地干扰这一估计。

*涨跌停板截断了日内极值。*日收益率被限制在 ±10%（或相应品种的幅度）以内，使波动率序列看起来比实际更温和，剧烈跳变更少；关于涨跌停的实证研究还发现，触及涨跌停后的波动会外溢到随后几个交易日，即把一次冲击分摊到几天之中。

*停牌造成数据缺口。*停牌期间没有观察值，如果估计方法把缺口当作“没有波动”而不是“波动未被观察到”，就会把一段高波动时期记录为平静期。

两者很可能朝同一方向起作用：*使估计出的 H 偏高*，即让波动率路径显得比实际更光滑。这是基于机制的推论，而不是实测结果。它与 Gatheral、Jaisson 与 Rosenbaum 自己的观察方向一致：他们指出，用全天已实现方差代替瞬时方差会高估 H，因为积分本身就是一种平滑；但波动率代理变量中的测量误差会把估计推向更粗糙的一侧，因此境内净偏差的大小尚无定论。所以，直接把国际文献的 $H \approx 0.1$ 搬到境内，或者用境内数据估出一个更高的 H，都需要谨慎：前者忽略了市场结构的差异，后者混入了制度造成的偏差。境内与国际市场的 H 是否相同，尚无可靠答案；任何以 H 为关键输入的境内定价，都应把它视为假定的参数，而不是测得的常数。

境内哪些产品确实需要这些模型

综合上述限制，境内的实际分工如下。

场内股票类期权（ETF 期权与股指期权）：不需要本章的任何模型。它们是欧式期权（第 10.13 节），布莱克–斯科尔斯–默顿公式加曲面插值就足够了。

场外普通期权：同上，另加第 19.13 节的借券成本调整。

雪球与自动赎回结构：这是本章模型真正派上用场的地方，具体而言是局部–随机波动率加混合参数扫描。

商品期权：第 19.13 节指出它们呈反向偏斜。用本章的术语说，这意味着校准出的 ρ 为*正*，与股票相反；这是模型正确反映标的经济特征的例子，而不是需要解释的异常。

利率产品：SABR 用于挂钩 LPR 的期权类结构（第 29.7 节）。境内利率虽已降至历史低位，但仍为正且离零还有一段距离（截至 2026 年 10 月，一年期 LPR 为 3.0%，短端货币市场利率低于 2%），因此 β 取 0.5 或 1 都可行，不像 2014–2022 年负利率时期的欧元市场那样，只能取 $\beta = 0$ 或改用位移 SABR。

监管对建模选择的约束

最后一点是制度性的，其影响比通常认为的更大。第 20.14 节介绍了中国证券业协会 2025 年修订的《证券公司金融工具估值指引》（2025 年 6 月 1 日起施行）。此外，证券公司的场外衍生品交易按规定向中证机构间报价系统报告；证券业与基金业协会 2025 年底发布的《衍生品估值报告内容与格式指引》（中证协发〔2025〕286 号，2026 年 7 月 1 日起施行）为交易商与第三方估值机

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

构向私募基金管理人和托管人出具的估值报告提供了统一模板。这对模型选择的实际影响是形成了一种**可复核性偏好**：交易台倾向于使用能够清楚说明、可以独立重算的模型，而不是拟合更好却难以向第三方解释的模型。

按这一标准，局部波动率表现极好：它没有参数，拟合由构造保证精确，任何人拿到同一组报价、采用同一插值方法，都会得到同一个曲面。粗糙波动率则表现很差：它需要假定 H，需要一套马尔可夫近似，可能还需要神经网络。

这一约束确实存在，而且并非没有道理。无法复核的估值在争议中毫无价值。但也要看到其代价：它使境内建模实践系统性地偏向拟合良好而动态错误的模型，而第 21.11 节表明雪球这类境内主力产品的定价恰恰依赖于动态。可复核性与正确性在这里存在矛盾，应当承认这一点。

21.14 这些结果的由来

布莱克–斯科尔斯–默顿公式相当准确，以至于它的缺陷过了十几年才在商业上变得严重，而使之严重起来的是1987 年的股灾。股票市场的微笑自此出现，再也没有消失。

三种应对方案在七年之内相继出现，其中两种在股灾之前就已发表，三种都沿用至今。Merton（1976）此前已经引入了跳跃，跳跃在短期限上产生微笑，也是对一个刚刚跳空的市场的自然反应。Hull 与 White（1987），以及独立完成的 Wiggins（1987）与 Scott（1987），使波动率本身成为随机的。这是标准参考文献，要理解这个问题的结构，至今仍应阅读 Hull 与 White 的论文。Stein 与 Stein（1991）加入了可解的均值回复形式，而最终取代所有这些模型的是 Heston（1993），原因并不是它的动态更好，而是它的特征函数有闭式解，价格因此只是一个单重积分。Carr 与 Madan（1999）给出了快速求逆这类变换的方法，使这一计算上的偶然成为决定性因素。

另一种应对是放弃对动态的选择。Dupire（1994），以及从树出发得到同一结论的 Derman 与 Kani（1994）和 Rubinstein（1994），证明有且只有一个局部波动率曲面能复现每一个有报价的普通期权。本章在很大程度上讨论的就是这种精确拟合的代价。Bates（1996）把跳跃与随机波动率结合起来，如今跳跃模型主要以这种形式使用。随后，Hagan 等（2002）提出 SABR，其渐近公式使随机波动率微笑可以直接由公式报价，SABR 也因此成为利率市场的通用语言。Gatheral、Jaisson 与 Rosenbaum（2018）则重新开启了这个问题：他们测得波动率比上述所有模型所假定的都更“粗糙”。

第 21.11 节的方法，即把拟合同一普通期权曲面的模型之间的价差解读为模型风险，来自 Hull 与 Suo（2002）。他们把这套方法用于隐含波动率函数模型（即局部波动率），得出的结论与第 21.11 节相同：在每一个有报价的普通期权上一致，能让一些奇异期权的价格几乎确定，却让障碍期权的价格相去甚远。其贡献在于把模型风险从一句警告变成了一项度量，这套程序在第 34 章与第 39 章再次出现。

小结

波动率模型必须拟合今天的曲面，并预测曲面如何变动。普通期权市场只确定前者，由此留下的自由度，正是本章各模型以不同方式加以利用的空间。

局部波动率把 σ 设为价格与时间的确定性函数，由 Dupire 公式直接从曲面读出，因此拟合由构造保证精确，市场保持完备。隐含波动率是路径所经历的局部波动率的平均，而平均会抹平陡度，所以局部波动率随执行价的陡度约为隐含波动率的两倍。它的失效在于动态：局部波动率偏斜随期限急剧衰减，因此模型预测前向微笑近乎平坦，而市场的前向微笑大致平稳，模型因而给

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

远期起始产品定错价，并用错误的 vega 分布对冲。

Heston 把方差设为与价格相关、均值回复的平方根扩散。相关系数产生偏斜，波动率的波动率产生曲率，均值回复则把两者都抹平。没有哪个参数只影响一项特征，所以校准是真正的多维优化，单个拟合参数没有独立含义。跳跃产生任何扩散都产生不了的短期限偏斜，但这种偏斜随期限衰减得比市场更快。

平值偏斜在约 1 个月到几年的期限上服从幂律 $\psi(T) \sim T^{-0.4}$；短于 1 个月的证据尚有争议。Heston 则趋于饱和，向短端上升太少，在长端又衰减太快：两端同时偏离市场，是结构性失效而不是参数问题。Bates 模型让方差扩散与跳跃同时起作用，使短端接近市场，却以长端为代价。八个参数可以调整拟合，却产生不了这条规律。

粗糙波动率是最简洁的解决办法，尽管支持它的每一条论据如今都有争议。对数波动率的行为类似 $H \approx 0.1$ 的分数布朗运动，由此仅凭一个参数就得出 $\psi(T) \sim T^{H-1/2} = T^{-0.4}$，而且大致相同的 H 同时出现在已实现波动率与期权价格中。粗糙 Bergomi 在给定市场远期方差曲线后只需三个参数，对指数曲面的拟合优于 Heston。使它得以实用的是快速模拟、恢复状态向量的马尔可夫近似以及神经网络校准：它所取代的马尔可夫假定只是计算上的惯例，从来不是经济学主张。

奇异期权交易台使用局部–随机波动率：随机方差过程乘以杠杆函数，杠杆函数经校准使普通期权拟合精确。两者之间的混合参数就是做成旋钮的模型风险。两个在每一份普通期权上都一致的模型，仍可能给同一份障碍期权定出相去甚远的价格，因为价格到达各终端分布的方式不同，所以输出应当是区间，而不是单一价格。校准本身也是一种建模选择：目标函数决定拟合照顾哪些报价，应当与账簿的对冲相匹配；参数逐日保持稳定，是以拟合变差为代价换来的。

在中国，主要限制在于数据而不是数学。可靠报价只有五到七个，五参数模型会给出近乎完美的拟合和毫无意义的参数，因此务实的做法是固定 κ 与 θ。偏斜方向随行情翻转，校准出的 ρ 也会变号，按行情分别维护两组参数更符合实际。雪球对前向偏斜敏感，而境内没有可用于校准它的数据，混合参数只能假定；让它遍历取值范围并报告价格区间，在境内是必需的做法。估值复核要求形成的可复核性偏好，系统性地偏向拟合良好而动态错误的模型，而雪球定价最承受不起的恰恰是这种偏向。

延伸阅读

Gatheral 的《The Volatility Surface》同时讨论局部波动率与随机波动率，是读完本章后自然的下一步。Dupire（1994）篇幅很短，值得读原文，重点在论证而不在公式。关于 Heston，1993 年的原始论文提出了模型，但数值上关键的内容，即特征函数的分支切割以及规避“小 Heston 陷阱”的形式，见于 Albrecher 等人与 Gatheral 的著作，任何忽略这一点的实现都可能在长期限上悄无声息地给出错误价格。Hagan 等（2002）是 SABR 的原始论文；修补其负密度问题的翼部修正出现得较晚，且散见各处。关于粗糙波动率，Gatheral、Jaisson 与 Rosenbaum（2018）是开创这一方向的实证论文，明确交代了“究竟测量了什么”；Bayer、Friz 与 Gatheral（2016）提出了粗糙 Bergomi，El Euch 与 Rosenbaum（2019）给出了粗糙 Heston 的特征函数，要了解仿射方法如何在粗糙性下依然适用，应读这一篇。Bates（1996）是把跳跃加入随机波动率的论文，Duffie、Pan 与 Singleton（2000）则给出一般仿射框架，解释了其特征函数为何能分解为乘积。关于局部–随机模型，Guyon 与 Henry-Labordère 的《Nonlinear Option Pricing》（2013）出自使粒子方法走向实用的作者之手，书中明确指出难点在条件期望而不在校准。Guyon 与 Lekeufack（2023）是第 21.8 节关于研究前沿一段所依据的路径依赖波动率论文。关于马尔可夫近似与神经网络校准的文献很新，且仍在快速发展。关于校准本身，Christoffersen 与 Jacobs（2004）是选定目标函数之前应读的论文：同一个模

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

型分别按价格误差与隐含波动率误差拟合，会得到不同的参数和不同的样本外表现，所以第 21.10 节的加权问题是建模决策，而不是数值决策。境内方面，中国证券业协会的《证券公司金融工具估值指引》（2025 年修订）与证券、基金两个行业协会 2025 年底发布的《衍生品估值报告内容与格式指引》，连同中证机构间报价系统的交易报告要求，是理解第 21.13 节所说“可复核性偏好”的一手依据。

练习题

21.1 解释 Dupire 公式 (21.2) 的分母为什么与隐含概率密度成正比，以及这对局部波动率模型的存在条件意味着什么。

21.2 用平均化论证解释“二倍法则”，并说明陡峭的局部波动率曲面是否意味着校准出错。

21.3 结合例 21.2，解释局部波动率模型为什么会给远期起始期权定错价，以及偏差的方向。

21.4 某次 Heston 拟合给出 $\rho = -0.05$。这意味着什么形状的微笑？你预期在哪个市场看到它？

21.5 解释提高 σ_v 为什么会同时改变平值水平与曲率，以及这对解读单个拟合参数意味着什么。

21.6 指出跳跃能产生而扩散不能产生的特征，以及跳跃所生成的期限结构存在的相应缺陷。

21.7 定义平值偏斜 $\psi(T)$，写出它服从的经验幂律，并解释经典随机波动率模型为什么无法复现随期限缩短而不断变陡的偏斜。

21.8 说明 Hurst 参数与偏斜期限结构的关系，并给出能复现观察到的幂次的 H 值。

21.9 解释局部–随机波动率模型中杠杆函数的作用，以及混合参数度量的是什么。

21.10 两个模型复现了每一条普通期权报价，却给同一份障碍期权定出不同价格。解释这为什么可能而又不构成套利，并说明交易台应当因此报告什么。

21.11 解释为什么校准目标通常以隐含波动率（价格误差除以 vega）而不是价格来表述、按价格误差设定的目标会忽视什么，以及对参数的逐日变动施加惩罚会让交易台得到什么、放弃什么。

21.12 说明为什么在境内，“精确”的 Heston 拟合往往是坏消息而不是好消息，以及偏斜方向翻转为什么意味着校准出的 ρ 会变号。

21.13 说明涨跌停板与停牌为什么可能使估计出的 Hurst 参数偏高，以及这一论证的局限。

进阶习题

21.14 例 21.1 得到的局部与隐含斜率之比是 1.75，而不是恰好为 2。推导产生二倍因子的平均化论证，指出该因子精确成立所需的近似条件，并解释曲面的哪些特征会使实测比值偏离它。

21.15 第 21.3 节论证，局部波动率在精确拟合今天曲面的同时弄错了前向微笑。构造两个在每个期限上终端分布相同、前向微笑却不同的过程，并据此准确说明普通期权曲面不包含过程的哪些信息。

21.16 表 21.2 显示 κ 的上升与 σ_v 的下降都会抹平微笑。证明两者的作用机制不同，解释为什么这使得仅凭单一期限难以同时识别它们，并说明什么数据能把它们区分开。

21.17 第 21.7 节表明，Heston 在短端太平，同时在长端衰减太快。解释为什么增加参数无法同时解决这两个问题，并说明这对“把单一模型校准到整个曲面”的做法意味着什么。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

21.18 式 (21.8) 给出 $\psi(T) \sim T^{H-1/2}$。解释 $H < 1/2$ 为什么会使偏斜在 $T \to 0$ 时发散，讨论无穷大的短期限偏斜在经济上是否合理，并说明该模型对极短期限期权真正的论断是什么。

21.19 第 21.8 节的案例认为，波动率建模中的马尔可夫假定是计算上的惯例而不是经济学主张。在本书中另找两个可能属于同一类的建模惯例，说明各自需要什么变得廉价才会放弃它，并解释如何区分惯例与主张。

21.20 表 21.3 在改变跳跃参数时保持方差率不变，1 年偏斜几乎不变，1 个月偏斜却大幅变动。利用“跳跃成分对偏度的贡献按 $T^{-1/2}$ 衰减，而相关扩散的贡献起初随期限增大”这一事实解释原因，并说明这对“Bates 校准应当用哪些期权来确定跳跃参数”意味着什么。

21.21 例 21.5 显示，向上敲出期权的价格随混合参数单调上升，而普通期权拟合保持不变。解释其机制，说明外汇交易台为什么能从市场价格校准混合参数而股票交易台不能，并说明股票交易台应当报告什么来代替单一价格。

21.22 例 21.7 用两个在每份普通期权上都一致的模型得到了两个障碍期权价格。解释为什么局部波动率下的价格较低，构造一个能部分对冲该价差的普通期权组合，并解释为什么任何普通期权组合都无法完全对冲它。

21.23 第 21.13 节认为境内的混合参数无法用市场数据校准。设计一套在没有远期起始期权报价的情况下，利用其他可观察数据约束该参数的方案：说明你会用哪些数据、能得到多强的约束，以及剩余的不确定性应当如何在定价中表述。

21.24 第 21.13 节指出，估值报告与复核要求形成了一种偏向拟合良好而动态错误的模型的“可复核性偏好”，并认为可复核性与正确性在此存在矛盾。设计一套既满足可复核性、又不牺牲动态的估值披露方案，并说明它分别给监管方和交易台增加了哪些负担。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

第 22 章　波动率产品：VIX、方差互换与离散度

第 12.4 节说过，想要波动率敞口的交易者必须对期权做 delta 对冲，剩下的就是已实现波动率对隐含波动率的押注。第 18 章几乎已经说清这个残差：delta 对冲头寸做多 gamma、做空 theta；第 18.4 节指出，股价恰好移动一个日标准差（按隐含波动率计）的那一天它不赚不亏。第 22.1 节补上这一步。两种描述都把波动率当作剔除不想要的敞口后剩下的部分。

本章讨论直接提供波动率敞口的工具。方差互换以固定利率交换已实现方差，没有 delta 要对冲，也不取决于价格在哪里移动。VIX 期货以一个由期权价格算出的指数为标的。离散度交易分离出相关性。每种工具都把一件副产品做成了合约，也都不完美，而不完美之处各不相同，各有启发。

人们为什么想要这样的合约，决定了整个市场的形态。持有股票的人都在做空波动率，无论自己是否意识到：回撤总在波动率上升时到来，而缓解回撤的对冲恰在此时最贵。因此，波动率有天然的买方，即股票持有者；也有天然的卖方，即替持有者承担其想转出的风险、并因此获得报酬的中介或基金。第 19.10 节给出了这一转移的价格，即股指上隐含波动率高于已实现波动率两到四个点，并称之为波动率风险溢价。本章的工具让这份溢价可以单独买卖，不必连带期权的 delta、执行价与再平衡。这是它们的吸引力所在。由此也可以解释为什么卖方头寸往往过度集中；又因为投资者整体通过所持股票在结构上做空波动率，本章的几次事件（2008 年、2018 年 2 月、2020 年 3 月）以同一形态反复出现。本章按市场发展这些工具的先后展开：先是方差互换及其上限（第 22.2 至 22.5 节），再是 VIX 及其期货与产品（第 22.6 至 22.8 节），最后是交易商的视角（第 22.9 至 22.13 节）。

22.1　拥有波动率的三种方式

delta 对冲的期权。买入期权并对冲其 delta。第 18.1 节的交易商对冲的是卖出的看涨期权，站在这笔交易的另一侧。对冲消去了第 18 章展开式 (18.1) 中的 delta 项，剩下 gamma 项与 theta 项：买方每天从价格变动中赚到 $\frac{1}{2}\Gamma(\Delta S)^2$、付出 theta；略去利息项，按隐含波动率 σ 计、一天所付的 theta 是 $\frac{1}{2}\Gamma S^2\sigma^2\,\Delta t$。把当日收益率写成 $\Delta S/S$，当日盈利就是

$$\frac{1}{2}\Gamma S^2\left[(\Delta S/S)^2-\sigma^2\,\Delta t\right]$$

即已实现方差减隐含方差，以 $\frac{1}{2}\Gamma S^2$ 加权。在头寸存续期内累加，就得到第 12.4 节的残差，只是按 gamma 加权：盈亏取决于标的在哪里移动，而不只是移动了多少；已实现波动率相同的两条路径，盈亏并不相同。该恒等式对任何期权都成立（看跌期权、蝶式，或因起始接近 delta 中性而常用的跨式），只是 Γ 不同。它还假定 σ 不变；若隐含波动率变动，就要再加上式 (18.1) 的 vega 项，即第 18.5 节的 vega 盈亏。

方差互换。直接以已实现方差为标的签订合约。没有 delta，没有 gamma 加权，也没有再平衡。合约的敞口就是其名称所说的已实现方差，别无其他。

VIX 期货。交易一个由期权价格构造的指数。这是最容易参与、也最不直接的一种：VIX 期货不是对波动率的索取权，而是对某个计算出来的指数在未来某日的水平的索取权；第 22.7 节将

说明两者能差多远。

这三者不能相互替代，这个市场的多数麻烦恰恰来自把它们当作替代品。

22.2　方差互换

方差互换在到期时支付

$$N_{\text{var}}\left(\sigma_R^2 - K_{\text{var}}^2\right) \tag{22.1}$$

其中 σ_R^2 是合约存续期内对数收益率的年化已实现方差，K_{var} 是执行利率，以波动率报出，N_{var} 是方差名义本金，按每个方差点支付（波动率以百分点计，因此 0.04 的已实现方差记为 $20^2 = 400$）。

vega 名义本金的惯例。 方差名义本金不直观，因此市场以 **vega 名义本金**报价，即收益对已实现波动率在执行利率处的斜率：已实现波动率变动一个点，一阶近似下赚到 N_{vega}。由于式 (22.1) 在 $\sigma_R = K_{\text{var}}$ 处的斜率是 $2K_{\text{var}}N_{\text{var}}$，

$$N_{\text{var}} = \frac{N_{\text{vega}}}{2K_{\text{var}}} \tag{22.2}$$

代入式 (22.2)，收益 (22.1) 变为 $N_{\text{vega}}(\sigma_R^2 - K_{\text{var}}^2)/(2K_{\text{var}})$。交易台说自己“在 20 上空了 10 万美元的 vega”，意思是已实现波动率若为 21 而非 20，它大约亏 10 万美元。只是大约，因为收益对波动率不是线性的：精确亏损为 $100{,}000 \times (21^2 - 20^2)/(2 \times 20) = 102{,}500$ 美元，多出的 2.5% 就是凸性，即第 22.4 节的主题。

已实现方差由合约定义，而非直接观察。 合约规定观察时点（每日收盘）、收益率约定（对数收益率）、年化因子（252），以及是否减去均值（这一点很重要）：

$$\sigma_R^2 = \frac{252}{n}\sum_{i=1}^{n}\left(\ln\frac{S_i}{S_{i-1}}\right)^2 \tag{22.3}$$

其中 S_0 是成交日收盘价，S_i 是第 i 个约定观测日的官方收盘价，共 n 个观测日。这个求和就是合约本身：成交确认书上写的是它，结算也据它计算，任何文件里都不会出现积分。式中不减均值，这是标准做法：正因如此，第 22.3 节的期权序列才能复制该收益，但这也使该度量与样本方差略有不同。这些并非细枝末节：执行利率相同、条款不同的两份合约，就是两份不同的合约；第 22.5 节所说的上限（个股合约的标准条款，2008 年后股指合约也有采用），就是这样一项条款。

22.3　复制方差

这个市场赖以运转的结论是：方差可以由静态持有的普通期权复制，既不需要模型，也不需要波动率预测，随价格变动而调整的只有一个美元规模恒定的股票头寸。思路来自第 12 章。第 12.8 节用债券、远期与拐点处的期权构造出任意分段线性收益；光滑收益是分段线性收益的极限，因此可以同样由债券、远期与一串连续的期权序列构造出来。把这一结论用于光滑收益 $-2\ln(S_T/F)$（T 为合约期限，以年计；F 为今天报出、在到期日交割的远期价格），即**对数合约**。下面两段分别说明两个事实，合起来即得结论。

对数合约的 delta 对冲恰好赚到已实现方差。 设价格服从

$$\frac{dS}{S} = \mu_t\,dt + \sigma_t\,dW$$

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

其中 μ_t 为任意漂移，σ_t 可以是任何波动率过程，常数、随机或路径依赖均可；下面的推导与此无关。对 $\ln S$ 用伊藤引理得

$$d(\ln S) = \Big(\mu_t - \frac{1}{2}\sigma_t^2\Big)dt + \sigma_t\, dW, \qquad \text{于是} \qquad \frac{dS}{S} - d(\ln S) = \frac{1}{2}\sigma_t^2\, dt$$

简单收益率与对数收益率之差累积的是一半方差，与漂移无关，也与路径无关。在合约存续期内积分并乘以 $2/T$，

$$\frac{1}{T}\int_0^T \sigma_t^2\, dt = \frac{2}{T}\left[\int_0^T \frac{dS}{S} - \ln\frac{S_T}{S_0}\right] \tag{22.4}$$

左边是连续时间下的已实现方差，即合约的求和式 (22.3) 用每日收盘价所估计的量：按第 14.7 节的 $dW^2 = dt$，观测越密，求和越趋近于它；已实现方差 σ_R^2 本身则是合约所定义的这个求和。右边是一个交易策略：积分是每一时刻持有 $1/S_t$ 股股票（一个持续再平衡、美元敞口恒定的头寸）在计入融资与股息之前的盈亏，对数项则是一份以 $\ln S_T$ 为收益的合约。因此，已实现方差可以由交易台能够持有的两种头寸构成，其中不涉及任何概率。

对数合约的 gamma 以逐次再平衡的方式完成同一件事。对数合约的收益是 $-2\ln(S_T/F)$，其 t 时刻的价值 V_t 是该收益的风险中性期望贴现到 t。暂取 σ 为常数，记 $F_t = S_t e^{(r-q)(T-t)}$ 为 t 时刻的远期价格，r 为无风险利率，q 为股息率。在风险中性测度下 $\mu_t = r - q$，把上面的 $d(\ln S)$ 方程从 t 积分到 T，得 $\ln S_T$ 的均值为 $\ln F_t - \sigma^2(T-t)/2$，因此

$$V_t = e^{-r(T-t)}\, E_t^Q\Big[-2\ln\frac{S_T}{F}\Big] = e^{-r(T-t)}\Big[-2\ln\frac{F_t}{F} + \sigma^2(T-t)\Big]$$

其 gamma 为

$$\Gamma = \frac{\partial^2 V_t}{\partial S^2} = \frac{2e^{-r(T-t)}}{S^2}$$

即收益本身的二阶导数 $2/S^2$ 乘以贴现因子。股息率只出现在 F_t 中，不影响这个二阶导数。于是第 18.3 节的当日 gamma 收入为

$$\frac{1}{2}\Gamma(\Delta S)^2 = \frac{1}{2}\cdot\frac{2e^{-r(T-t)}}{S^2}(\Delta S)^2 = e^{-r(T-t)}\Big(\frac{\Delta S}{S}\Big)^2$$

即当日收益率平方的现值，与 S 的水平无关。正是这样的权重，使累计的 gamma 收入与价格在何处移动无关；普通期权的 gamma 则集中在执行价附近，同样的移动在那里赚得比别处多。按无风险利率累积到到期日，每天的收入恰好等于当天的收益率平方，这就是下文式 (22.5) 中的 e^{rT}：序列中的期权价格是现值，复制时要把它们乘回去。

对数合约的收益可以由一串按 $1/K^2$ 加权的期权复制出来。 因此这份合约可以用市场上交易的工具构造出来。第 12.8 节构造分段线性收益的方法，是在每个拐点放置期权，数量等于该处斜率的变化。光滑收益 $f(S_T)$ 是其极限情形：每个执行价都是拐点，斜率变化为 $f''(K)\,dK$。围绕远期展开，远期之下用看跌、之上用看涨，使所用期权全部为虚值：

$$f(S_T) = f(F) + f'(F)(S_T - F) + \int_0^F f''(K)\,(K - S_T)^+\, dK + \int_F^\infty f''(K)\,(S_T - K)^+\, dK$$

对 $f(S_T) = -2\ln(S_T/F)$，各部分为

$$f(F) = 0, \qquad f'(F) = -\frac{2}{F}, \qquad f''(K) = \frac{2}{K^2}$$

即 $2/F$ 份空头远期合约（签订时无需付费），加上每个执行价处 $2\,dK/K^2$ 份期权。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

记 σ^2_{var} 为公允方差互换利率：使式 (22.1) 今天价值为零的执行利率 K^2_{var}，即已实现方差的风险中性期望，$\sigma^2_{\text{var}} = E^Q[\sigma^2_R]$。对式 (22.4) 取该期望。风险中性测度下股票的期望收益率是 $r - q$，因此股票头寸的期望盈亏为

$$E^Q\left[\int_0^T \frac{dS}{S}\right] = (r-q)\,T = \ln\frac{F}{S_0}$$

与对数项合并即得

$$\sigma^2_{\text{var}}\,T = -2\,E^Q\left[\ln\frac{S_T}{F}\right]$$

因此公允总方差 $\sigma^2_{\text{var}}T$ 就是对数合约收益的期望。在上面的展开式中逐项取期望：远期项的期望为零，每份期权的期望收益是其价格按无风险利率增长后的值，即 $e^{rT}P(K)$ 或 $e^{rT}C(K)$，其中 $P(K)$ 与 $C(K)$ 是执行价为 K、在 T 到期的看跌与看涨期权今天的价格。结果是

$$\sigma^2_{\text{var}} = \frac{2e^{rT}}{T}\left[\int_0^F \frac{P(K)}{K^2}\,dK + \int_F^\infty \frac{C(K)}{K^2}\,dK\right] \tag{22.5}$$

这就是式 (19.2)；第 19 章只给出了结论，这里给出了推导。图 22.1 展示了 $1/K^2$ 权重在整串期权上的分布：低执行价占了大部分权重（执行价 50 处的权重是平值处的四倍，执行价 200 处只有四分之一）。因此，方差互换对下行翼的敏感度远高于习惯平值 vega 的交易者的预期。

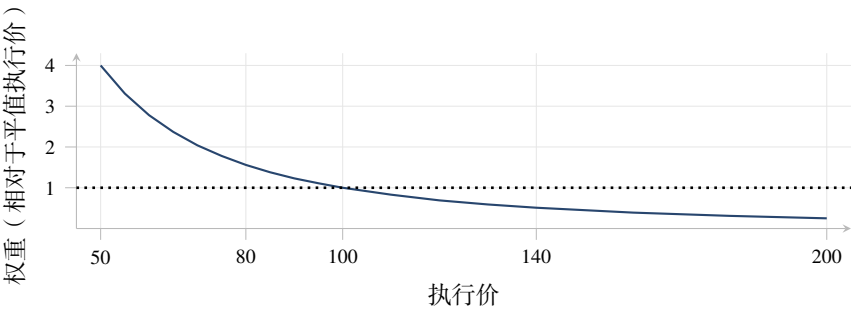


图 22.1: 方差复制组合中各期权相对于平值执行价的权重（$S_0 = 100$）。

例 22.1　构造期权序列，以及截断的代价

取平坦的 20% 波动率曲面，期限 1 年，$S_0 = 100$ 美元，$r = 2\%$，不派息（因此远期为 102.02），正确答案恰好是 20%。

用执行价从 50 到 200、间隔 5 点、相对于远期为虚值的期权构造期权序列，每份按 $\Delta K/K^2$ 加权，代入式 (22.5)：

复制出的波动率 = **19.96%**

真值为 20.00%。这 4 个基点的误差，最容易怀疑的原因是积分被截断在 50 与 200，但下表表明怀疑错了对象。

下表逐步拓宽执行价区间，最后一行同时缩小间距：

执行价区间与间距	复制出的波动率
50–200，步长 5	19.956%
30–300，步长 5	19.956%
20–500，步长 5	19.956%
10–800，步长 2	20.015%

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

由此得到两点启示。把区间拓宽到50–200之外毫无改善：在20%的波动率下，执行价50的1年期看跌期权价值不到一美分，权重再大也贡献不了什么。但间距确有影响，原因却不在被积函数难以逼近。误差取决于网格与远期102.02的相对位置：期权序列在此由看跌切换为看涨，虚值期权价格在此达到峰值并出现折点；落在峰值上的执行价把整个区间都按峰值计入，所以执行价恰落在远期上时偏高+10个基点，而本例的5点网格跨在两侧，偏低4个基点。误差随间距的平方缩小，故2点网格即使在102处有执行价（接近该网格最不利的位置），偏差也在1.5个基点以内。

波动率很高时，两项误差的大小次序正好相反。在60%的波动率下，50与200之外的期权有可观的价值，截断误差占主导，第19.3节的警告此时尤为适用：期权序列止于报价规则止步之处，而不是积分的终点。

22.4 为什么是方差而不是波动率

最自然的合约似乎应当支付已实现*波动率*，因为人们思考时用的是波动率。市场交易的却是方差，理由见第22.3节：方差可复制，波动率不可。波动率互换确实存在，主要在外汇市场交易，那里常以它而非方差互换报价，但其定价以方差互换为基准再加一项调整，例22.2表明这项调整大到不容忽略。

例 22.2 方差与波动率之间的价差

假设在风险中性测度下，该期间的已实现波动率服从均值为20%的对数正态分布。方差互换的执行利率是$\sqrt{E^{Q}[\sigma_R^2]}$，波动率互换的是$E^{Q}[\sigma_R]$，由Jensen不等式，前者大于后者。

波动率的波动率 ν	方差互换	波动率互换	价差
20%	20.40%	20.00%	0.40点
30%	20.92%	20.00%	0.92点
50%	22.66%	20.00%	2.66点
70%	25.55%	20.00%	5.55点

由于对数正态分布满足$E^{Q}[\sigma_R^2] = (E^{Q}[\sigma_R])^2 e^{\nu^2}$，价差为$\bar{\sigma}\left(e^{\nu^2/2}-1\right)$，其中$\bar{\sigma}$是该期间已实现波动率的均值、$\nu$是同一期间其对数的标准差（以单一期间度量的波动率之波动率），因此价差随ν迅速增大。若该期间已实现波动率的对数标准差为40%到60%（1年期股指互换的现实水平），同一标的上方差互换的执行利率比波动率互换高出一个半到四个波动率点。

由此有两点推论。其一，方差互换的执行利率不是波动率预测。把22.66%的方差互换报价称作“市场预期的波动率”，就把预测高估了2.66个点。第19.3节把（相对平值波动率的）那部分超额归因于偏斜，这一价差并不是叠加其上的又一项高估：平值隐含波动率接近波动率互换的执行利率（现货与波动率反向变动时略低于它），因此那部分超额在很大程度上就是这一价差。

其二，这个价差本身也可以交易：买入波动率互换、卖出方差互换，就是持有波动率的波动率头寸，也是不借助方差期权交易它的少数途径之一。

22.5 凸性并非没有代价

抬高执行利率的凸性，也使收益不对称，而且不对称得很严重，图22.2直观地展示了这一点：方差互换的收益曲线在执行利率处与波动率互换对应的直线相切，在其余各处都位于直线上方。两者的差距随偏离执行利率的距离平方增长，两侧相同；但已实现波动率可以远高于执行利率，却不可能远低于它。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

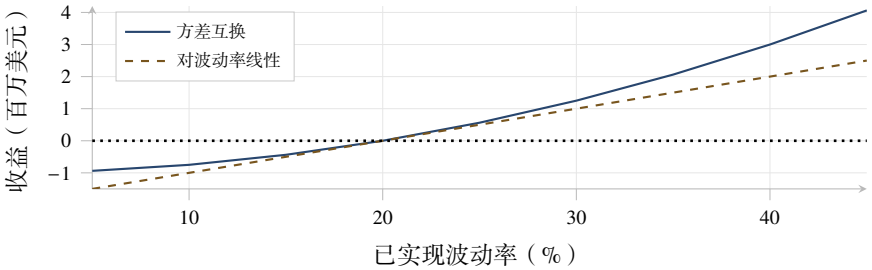


图 22.2: 执行利率 20%、vega 名义本金每点 10 万美元的多头方差互换的收益。

例 22.3　买方的凸性，与卖方的问题

一份执行利率 20%、vega 名义本金 10 万美元的多头方差互换，其收益如下：

已实现	收益	若对波动率线性	凸性收益
10%	−750,000	−1,000,000	+250,000
15%	−437,500	−500,000	+62,500
20%	0	0	0
25%	+562,500	+500,000	+62,500
30%	+1,250,000	+1,000,000	+250,000
40%	+3,000,000	+2,000,000	+1,000,000

（单位：美元。）

买方在两个方向上都从凸性中获益，因此执行利率高于波动率互换。卖方实际上只在一个方向上为此付出代价，因为已实现波动率不会低于零，却可以无限上升：已实现波动率为 40% 时卖方亏 300 万美元，而现实中最好的情形是波动率为 10% 时赚 75 万美元。卖方的损失没有上限，盈利却至多 100 万美元，即已实现波动率为零时的收益。

2008 年，股指的已实现波动率达到卖出方差时执行利率的数倍。卖方（其中许多是交易商，把做空方差视为对其所持期权多头的抵消）承受的损失远超 vega 名义本金所显示的量级。

市场的回应是结构性的。个股方差互换因标的会跳空、尾部风险大得多，从一开始就对已实现波动率设有**上限**，惯例为执行利率的 2.5 倍；即便如此，2008 年之后它也几乎停止交易；股指方差互换也出现了带上限的合约，不过不带上限的仍有成交。带上限的方差互换等于方差互换减去一份以已实现方差为标的、执行价设在上限处的看涨期权，因此不能再由式 (22.5) 静态复制。上限必须用刻画远期方差如何变动的模型定价，例如第 21.8 节的粗糙波动率模型。

于是，这种因无需模型而受青睐的产品，恰恰因为复制带来的收益结构，又离不开模型了。

案例 22.1　2020 年 3 月，以及上限值多少

例 22.3 所述的 2008 年教训在十二年后迎来检验：凡是把这项修补写进合约的地方，它都起了作用。

疫情抛售最严重的那个月，主要股指的年化已实现波动率超过 80%，而此前几周签订的方差互换执行利率在 12% 到 18% 之间。按不带上限的条款（即 2008 年以前的条款，股指市场仍有很大一部分按此成交），卖方的损失远超其资本所能承受的规模。

考虑一份在抛售开始前不久签订、执行利率 15%、vega 名义本金 10 万美元的 1 个月期互换，设存续期内已实现波动率为 80%。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

不带上限时卖方亏

$$100{,}000 \times \frac{80^2 - 15^2}{2 \times 15} = 100{,}000 \times 205.83 = 2{,}060 \text{ 万美元}$$

而该头寸标明的 vega 名义本金只有 10 万美元。这 206 倍集中体现了这种产品的问题；这里不涉及任何模型误差，只是已实现波动率达到执行利率五倍以上时，收益公式必然给出的数字。

上限设在执行利率的 2.5 倍时，损失停在

$$100{,}000 \times \frac{37.5^2 - 15^2}{2 \times 15} = 100{,}000 \times 39.375 = 394 \text{ 万美元}$$

上限使损失降为原来的 **1/5.2**。更重要的是，它把无界敞口变成了已知敞口，可以事先据此配置资本。有两点观察。

这项修补是结构性的，不是行为性的。没有人预测到疫情。市场在 2008 年之后所做的是修改合约，使“预测失败”不再致命。这是另一种审慎，也更可靠。

代价以模型风险的形式支付。例 22.3 指出带上限的方差互换不能再静态复制；以有限损失熬过 2020 年 3 月的带上限方差互换卖方，持有的工具必须用第 21 章的模型、而不是期权序列来定价。他们用已知的无界风险换来了只能估计的较小风险，而这一次，这样的交换显然是正确的。

22.6 VIX：一个指数，不是一个价格

VIX 是以标普 500 为标的、期限 30 天的方差互换利率，以波动率表示。但公布的数字不是式 (22.5)，而是对期权序列的离散求和，序列由指数发布方 Cboe 事先定好的规则选出。这个指数的种种奇特之处，包括它为什么高于平值隐含波动率、为什么取决于翼部报价的深度、为什么会在波动率毫无变化的日子里变动，都源于这条规则，而非理论，因此值得把它写出来。

远期来自期权，而不是来自指数。 对每个到期日，以 T 为其剩余期限、r 为相应的无风险利率，设 K^* 为看涨与看跌价格最接近的执行价。构造时取

$$F = K^* + e^{rT}\big(C(K^*) - P(K^*)\big) \tag{22.6}$$

这就是把看跌–看涨平价关系反过来用。平价关系对每个执行价都成立，因此若价格没有报价误差，任何挂牌执行价都会给出同一个 F；Cboe 选用 K^*，是因为那里两份期权都接近平值、流动性好，$C - P$ 的报价误差最小。分界执行价 K^* 是估计量的选择，而非恒等式的要求。标普 500 的点位与股息预测都不参与计算。市场对未来一个月持有成本的看法已经包含在期权价格中，式 (22.6) 是把它提取出来，而不是假定它。

期权序列是围绕 K_0 的虚值期权。 设 K_0 为不超过 F 的最高挂牌执行价。该序列在 K_0 之下取看跌、之上取看涨，在 K_0 处取两者的平均，于是除 K_0 处的一对期权外，所用期权都是虚值的（由于 $K_0 \le F$，K_0 处的看涨期权略为实值），且没有一份被重复使用。每份期权对应一个 ΔK_i，即其两侧相邻执行价之间距离的一半。从 K_0 向两侧推进，遇到连续两个无买价的执行价即停止。以 $Q(K_i)$ 记 K_i 处所用期权买卖报价的中点（Cboe 的记号，不是测度），该到期日的方差互换利率 σ^2（即第 22.3 节的 σ^2_{var}）为

$$\sigma^2 = \frac{2}{T}\sum_i \frac{\Delta K_i}{K_i^2}\, e^{rT} Q(K_i) \;-\; \frac{1}{T}\left(\frac{F}{K_0} - 1\right)^2 \tag{22.7}$$

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

求和项是式 (22.5) 的离散化，减去的那一项则不是：它是这套方法中唯一不能由第 22.3 节推出的部分。

最后一项从何而来。 复制在 F 处分界，期权序列则在 K_0 处分界；分界点 K_0 是挂牌执行价，因此一般不等于 F。改为在 K_0 处展开对数函数再取风险中性期望，得到的是把式 (22.5) 中的 F 换成 K_0 的结果，外加移动分界点的代价。记 $x = F/K_0 - 1$，这一代价为 $2[\ln(1+x) - x] = -x^2 + O(x^3)$，即对数的二阶余项，除以 T 就是减去的那一项。其大小以 $(\Delta K/K_0)^2/T$ 为界，在标普 4500 附近、5 点一档的网格上，这一方差约为 0.00002，在 VIX 约为 17.6、距到期 24 天时约合 **0.005 个 VIX 点**；Cboe 仍保留这一项，是因为这套方法并不保证网格足够细，在 25 点一档的网格上同一上界约为 0.13 个点。[技术附注 22] 给出了完整推导与二次式所替代的精确修正，并把这一项与另外两项更大的误差放在一起度量，后两者使公布的指数偏离方差互换利率。

30 天是两个到期日的混合。 一般没有期权恰好在 30 天后到期，因此式 (22.7) 分别对 30 天两侧最近的两个到期日计算（近月剩余期限多于 23 天，次月少于 37 天），再按*总方差*而非波动率插值：

$$\mathrm{VIX} = 100\sqrt{\left[T_1\sigma_1^2\,\frac{N_2 - N_{30}}{N_2 - N_1} + T_2\sigma_2^2\,\frac{N_{30} - N_1}{N_2 - N_1}\right]\frac{N_{365}}{N_{30}}} \tag{22.8}$$

其中 σ_1^2 与 σ_2^2 是近月与次月按式 (22.7) 算出的值，N_1 与 N_2 是从现在到近月与次月到期的分钟数，$N_{30} = 30 \times 1{,}440 = 43{,}200$ 是 30 天的分钟数，$N_{365} = 525{,}600$ 是 1 年的分钟数，$T_i = N_i/N_{365}$。方括号内是把总方差线性插值到 30 天（相继各期的方差可以相加，波动率不能），因子 N_{365}/N_{30} 将其年化。计算按分钟而非按天计数，因此权重在盘中连续变化，而不是每天跳一次。自 2014 年起周度到期日也可入选，30 天两侧的两个到期日因此靠得很近；在此之前窗口更宽，插值的作用更大。

例 22.4　由期权序列计算指数

设标普 500 为 4500 点，$r = 4.2\%$，期权按 5 点一档报价，偏斜向下倾斜：远期处为 17%，越往低执行价越陡。近月 24 天后到期，次月 31 天。价格按 1.4% 的股息率生成，但这套构造从头到尾都用不到它。

*先算远期。*式 (22.6) 对近月给出 F = **4508.29**，比标普 500 的 4500 点高 8.3 点，恰为 24 天的持有成本，因此 $K_0 = 4505$。

*再取期权序列。*无买价规则保留了 295 个执行价，从 3475 到 4945：

K	期权	ΔK	价格	$\Delta K e^{rT} Q/K^2$（$\times 10^6$）
3500	看跌	5	0.060	0.024
4000	看跌	5	2.302	0.721
4300	看跌	5	20.540	5.570
4505	看跌/看涨均值	5	78.347	19.355
4700	看涨	5	11.785	2.675
4900	看涨	5	0.207	0.043
全部 295 个执行价合计				1020.478

注意这个期权序列向两侧延伸的距离：向下延伸到远期以下 22.9%，向上只有 9.7%。由于偏斜，对应的看涨期权早已没有买价时，深度虚值看跌期权仍有买价；因此在任何截断规则生效之前，期权序列就已经不对称了。

把各项代入式 (22.7)：

$$\frac{2}{T}\sum\frac{\Delta K_i}{K_i^2}e^{rT}Q(K_i) = 0.0310395, \qquad \frac{1}{T}\left(\frac{F}{K_0} - 1\right)^2 = 0.0000081$$

于是 $\sigma_1^2 = 0.0310314$，σ_1 = **17.62%**。修正项只使数值变动 0.0023 个 VIX 点，与上面的界一致，也说明这一

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

项只是一道保险，并不起实质作用。

次月（31 天）给出 $\sigma_2 = \mathbf{17.82\%}$。式 (22.8) 中的权重是各 N 的比值，单位互相约去；取两个到期日恰好距今 24 天与 31 天的时刻，$N_1 = 24 \times 1{,}440$、$N_2 = 31 \times 1{,}440$ 分钟，权重为 $(31-30)/(31-24) = 1/7$ 与 $6/7$，于是

$$\text{VIX} = \mathbf{17.80}$$

这一数值更接近 31 天的值，因为 30 天离 31 天更近。

*现在让翼部变薄。*提高判定“无买价”的价格门槛，使近月期权序列（举例而言）只覆盖 3890 到 4835，而不是 3475 到 4945，执行价从 295 个减至 190 个。VIX 降到 **17.70**。没有任何一份期权的隐含波动率发生变化；指数下降十分之一个点，仅仅是因为有报价的期权变少了。

由最后这个实验以及式 (22.7) 与式 (22.8)，可以得出三点结论。按 $1/K^2$ 加权使 VIX 高于平值隐含波动率，因为低执行价权重更大，而偏斜又使这些期权更贵。把式 (22.5) 用于图 19.1 的 1 年期偏斜（代替 30 天期偏斜）：在图中所标执行价之间线性插值，两端之外保持微笑水平，利率取零，执行价取 50 到 200，得到 24.38%，而平值隐含波动率为 20.00%；水平为 20% 的平坦微笑则恰好返回 20.00%。这 4.38 个点的差距就是偏斜溢价，偏斜越陡，差距越大。若只用该偏斜实际有报价的执行价（70 到 130），数值降到 21.99%，平坦微笑的对照值也降到 19.56%：即使没有偏斜，截断本身也有代价。

截断规则使 VIX 依赖于报价深度。计算在遇到连续两个无买价的执行价时停止，因此平静时翼部稀薄，求和被提前截断，指数所依据的期权序列比交易活跃时更窄。这在例 22.4 中影响十分之一个点，而在波动率高、翼部最关键的时候影响更大。2024 年 8 月 5 日美股开盘前，VIX 一度报出 65.73，而标普 500 期货只跌了约 3% 至 4%：公式读取的是开盘前报价极宽的 SPX 期权的买卖中点。当天 VIX 收于 38.57。这与例 22.4 一样，是指数依赖报价而非成交的表现，只是规模放大到了极致、方向相反：过宽的报价抬高了求和所读取的中点价。

固定的 30 天期限是插值的结果：两侧的两个挂牌到期日按总方差混合，因此 VIX 对应的是一个合成期限，没有任何实际交易的期权与之对应。到期日移出或移入窗口时，式 (22.8) 中的权重随之变化，指数可能因与波动率毫不相干的原因而变动。

综上，VIX 是一个定义明确的数字，却不是任何可以持有之物的价格。今天定义它的期权序列不是明天定义它的期权序列，没有哪个长期持有的头寸能跟踪它，因此无法对它套利。

22.7 VIX 期货与期限结构

VIX 期货与其他期货一样逐日盯市，每日结算价取自收盘时段的成交；到期时则以**特别开盘报价**（Special Opening Quotation，SOQ）进行现金结算：在结算日上午对恰好 30 天后到期的标普 500（SPX）期权进行特别开盘集合竞价，再以其开盘价代入 VIX 公式算出，因此无需插值；结算日是该标准（第三个星期五）SPX 到期日之前 30 天的星期三。与第 10.3 节的指数期权一样，结算值是算出来的，而不是成交出来的，可能与前一日收盘值、与几分钟后的指数都相差不小。因此，SOQ 只在最后一天决定期货价格，期货价格到期时收敛于它；到期之前，期货价格与指数的当前水平*并无直接联系*，原因值得说清楚。

*VIX 期货不是以 VIX 为标的的远期。*第 5 章的持有成本论证要求标的可以买入并储存，而 VIX 无法持有。因此没有持有成本套利把期货与即期指数联系起来。签订期货合约不花钱且逐日盯市，因此风险中性测度下期货价格的期望增长为零（第 13.10 节），到期时收敛于指数，即期货价格是 VIX_T（指数在期货到期日 T 的值）的风险中性期望。由于 VIX_T^2 是 30 天的方差率而平方根是凹函

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

数，第 22.4 节的 Jensen 效应使期货价格低于远期方差互换利率（即 T 之后 30 天的公允方差利率，见第 22.12 节）的平方根。

实际后果体现在期限结构上。由于波动率均值回复（第 19.6 节），即期波动率较低时（多数时候如此）曲线通常向上倾斜，压力时期则倒挂：用第 5 章的术语，平静时为期货升水，压力中为现货升水。均值回复也使期货的变动小于指数：在图 22.3 的两条曲线之间，指数从 15.5 升到 40，近月合约只从 16.4 升到 33，约为指数升幅的三分之二，5 个月合约则不到四分之一。因此按即期 VIX 确定规模的对冲会对冲不足，合约越远，不足越多。除第 22.8 节产品的发行方用前两个合约对冲之外，这条曲线的主要交易者是押注其斜率的对冲基金。

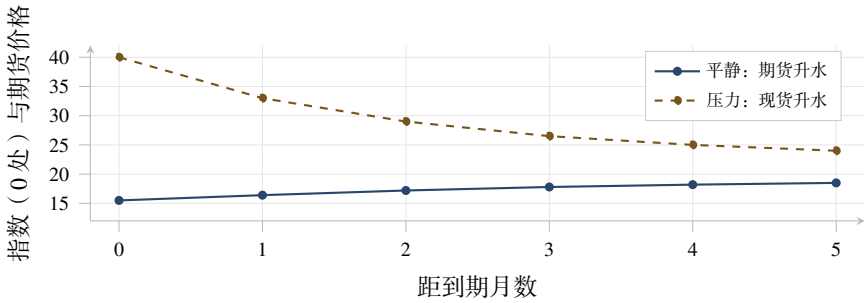


图 22.3: 有代表性的 VIX 期货曲线（示意）。

例 22.5　期货升水让多头付出什么

用图 22.3 的平静曲线：近月为 16.4，次月为 17.2。

维持恒定 1 个月期敞口的基金必须展期：它以 17.2 买入次月合约，1 个月后若曲线不变，该合约已成为近月合约，按 16.4 计价。

$$\text{损失} = 17.2 - 16.4 = 0.8 \text{ 点}, \qquad 0.8/17.2 = \textbf{每月 4.65\%}$$

按复利计算，$(1 - 0.0465)^{12} - 1 = \textbf{每年 } -43.5\%$，而这期间 VIX 指数始终未变。

这就是第 5.11 节的展期收益，只是背后没有持有成本；VIX 期货曲线比大多数期货曲线陡，展期收益也就大。它有两个后果，交易双方各对应一个。

做多 VIX 期货的产品在结构上不适合作为对冲长期持有。投资者若买入波动率敞口作为组合保险并持有 1 年，要付出约为头寸 40% 的代价；收益必须先超过这个数，这份对冲才算起了作用。

反过来，做空 VIX 期货的产品把这笔展期作为持有收益赚走，即换一种产品收取第 19.10 节的波动率风险溢价。第 22.8 节讲述收取这份溢价的人后来的遭遇。

溢价与展期是一体两面。即期水平低时，仅凭均值回复就会使曲线向上倾斜，但如果期货价格只是对指数的预测，平均而言多头不会为此付出任何代价；曲线之所以倾斜得更陡，是因为卖方要求承担风险的补偿，多出的部分既是买方的展期成本，也是卖方的补偿。两者都不是市场无效率："赚取期货升水"的策略并未利用什么定价错误，它获得的是承担一项偶发风险的报酬。

22.8　VIX 交易所交易产品

第 18.12 节把 2018 年 2 月列为对冲推动市场的事件之一，下面从产品角度看其机制。

反向 VIX 产品是一种交易所交易票据（银行的债务）或基金，其价值逐日与一个不断展期、持有前两个月 VIX 期货的指数反向变动：该指数每跌 1%，它涨 1%；每涨 1%，它跌 1%。它实质上是前两个月 VIX 期货的空头，经过包装，零售投资者无需期货账户就能收取例 22.5 中的展期收益；到 2018 年初，规模最大的两只产品 XIV 与 SVXY 合计约 30 亿美元。要提供每日 $-1\times$ 的敞口，

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

产品就必须每天再平衡以恢复该敞口，这与第 14.9 节的杠杆基金完全相同。

例 22.6 反向产品为什么必须在上涨中买入

净值为 A、维持 $-1\times$ 敞口的基金做空名义金额为 A 的期货。设期货当日收益率为 R。

净值变为 $A(1-R)$，故新的目标空头为 $A(1-R)$。

而现有空头的敞口已增长到 $A(1+R)$。

因此该基金必须在收盘时买入

$$A(1+R) - A(1-R) = \mathbf{2}\boldsymbol{AR}$$

的期货。价格上涨时它买入，因此这种再平衡是助涨助跌的，是第 18.12 节空 gamma 反馈的另一种形式。

按反向 VIX 产品约 30 亿美元的规模计算，再平衡如下：

期货变动	变动后净值	所需买入
+10%	27.0 亿美元	6.0 亿美元
+25%	22.5 亿美元	15.0 亿美元
+50%	15.0 亿美元	30.0 亿美元
+96%	1.2 亿美元	57.6 亿美元

基金越缩水，需求越大。期货上涨 96% 时，这些产品已损失 96% 的资本，却必须在一个本已对其不利的市场中买入 57.6 亿美元期货，接近其原始规模的两倍。

这笔买入要在期货收盘前的十五分钟内完成，而那段时间的成交量通常只占全天的一小部分。这笔再平衡不是深度市场中的一笔大单，而是一个稀薄市场中事先公开的大单。

图 22.4 把两个量画在同一坐标系中，问题就出在交点。基金必须买入的量随涨幅上升，基金自身却在缩小；当日涨幅超过三分之一后，所需买入量就超过了基金剩余的全部价值。2018 年 2 月的情形正处于两条线交叉之后。

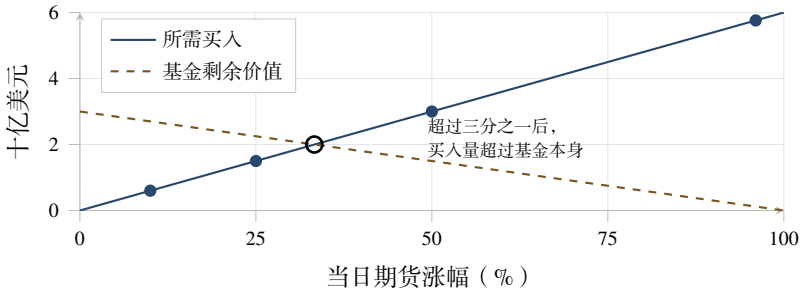


图 22.4: 资产规模 30 亿美元的 $-1\times$ 反向 VIX 产品的每日再平衡。标记为例 22.6 中的涨幅。

案例 22.2 2018 年 2 月 5 日，从波动率产品看

那天标普 500 下跌约 4%，跌幅不小，但算不上历史性的。VIX 期货大约翻了一倍。

对于 $-1\times$ 产品，标的期货变动 100% 就意味着全损：净值乘数是 $(1-R)$，在 $R=1$ 时为零。最大的反向产品 XIV 的招募说明书中有一项条款，允许在发行方盘中公布的价值（日内指示价值）较前一日收盘下跌超过 80% 时提前终止。这一条件触发了。该票据被提前终止，持有人每张票据拿回 5.99 美元，而几天前它还在 100 美元以上。SVXY 是直接持有期货的基金，而非银行发行的票据，没有这类条款；它当天亏损约 90%，但存续了下来。三周后，其

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

发起人把敞口降到 −0.5×，并一直维持至今。这一事件有三点应分别说明。

产品的表现与其声明一致。日度 −1× 反向产品在标的单日变动 100% 时会损失全部，招募说明书也是这样写的。在狭义上，这不算误导销售。

再平衡放大了毁掉产品的那次变动。例 22.6 给出了规模。正因为价格已经上涨，这些产品必须在收盘时买入，而它们的买入量占可得成交量的相当一部分。对冲需求随亏损增长的产品，等于在亲手促成自己的毁灭。

市场本身已很脆弱。两年来已实现波动率持续偏低，市场积累了大量做空波动率头寸，范围远超交易所交易产品：第 19.10 节的卖出期权策略、交易商的账簿，以及按波动率决定股票配置的基金（风险平价与波动率目标基金，其配置随已实现波动率上升而机械下降），都持有这类头寸，而且方向一致。

一般性的教训与第 18.12 节从五个事件中得出的相同，第 35.7 节在自动赎回市场中还会遇到：机制在于头寸过度集中加上机械化对冲，工具是次要的。1987 年的组合保险、2018 年的反向交易所交易产品、2024 年的雪球敲入，是同一结构的不同包装。反复出现的特征是：对冲需求是价格的已知函数，2018 年时还是公开的函数，任何愿意动手的人都能事先算出来。

22.9　同一份溢价，从三种产品看

第 19.10 节指出股指的隐含波动率比随后的已实现波动率高出两到四个点。按方差互换的形式，这份溢价以 VIX^2 对随后 30 天的已实现方差来度量，Carr 与 Wu（2009）就是这样度量的；它随时间变化。第 22.1 节的三种产品都在收取这份溢价，但收到的数额并不相同。这可以用来检验对每份合约的理解，例 22.7 就做这一检验。

例 22.7　一份溢价，三个数

假设 1 年期隐含波动率为 18%，已实现波动率为 15%。

做空 delta 对冲跨式，按第 22.1 节，赚到的是隐含与已实现*方差之差*，沿路径按 gamma 加权：

$$18^2 - 15^2 = 324 - 225 = 99 \text{ 个方差点（波动率点的平方）}$$

但实际能赚到多少，取决于标的价格在何处停留。若股价这一年大多停留在离执行价很远的地方，该头寸在价格变动时的 gamma 很小，只能收到这 99 点中的一部分。

*做空方差互换*以 18% 成交，恰好赚到 99 个方差点。按单位 vega 名义本金计，由式 (22.2)，空头的收益为 $(K_{\text{var}}^2 - \sigma_R^2)/(2K_{\text{var}})$，此处为

$$\frac{18^2 - 15^2}{2 \times 18} = \textbf{2.75 个波动率点}$$

完全不取决于价格在哪里移动。它小于两者 3 个点的波动率差，因为收益是 σ_R 的凸函数（第 22.4 节）：已实现波动率低于执行利率时空头赚到的，少于高出同样幅度时它要亏掉的。它与跨式收取的是同一个量，只是收取得更直接，这就是这份合约存在的理由。

*做空 VIX 期货*赚的则不同。它收取的是例 22.5 的展期收益（在示意曲线上每月 0.8 个点），押注的是*曲线形状*，而不是 1 年期隐含波动率与 1 年期已实现波动率之差。两者相关，但它们是针对不同变量的不同合约，可能分道扬镳。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

工具	收的是什么	会出什么问题
delta 对冲的跨式	隐含减已实现方差，按 gamma 加权	路径：gamma 未必在移动发生处
方差互换	隐含减已实现方差，精确交付	凸性：损失是二次的
做空 VIX 期货	沿曲线下滑的展期	曲线倒挂，且早于已实现波动率上升

陷阱藏在第三行。VIX 曲线随波动率的预期立即倒挂；已实现波动率则要等价格真正大幅变动才会上升。因此，做空 VIX 期货的头寸立即承受损失，而做空方差互换的结算损失要随价格变动的实际发生逐步累积；其盯市价值在隐含方差上升时同样亏损，但收益要等已实现路径决定。把两者视为可以相互替代的人会发现，二者在平静市场里相关性很高，却恰恰在最关键的那一周里低得多。

22.10 方差互换账簿会出什么问题

第 22.3 节的复制在其假定下是精确的，交易商的业务就存在于这些假定与现实之间的缝隙中。其中有四条缝隙最重要。

跳跃。对数合约的论证假定路径连续。对数幅度为 J 的跳空使已实现方差增加 J^2（年化之前），而复制组合收到的是 $2(e^J - 1 - J)$，两者相差约 $J^3/3$，向下跳空时复制组合收得更少。复制恰恰在最关键的日子里对冲不足，这正是第 21.5 节所说的残差：任何事先建立的头寸都无法对冲它。

股息。已实现方差由价格收益率算出，而价格在除息日下跌。除非合约对此作调整（股指合约通常不调整，个股合约则常把实际支付的股息加回），否则一次大额特别股息会被记为一段从未发生的波动率。

个股。第 22.5 节记录了个股方差互换虽从一开始就带上限，2008 年后仍几乎停止交易。原因在于例 22.3 的凸性作用于可能因业绩不及预期或收购要约而跳空 40% 的标的：卖方损失即使有上限，在上限以内仍是该变动的二次函数，而该变动分布的尾部远比股指厚。离散度交易台本会使用个股方差互换，却常改用跨式或其他期权，因为带上限的互换成交清淡，而上限又切掉了成分端所做多的个股大幅波动带来的收益。这一替代恰好重新引入了这种产品本要消除的路径依赖。

期权序列不等于合约本身。交易商持有的是固定的期权组合，客户持有的是对已实现方差的索取权。若标的移动得足够远，使序列中的执行价全部变为深度实值或深度虚值，复制组合的 gamma 就不再与对数合约相匹配，对冲效果恰在已实现方差、从而应付收益最大时变差。这就是例 22.1 的截断问题，只不过在这里是持仓期间持续存在的风险，而不是定价误差。

*这些都不是理论的缺陷。*这份合约按定义无需模型，但每一条都仍需判断，方差互换交易台的业务就是给这些判断定价。

22.11 离散度

第 16.2 节提到了离散度交易者，第 19.7 节给出了计算：由指数与个股的隐含波动率可以反推出一个相关性。例 19.4 的离散度交易，即卖出指数波动率、买入个股波动率，就是押注该相关性的头寸；用方差互换可以把它构造得很纯粹。

取例 19.4 的数字，并把其中的隐含波动率当作 1 年期方差互换执行利率：50 只等权股票为 30%，指数为 18%，隐含相关性 34.7%；例 19.4 在已实现相关性 25% 时得到的 2.6 个点差距，按方差收益计为 2.38 个点（见下文表格第一行）。成分端的权重由例 19.4 中式 (19.3) 的等权形式得出。成分方差 σ_c^2 平行移动时，在相关性不变的情况下，指数方差 σ_I^2 按 $\sigma_I^2/\sigma_c^2 = (0.18/0.30)^2 = 0.36$ 倍移动。因此，每做空 1 单位指数方差，持有平均分配在 50 份成分互换上的 0.36 单位方差名义本

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

金，就能使头寸对波动率中性，只承担相关性风险。一般而言，这一权重为 $(K_I/K_c)^2$，即指数执行利率 K_I 与成分执行利率 K_c 之比的平方。

图 22.5 画出了由此得到的盈亏随已实现相关性的变化，这条线正体现了该结构的意义：无论成分波动率如何，它都在隐含相关性 34.7% 处穿过零点，并随相关性线性变化，斜率由成分方差决定。例 22.8 从中读出四种情形，并加上一种平静情形。

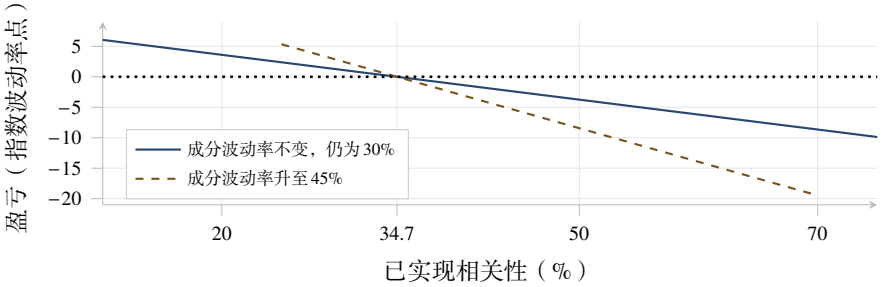


图 22.5: 方差中性离散度交易的盈亏随已实现相关性的变化。

例 22.8　离散度赚什么、亏什么

该头寸以 18% 做空 1 单位指数方差，以 30% 做多 0.36 单位成分方差。

成分波动率	已实现相关性	盈亏	
30%	25.0%	+2.38	相关性低于隐含
30%	34.7%	0.00	相关性恰好实现在隐含水平
30%	45.0%	−2.53	相关性上升，波动率不变
20%	20.0%	+1.60	平静：两者都下降
45%	70.0%	**−19.46**	崩盘：波动率与相关性同时跳升

（盈亏以每单位指数 vega 名义本金的波动率点计。）

*第二行是检验。*已实现相关性恰好等于隐含水平时，无论波动率如何（只要各成分的已实现波动率相同），该交易的盈亏都恰好为零。这并非人为设定，而是由权重自然得出的，它确认了该头寸是纯粹的相关性押注。

*最后一行是这笔交易本身。*第一行（相关性比隐含水平低约十个点）赚 2.38 个点；崩盘亏 19.46 个点。比例是一比八，而且这笔损失与组合中其他所有头寸的损失出现在同样的几周里。

不对称有两个原因。相关性损失按已实现成分方差放大，而崩盘中两者同时上升：成分波动率维持 30% 时，70% 的相关性损失 8.65 个点；与之相伴的 45% 波动率下则损失 19.46 个点。此外，相关性从 34.7% 出发，向上的空间接近向下的两倍，因此可能出现的最大变动都对做空的指数端不利。

因此这笔交易被形容为“平时稳定小赚、一亏就是一大笔”，做它的是能够按资本基础控制规模的交易台，而不是必须按月汇报业绩的基金。Cboe 把隐含相关性编制成指数公布（COR1M、COR3M）。2024 年 7 月，指数收益集中于少数几只超大市值股票，三个月期指数跌至有记录以来的最低点，这笔交易也已十分拥挤；8 月 5 日波动率飙升时（第 22.6 节），相关性随之上升，方向正是上表最后一行。

相关性互换。 相关性互换直接按已实现平均两两相关性与执行水平之差结算，听起来更纯粹，用得却更少。原因在于复制：离散度交易由方差互换构成，而方差互换本身可由期权复制；相关性互换则无法复制，卖出它的交易商只能用离散度头寸近似对冲，其收益是同一相关性按方差加权的替代量。市场交易的是可复制的替代品，而不是纯粹的工具；方差而非波动率成为标准合约，也是出于同样的偏好。买方主要是因发行最差价票据而做空相关性的结构化产品交易商（第 34.11 节）；卖方则是对冲基金与离散度交易台，它们本已通过方差持有同样的观点。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

22.12 远期方差与波动率上的期权

第 21.8 节指出粗糙波动率模型的直接输入是远期方差曲线，即今天对未来每一时间窗口的公允方差利率。这条曲线本身就是交易对象，本节讨论它在哪里交易。

远期起始方差互换以未来某一时间窗口内的方差为标的，可由两份即期起始方差互换的价差复制：做多期限较长的、做空期限较短的，按各自期限加权。由于两端都可由期权复制，远期也可以：整条远期方差曲线都由今天的普通期权曲面张成，而且不需要可储存的标的，第 5 章的远期价格则需要。交易商用它对冲自己发行的棘轮与自动赎回结构的前向波动率敞口（第 34.12 节、第 35 章），波动率基金则用它建立期限结构头寸。例 22.9 给出了完整计算。

例 22.9 从两份即期互换读出远期方差

设 6 个月方差互换报 18%，1 年期报 20%。到各日期的总方差为 TK^2_{var}：$0.5\times0.0324 = 0.0162$ 与 $1\times0.0400 = 0.0400$。后半年的方差就是二者之差，再除以它所覆盖的半年：

$$\sigma^2_{\text{fwd}} = \frac{1\times0.0400 - 0.5\times0.0324}{1-0.5} = \frac{0.0238}{0.5} = 0.0476, \qquad \sigma_{\text{fwd}} = \mathbf{21.82\%}$$

远期高于两个即期执行利率，这与第 4 章中向上倾斜的曲线上远期利率高于两个即期利率是同一道理：期限结构在半个期限内上升了两个点，这两个点必须全部由后半段补足。检验用的是裂项恒等式：两个半年方差的平均恰为 1 年方差，$(0.0324 + 0.0476)/2 = 0.0400$。

按方差名义本金，做多一单位 1 年期互换、做空半单位 6 个月互换，就是做多 0.5 单位远期方差；换算成一单位，即做多 2 单位、做空 1 单位，这正是“按各自期限加权”的含义。

对未来方差非线性的产品不能由曲面张成。VIX 期货（方差的平方根）、以已实现方差和以 VIX 为标的的期权，以及第 22.5 节的上限，都需要一个刻画方差如何变动的模型，而不只是方差的期望。这正是第 21 章划出的界线。

VIX 期权是规模最大的例子。它们是欧式期权，与期货一样以 SOQ 现金结算，其远期是同一到期日的期货价格而非即期 VIX，因此看跌–看涨平价关系对应的是期货。定价需要同时刻画标普 500 与据以计算 VIX 的波动率曲面的联合模型。其隐含波动率向上偏斜，与股票的偏斜方向相反，因为 VIX 会骤升而不会骤降，市场愿为这一右尾支付溢价。尾部风险套保者买入虚值看涨期权作为崩盘保护；卖出它们的是波动率卖方与交易商。把 VIX 公式用于一串 VIX 期权，得到的是 VVIX，即 VIX 本身的隐含波动率。用同一个模型同时拟合 SPX 微笑与 VIX 微笑，就是第 21.8 节的联合校准问题；陡峭的 VIX 偏斜正是其难处所在：它要求的波动率的波动率，单凭 SPX 微笑看不出来。

22.13 谁在交易，交易了什么

波动率的买方就是第 16.2 节的保护买方，只是换了一种产品。养老基金买入 VIX 看涨期权或做多方差互换，是在为其股票组合买入凸性。它支付第 19.10 节的溢价与例 22.5 的展期成本，而且是明知而为，因为另一种选择是少持有股票。

波动率的卖方收取这份溢价。他们分为两类：能承受回撤的（资本充足的交易商、保险公司与捐赠基金），以及承受不了的，即其余的大多数。卖方的实际对冲少于其宣称时会发生什么，安联环球投资（Allianz Global Investors）的 Structured Alpha 基金是一例：基金卖出股指期权，并告诉投资者持有防范崩盘的看跌期权，经理实际买入的却是更虚值、更便宜的看跌期权；2020 年 3 月，这批管理规模一度超过 110 亿美元的基金亏损逾 70 亿美元。该公司的美国子公司于 2022 年 5 月承认证券欺诈罪，共支付约 60 亿美元。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

交易商居间撮合，随客户买卖成为多头或空头，并用第 22.3 节的普通期权序列对冲；它们做的是该序列与合约之*差*的生意（第 22.10 节）。

离散度交易台按第 22.11 节所述交易相关性，也是指数保护买方的天然对手方：指数看跌期权的需求使指数偏斜变陡，也正是这份需求把隐含相关性推高到值得卖出的水平。最差价票据的发行是这类交易的第二个来源：投资者做多相关性，发行交易商因而做空相关性（第 34.11 节），并通过买入指数波动率、卖出个股波动率把它买回，这又进一步推高隐含相关性。

波动率目标与风险平价基金根本不交易波动率产品，却是市场上最大的波动率*敞口*之一，因为其股票配置是已实现波动率的减函数。目标波动率为 10% 的基金按 $10\%/\sigma_R$ 的比例持有股票：已实现波动率从 12% 翻倍到 24% 时，股票权重减半，由 83% 降至 42%；假设这类基金共有 1,000 亿美元，就要卖出约 420 亿美元股票。它们不持有任何期权，却在机械地做空波动率；第 22.8 节的案例说明了已实现波动率跳升时这意味着什么。

连同所持股票一起看，投资者整体在结构上做空波动率，溢价就是卸掉这份风险的价格。本章的几次事件表明，承担这份风险的能力小于收取溢价的意愿，而这一差距总在最不合时宜的时刻暴露。

22.14　中国市场的若干差异

方差互换、VIX 期货与离散度交易，境内没有一件以本章所描述的形态存在。三者各有原因，合起来决定了境内的波动率风险溢价由谁、以什么方式收取。

没有方差互换市场，原因在于曲面

境内没有标准化的方差互换，场外的零星交易也不构成市场。表面原因是缺乏需求或缺乏合约文本，但真正的原因见第 22.3 节。

方差互换之所以能卖出，是因为它可以复制。复制需要一整串虚值期权，尤其是式 (22.5) 中权重最大的低执行价合约。第 19.13 节指出，境内挂牌执行价范围窄，深度虚值合约稀少。因此复制组合在境内根本无法构建，做市商无法把方差互换转化为可对冲的头寸，只能整笔持有。境内的波动率因此只能以期权交易；又因为没有 VIX 期货（见下一小节），第 22.1 节的三条路只剩 delta 对冲的期权一条，交易者承担着有方差互换的市场里本可消除的 gamma 加权风险。

没有可交易的波动率指数

中国波指（iVIX）2015 年起试运行，2016 年 11 月正式发布，2018 年 2 月暂停（第 19.13 节）。对本章而言，重要的不是指数本身，而是它从未有过期货。没有 VIX 期货，没有第 22.7 节的期限结构可观察，也没有第 22.9 节的展期可收取；境内的期限结构只能由期权隐含波动率推出，而这些隐含波动率也受挂牌深度限制（第 19.13 节）。这也意味着境内没有 XIV 那样的零售波动率产品，也没有第 22.8 节的 $2AR$ 机制；但同类风险并未消失，只是换了一种形式，即下一小节的雪球。

雪球是境内版的结构性做空波动率

第 12.12 节介绍了雪球，第 18.12 节讲了它的对冲，第 21 章讲了给它定价的模型，第 35.7 节与第 35.14 节完整讲述了 2024 年初的集中敲入。放在本章的框架里，它是境内收取波动率与相关性风险溢价的主要工具。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

*相同之处。*投资者做空波动率（更准确地说，做空下行波动率）以换取票息；发行方对冲，而对冲交易在压力中与市场同向，因而起放大作用（第 18.12 节）。两者的头寸都过度集中，对冲都是机械化的，且对冲需求都是价格的已知函数。

*不同之处。*XIV 每日再平衡，故有例 22.6 的 $2AR$ 公式；雪球没有日度再平衡，其对冲需求的突变来自敲入线上 delta 的跳变，而非每日的机械操作，因此其冲击集中于特定价位，而非特定时刻。

*规模也不同。*2018 年 2 月全部反向 VIX 产品约 30 亿美元；境内雪球存量高峰时以千亿元计。两者的名义本金不能直接比较（雪球的名义本金不是净值），但即使粗略调整，境内这类头寸相对于标的市场的规模也相当可观。

*销售渠道不同，后果也不同。*XIV 在交易所挂牌，有券商账户的零售投资者都能买。境内雪球通过私募与高净值渠道销售，2021 年后适当性管理进一步收紧。因此直接受损的零售投资者更少，风险则更集中于渠道与发行方。风险并未消失，只是从众多小账户转移到了少数几张资产负债表上，孰轻孰重取决于承担者的资本实力。

离散度交易在境内几乎无法开展

第 22.11 节的交易需要个股波动率与指数波动率两端。境内有场内股指期权，但没有场内个股期权，个股期权只存在于券商场外市场。这带来三重障碍。

*隐含相关性无法从公开数据观察。*第 19.7 节的反解需要成分股的隐含波动率，而境内这些隐含波动率没有公开报价。任何关于境内隐含相关性的说法，都建立在场外报价或模型假定之上。

*成分端的交易对手集中。*场外个股期权的对手方是少数几家券商，因此这一端的执行成本、可得规模与信用风险暴露，都与交易所市场大不相同。

*两端的市场结构也不同。*指数端在交易所、逐日盯市、有中央对手方；成分端在场外、双边、按第 8 章的抵押品安排结算。因此，一笔本应市场中性的交易带有两端之间的结构性基差；这份基差在压力时期会扩大，而那恰恰是该交易本已亏损的时候。境内的离散度交易也就主要由能同时参与两个市场的券商自营完成，外部参与者无法复制。

溢价被谁收走：基差里的波动率

综上，境内的波动率风险溢价不通过本章的任何一种产品收取，而主要通过三条渠道：

*场内期权的义务仓。*卖出 50ETF、300ETF 等 ETF 期权与股指期权并做 delta 对冲，是最直接、也是唯一可以完整套用第 18 章方法的一条。

*雪球与场外结构。*即上一小节所述，规模最大。

*股指期货的贴水。*这一条是境内特有的。第 18.14 节记录了境内股指期货长期贴水，并指出雪球发行方为对冲而持有期货多头，贴水因此是其收入来源之一。贴水水平也随雪球的对冲流变化（第 35.14 节）。于是，一份本质上属于波动率与相关性的溢价，有一部分以基差的形式出现在线性产品上。只交易股指期货、从不碰期权的投资者因此也在收取或支付这份溢价，多半并不知情；贴水又恰在崩盘中加深，与其期货头寸的亏损同时发生，与第 22.13 节的波动率目标基金同理。

22.15 这些结果的由来

本章的工具建立在一个完全不依赖模型的结论之上。Breeden 与 Litzenberger（1978）证明期权链直接揭示了终端分布；Carr 与 Madan 后来证明任何取决于该分布的收益都可以由期权复制。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

Neuberger 的对数合约（1994）是方差互换所依据的收益结构，其 delta 对冲后的盈亏恰好等于已实现方差；Demeterfi、Derman、Kamal 与 Zou（1999）把复制写成了交易台所用的形式，第 22.3 节的 $1/K^2$ 权重即源于此。CBOE 于 2003 年按同一方法重建了 VIX，该指数因而是方差计算，而非隐含波动率的平均；Carr 与 Wu（2009）以方差度量了这类交易的溢价（第 19.10 节）。

小结

持有波动率有三种方式：delta 对冲的期权、方差互换和 VIX 期货，三者不能相互替代。第一种支付按 gamma 加权的已实现方差减隐含方差，因此取决于标的在哪里移动；第二种精确支付已实现方差；第三种是对一个计算出来的指数水平的索取权。

方差互换按合约定义的已实现方差支付 $N_{\text{vega}}(\sigma_R^2 - K_{\text{var}}^2)/(2K_{\text{var}})$。它可以由按 $1/K^2$ 加权的虚值期权静态复制，因为对数合约的 delta 对冲在每条路径上都赚到已实现方差，而对数合约的收益可由该期权序列复制。市场交易方差而非波动率，因为方差可复制；方差互换的执行利率比波动率互换高出的部分随波动率的波动率迅速增大，所以它不是波动率预测。同样的凸性使卖方损失呈二次增长：2008 年之后，本就带上限的个股方差互换市场萎缩，股指方差互换也出现了带上限的合约；带上限的合约需要模型，而 2020 年 3 月显示了上限的价值。

VIX 是按 Cboe 规则计算的、以标普 500 为标的的 30 天期方差互换利率：$1/K^2$ 权重偏重低执行价，偏斜又使这些期权变贵，所以它高于平值隐含波动率；截断规则使它依赖报价深度；它还是两个到期日之间的插值。它是一个定义明确的数字，却不是任何可以持有之物的价格。VIX 期货不是远期，因为 VIX 无法持有；在期货升水的曲线上展期多头头寸会持续亏损，按年累计可达头寸的很大一部分，买方的这项成本就是卖方的溢价。

净值为 A 的反向 VIX 产品在期货收益率为 R 时必须买入 $2AR$ 的期货，因此其对冲需求随亏损而增长；2018 年 2 月 5 日，这一需求压垮了收盘时的流动性。离散度交易以 $(K_I/K_c)^2$ 的权重做空指数方差、做多成分方差，已实现相关性等于隐含水平时盈亏为零，崩盘中则亏掉数倍于正常盈利的金额，因为相关性在所有资产同时下跌时上升，而其损失又按同时上升的成分方差放大。远期方差曲线由今天的普通期权曲面张成；对方差非线性的产品则不然，需要第 21 章的模型。

在中国，方差互换、VIX 期货与离散度交易都不以上述形态存在：复制所需的深度虚值合约稀少，因此波动率只能以期权而非方差的形式交易；中国波指从未有过期货，因此没有可供展期的波动率期货曲线；雪球是收取波动率与相关性溢价的主要工具，与 XIV 一样头寸集中、对冲机械，但它把对冲的突变放在敲入线上，而不是按日再平衡，因此冲击集中于特定价位而非特定时刻；离散度交易几乎无法开展，因为没有场内个股期权。境内溢价有一部分以股指期货贴水的形式出现，收取者在自己的账户里看不到其来源。

延伸阅读

Demeterfi、Derman、Kamal 与 Zou 关于方差互换的论文是式 (22.5) 最初的从业者推导，本章对其完整的复制过程作了压缩。Carr 与 Lee 综述了波动率中哪些可复制、哪些不可复制；波动率互换调整的精确表述可从这里入手。Cboe 的 VIX 编制方法文件记录了截断规则与到期日轮换等构造细节，值得一读，因为该指数的种种奇特之处都出自计算机制而非理论。关于 2018 年 2 月，国际清算银行 2018 年 3 月季度评论中的分析是标准文献：例 22.6 的机制只是简单的计算，该分析回答的是当天的变动有多少由再平衡造成。Bergomi 的著作（2016）是远期方差模型以及方差期权与 VIX 期权方面的从业者参考书。境内方面，各交易所关于期权加挂与做市商制度的规则，是

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

第 22.14 节“复制组合无法构建”的一手依据；中国证券业协会与券商年报披露的场外衍生品与收益凭证规模，可用于估计境内结构性做空波动率头寸的大小。

练习题

22.1 某方差互换执行利率 20%、vega 名义本金 10 万美元。计算其方差名义本金与已实现 35% 时的收益，与一份对波动率线性的合约比较，并说明方差互换与波动率互换执行利率之差由什么决定。

22.2 解释为什么对数合约的 delta 对冲无论路径如何都赚到已实现方差、对数合约 gamma 的哪项特征造成了这一点，以及复制组合为什么按 $1/K^2$ 而不是等权加权。

22.3 用例 22.1，说明在低波动率下拓宽执行价区间与缩小执行价间距哪一个更有效，并解释为什么这个答案在高波动率下会改变。

22.4 设 6 个月方差互换报 25%，1 年期方差互换报 22%。计算后半年的前向波动率，解释它为什么低于两个即期执行利率，并说明按方差名义本金计，构成一单位远期方差需要在两份互换上持有什么头寸。

22.5 解释方差互换（尤其是个股方差互换）为什么如今常带上限，以及上限对复制论证做了什么。

22.6 解释 VIX 为什么高于 30 天标普期权的平值隐含波动率，以及为什么 VIX 期货不是第 5 章意义上的 VIX 远期合约。

22.7 用图 22.3 的曲线，计算恒定 1 个月 VIX 期货多头头寸的月度与年化展期成本，并说明它由谁收取。

22.8 某 $-1\times$ 反向 VIX 产品净值 20 亿美元。计算期货当日上涨 30% 时所需的再平衡交易及其方向，并解释为什么该需求随产品亏损而增长。

22.9 解释为什么按 $(K_I/K_c)^2$ 加权的离散度交易在已实现相关性等于隐含相关性时（无论各成分共同的波动率如何）恰好为零，以及它在崩盘中所亏为什么远大于它在一个正常季度里所赚。

22.10 隐含波动率 22%、已实现 18%。计算做空方差互换以波动率点计赚了多少，并解释为什么做空 delta 对冲的跨式不一定赚得一样多，以及为什么通常赚得更少。

22.11 某股票在一笔不对股息作调整的方差互换存续期间支付了 8% 的特别股息。说明所度量的已实现方差会发生什么，以及谁从中获益。

22.12 解释为什么离散度交易台对单只个股常用跨式而不用方差互换，以及这样做放弃了什么。

22.13 解释为什么境内没有方差互换市场，并说明这与第 19.13 节的哪一项事实直接相关。

22.14 说明雪球与 XIV 在机制上的一项相同之处与一项不同之处，并解释为什么境内的隐含相关性无法从公开数据观察。

22.15 解释一个只做多股指期货、从不交易期权的境内投资者，为什么仍在收取一份波动率溢价。

进阶习题

22.16 例 22.1 发现在 20% 波动率下把执行价区间拓宽到 50–200 之外毫无改善，而改变间距则会改变答案。推导截断误差与离散化误差，说明各自如何随波动率与期限变化，并求出对一份执

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

行价为 50–200、间隔为 5、远期落在挂牌执行价上的 1 年期合约，两项误差相等时的波动率。

22.17 第 22.5 节论证，给方差互换加上限会摧毁其静态复制，因而需要模型。把带上限的方差互换分解为一份方差互换与一份方差上的看涨期权，说明该看涨期权需要什么关于该过程的信息、而互换不需要，并把它与第 21.11 节对模型风险的度量联系起来。

22.18 例 22.5 得到 43.5% 的年化展期成本，并认为这是补偿而非无效率。先构造“系统性做空 VIX 期货是一项风险溢价”的论证，再构造“它是参与者过度集中、赚取经济租金的交易”的论证，并说明什么证据能把两者区分开。

22.19 例 22.6 表明反向产品的再平衡需求为 $2AR$。推导 +2× 杠杆多头产品的对应表达式，解释为什么两种杠杆方向都会助涨助跌，并讨论一只在一天中的随机时刻而非收盘时再平衡的产品，是更安全还是仅仅更难预测。

22.20 第 22.13 节称波动率目标基金不持有任何期权，却在机械地做空波动率。把它形式化：把该基金的股票配置写成已实现波动率的函数，求其对已实现波动率变动的敏感度，并把该敏感度表示成可与期权 vega 相比较的单位。再讨论这对度量市场总体的做空波动率头寸意味着什么。

22.21 例 22.8 显示第一行的盈利与崩盘损失之比为一比八。给定已实现相关性与成分波动率的联合分布，推导方差中性的离散度交易具有正期望值所需的、关于隐含相关性的一般条件，并解释一家交易台为何可能在该条件不成立时仍理性地做这笔交易。

22.22 第 22.14 节论证境内的波动率风险溢价有一部分以股指期货贴水的形式出现。把这条论断写成一个可检验的命题：说明贴水应当如何随雪球存量、敲入线分布与融券成本变动，你需要什么数据，以及必须先排除哪些替代解释。

22.23 例 22.9 从两份即期方差互换读出一个远期方差。对一条倒挂的曲线（6 个月报 30%，1 年期报 24%）重做一遍，证明远期执行利率低于两个即期执行利率。然后求出使隐含远期方差为零的 6 个月执行利率，并解释高于该水平的报价意味着什么、如何对它套利。

22.24 第 22.12 节称整条远期方差曲线都由今天的普通期权曲面张成，而且不需要可储存的标的。解释为什么方差的情形不需要储存，指出使它成立的假定，并说明放松该假定时什么会失效。

22.25 第 22.14 节指出境内没有方差互换是因为复制组合无法构建。设计一份在境内挂牌深度约束下可以复制的、近似方差互换的合约：说明你会如何修改收益结构、需要哪些执行价、由此引入什么偏差，并讨论这样一份合约相对于直接卖出跨式是否真的更好。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

第 23 章　短期限期权、交易商头寸与市场反馈

前面各章都把期权市场看作转移风险的场所。本章讨论的是当这种转移规模足够大、速度足够快，以至于由此产生的对冲本身成为标的市场中的一股力量时会发生什么。

上一代教科书写作时，这种市场结构还不存在。当天交易、当天到期的期权，即第 10.12 节所说的 0DTE 期权，用不到十年时间从冷门品种成长为占标普 500 期权成交量一半以上的品种。第 10.12 节记录了这一增长，其机制留待本章讨论；第 18.12 节说明了这一机制，即交易商的对冲交易会反过来推动其所在的市场；第 21.12 节则指出，这个市场处于经典随机波动率模型无法生成偏斜的区域。

三种需求汇集在这份合约上：套保者的风险只持续一个交易时段（一次数据发布、一次政策决定），过去却要为此买一个月的保护；零售买方想做杠杆化日内押注；系统化卖方则在最短期限收取第 19.10 节的波动率风险溢价（第 23.13 节）。这些头寸的对冲是稳定还是扰动股指，取决于这些需求如何相互抵消。

本章的结构与其他各章不同，因为它的核心问题目前还没有答案。本章先推演 0DTE 可能破坏市场稳定的机制（第 23.2 至 23.11 节），再权衡证据，迄今证据大体给出的回答是“没有”，并说明为什么这并不令人安心（第 23.12 节），最后讨论什么情况下会酿成事故（第 23.14 节）。

23.1　0DTE 是什么，如何发展起来

当天到期的期权并不新鲜，月度与季度合约也总有到期的那一天。新鲜的是*每一天*都有合约到期。

标普 500 指数期权（SPX：欧式，现金结算，每点 100 美元，周度与日度系列按收盘指数结算）的周度到期日是逐步增加的：先有周五，2016 年加上周三与周一，2022 年加上周二与周四。此后每个交易日都是某批合约的到期日，交易者随时可以建立当日头寸。成交份额随之转移。据 Cboe 的数据，0DTE 合约在 2010 年代中期只占 SPX 期权成交量的个位数百分比，到 2024 年末已过半，2025 年全年接近五分之三。如今成交最活跃的标普 500 期权，是一份到明天就不复存在的合约。这句话里有两点需要区分。

*成交量不是风险转移。*0DTE 合约的 vega 只是月度期权的一小部分，寿命也只有几个小时而不是几周，因此按合约张数衡量这个市场，会高估实际易手的敞口。第 23.12 节还会回到这一点，因为这是相关评论中最常见的错误。

*但成交量就是对冲。*每一份成交的合约都有人对冲；0DTE 合约的对冲集中在几个小时内完成，而不是分摊到几个月里。即使风险本身没有压缩，对冲流也已经压缩；造成市场冲击的正是这种压缩。

23.2　短期限期权为什么表现不同

这个市场的种种反常之处，都源自 $T \to 0$ 时希腊字母的变化。假设标普 500 指数为 5000 点，隐含波动率 15%（正常的平静市场），利率 4%，股息率 1.5%。全章按交易小时计时，每天 6.5 小时，每年 252 天，因为 0DTE 期权依循的正是这个时钟；本章所有数字都按此定价，“30 天”指 30 个交易日，约合 6 周。

表 23.1: 临近到期时的平值看涨期权。最后两列是指数上涨 1% 时每单位指数的 delta 对冲盈亏。

剩余时间	价格	delta	gamma	gamma 项	精确盈亏
30 天	110.47	0.5323	0.001534	1.92	1.89
7 天	51.58	0.5158	0.003188	3.98	3.90
1 天	19.10	0.5060	0.008443	10.55	9.60
4 小时	14.94	0.5047	0.010763	13.45	11.65
1 小时	7.43	0.5024	0.021528	26.91	17.55
15 分钟	3.71	0.5012	0.043056	53.82	21.25

剩 1 小时时的 gamma 是 30 天时的十四倍（表 23.1），而且还在上升：由第 18.3 节的公式一望可知，平值 gamma 以 $1/\sqrt{T}$ 的速度趋于无穷。仅这一个数字就说明了问题的量级。

但更重要的不是 gamma 有多大，而是它集中在多窄的范围内（图 23.1）。表中最后两列说明了这一点。两列都是指数上涨 1% 时的对冲盈亏，一列是泰勒展开中的 gamma 项 $\frac{1}{2}\Gamma\,(0.01\,S)^2$，一列是对期权重新定价得到的精确值；剩 1 小时时，1% 的变动相当于 1 小时标准差的 2.7 倍；指数一离开执行价，gamma 就迅速衰减，到变动结束时只剩平值水平的 3%。精确盈亏沿途累积的是不断变小的 gamma，gamma 项则始终按起点的 gamma 计算，所以精确盈亏比 gamma 项低三分之一；剩 15 分钟时只有它的五分之二。

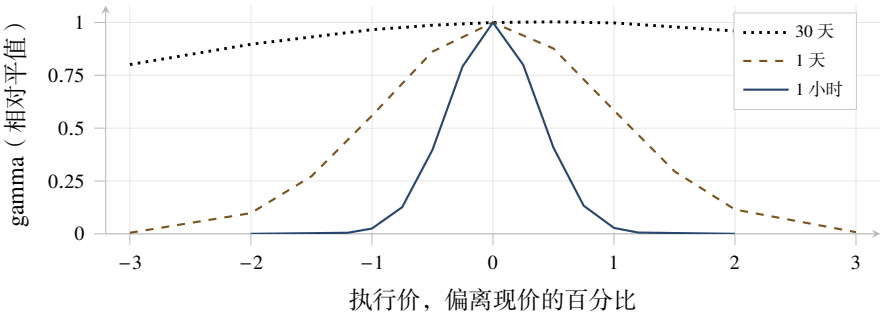


图 23.1: 各执行价上的 gamma，以平值取值归一化。

gamma 超过平值取值一半的执行价范围称为 **gamma 带**。以执行价的对数衡量，该带以略高于现价的一点为中心对称，而非以现价为中心，其边界的收窄情况如下：

距到期	gamma 带边界（现价上方 / 下方）
30 天	+6.76%/−5.52%
1 天	+1.13%/−1.09%
1 小时	+0.44%/−0.43%

这是本章的结构性事实。月度期权账簿在很宽的指数区间内都有 gamma，因此 1% 的变动只会逐渐改变对冲需求。到期前最后 1 小时，0DTE 账簿五分之四的 gamma 集中在现价上下半个百

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

分点之内，几乎全部在一个百分点之内，对冲需求因此是指数位置的阶跃函数。指数移动一个百分点，交易商的全部 gamma 敞口就可能消失、出现或者变号。

23.3 买方的盈亏计算

讨论市场结构之前，先看单笔交易。0DTE 期权的价值几乎全是时间价值，而且只剩几个小时。图 23.2 画出了这几个小时：指数保持不动，期权价值在一天的大部分时间里缓慢流失，到最后一小时则急剧下坠。

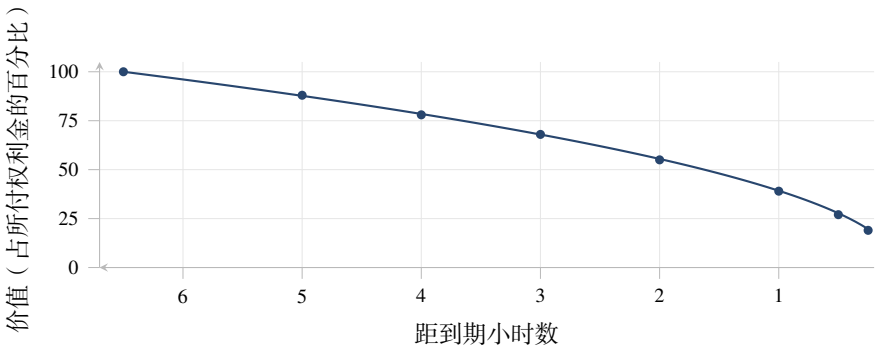


图 23.2: 指数不变时，一份平值 0DTE 看涨期权在盘中的价值。时间自左向右流逝。

例 23.1 买方面对的是什么

指数为 5000 点时，开盘买入一份平值 0DTE 看涨期权，价格 19.10，即**现价的 0.38%**。一个标准差的日变动为 47 点，即 0.94%。

下表给出指数完全不动时该期权在当日的价值，以及在各时点平仓时，买方回本所需的指数涨幅：

剩余时间	价值（指数不动）	占所付权利金	回本所需涨幅
6.5 小时	19.10	100%	—
4 小时	14.94	78%	+0.15%
2 小时	10.53	55%	+0.28%
1 小时	7.43	39%	+0.35%
15 分钟	3.71	19%	+0.38%
到期	0	0%	+0.38%

越早平仓，所需的涨幅越小，因为卖出时期权仍含有时间价值：剩 4 小时平仓时，收回的 19.10 中有 11.47 是时间价值。

日标准差为 0.94%，而持有到期的买方需要指数在当日朝正确方向变动 0.38%，才能仅仅收回本金。这相当于约 0.4 个标准差的门槛，越过之后才谈得上盈利。但这并不是彩票式的不利赌注：该期权定价并无明显错误，其期望收益率为负，主要由第 19.10 节的波动率风险溢价决定。

让人感觉不同的是盈亏的形状。若行情毫无变化，权利金的 61% 在最后一小时之前就已损失，因此这个头寸要么很快押对，要么一文不值。这种产品把对持有人略为不利的期望值，转化为一连串来得快、看得见的全赢或全输；这种设计对人的吸引力远大于缓慢的亏损。第 23.13 节将回到这一点。

还要注意这对买卖价差成本的影响。价格为 19.10 时，一个最小变动价位即一角钱的价差（价格在 3 美元及以上的 SPX 期权最小变动价位为 0.10 美元）占权利金的 0.52%；同一份期权只剩 15 分钟、价格为 3.71 时，同样的一角钱占 2.7%。同一份合约在当日晚些时候交易，按百分比计的成本要高出好几倍，而成交量恰恰在当日较晚时最大。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

23.4　charm：只在这里才重要的希腊字母

第 18.6 节提到过 charm，即 delta 随时间流逝的变化率，但只是一笔带过，因为对月度期权而言它只相当于舍入误差。记 f 为期权价值，则

$$\text{charm} = \frac{\partial \Delta}{\partial t} = \frac{\partial^2 f}{\partial S\, \partial t}$$

其中 t 为已流逝的时间。charm 是与 gamma 配对的交叉导数：gamma 刻画价格变动时对冲如何变化，charm 刻画价格不动、时间流逝时对冲如何变化。它对应 $\Delta S\, \Delta t$ 交叉项；第 18 章的展开式即式 (18.1) 略去了这一项，因为对月度期权而言，仅凭时间流逝，delta 几乎不会漂移。对 0DTE 而言，它引起的对冲流却占主导。

原因可从图 23.1 看出。临近到期时，虚值期权的 delta 必然趋向零，实值期权的 delta 必然趋向一。整个 delta 曲面退化成一个阶跃，而这一退化是时间推移造成的，不是价格变动造成的。图 23.3 以单份合约展示了这一退化：指数从开盘到收盘纹丝不动，执行价略高于现价的看涨期权的 delta 却一路下滑；曲线上的每一点下降，都对应某个人必须完成的一笔对冲交易。

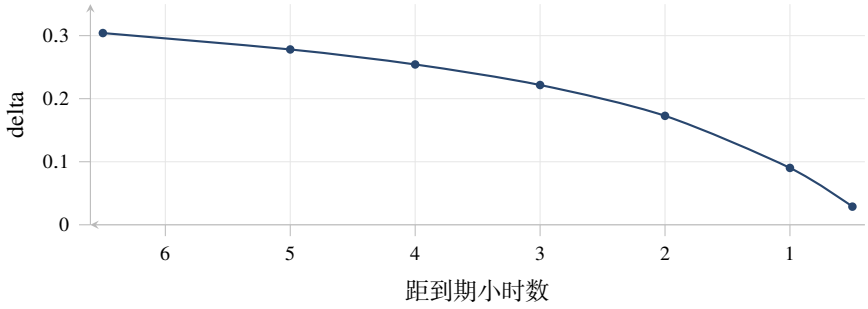


图 23.3: 执行价高于现价 0.5% 的看涨期权的 delta，指数全天不变。时间自左向右流逝。

例 23.2　指数未动，对冲却达十亿美元

考虑一份执行价高于现价 0.5%（约半个日标准差）的看涨期权，这是 0DTE 交易中常见的执行价。指数全天停在 5000 点：

剩余时间	delta	charm（每小时）
6.5 小时	0.3041	−0.0146
4 小时	0.2543	−0.0274
2 小时	0.1728	−0.0614
1 小时	0.0902	−0.1099
0.5 小时	0.0288	−0.1254

某交易商做空 10,000 张此类合约（指数乘数 100），开盘时以 304,095 个指数单位的多头对冲（15.2 亿美元），剩 1 小时时对冲降至 90,164 个单位，即 4.51 亿美元。指数根本没有动，该交易商却必须在最后一小时之前卖出约 10.7 亿美元的指数。这股对冲流有三项性质，使它有别于第 18.12 节的 gamma 对冲。

它是单向的。gamma 对冲在上涨时买、下跌时卖，一涨一跌之间相互抵消。charm 对冲则整天朝同一个方向进行，方向由时钟决定。

它是可预测的。只要知道未平仓量在各执行价上的分布，任何人都能事先算出它，因为唯一的输入是时间的流逝。

而且它在加速。charm 的绝对值从每小时 0.015 升至 0.125（八倍以上），因此这股对冲流在最后一小时

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

最快；此时0DTE成交量最大，其他收盘交易也在争夺同一批交易对手。

这股对冲流起稳定还是扰动作用，取决于交易商头寸的符号，这是第23.7节的内容。毫无疑问的是：如今在美国股市交易时段的最后一小时里，存在一股规模巨大、可以预测、由时钟决定的对冲流，而十年前它的规模还只是如今的零头。

23.5 隔夜跳空不在这份合约里

把0DTE的隐含波动率与任何其他量作比较时，都潜藏着一个不易察觉的度量问题；由此造成的差异很容易被误读。开盘时买入的0DTE期权在收盘时到期。它覆盖的是这一交易时段，而不是隔夜，报价时却以整整一个交易日作为距到期时间。若隔夜时段（收盘至次日开盘）承担日方差的比例为 ω，则交易时段承担 $1-\omega$，能复现该期权价格的隐含波动率为

$$\sigma_{\text{时段}} = \sigma_{\text{日}}\sqrt{1-\omega}$$

其中 $\sigma_{\text{日}}$ 是收盘到收盘收益率的年化波动率，即30天隐含波动率所度量的量。

隔夜占比 ω	显示出的隐含波动率	相对15%的收盘到收盘波动率
0%	15.00%	—
10%	14.23%	−5.1%
20%	13.42%	−10.6%
30%	12.55%	−16.3%
40%	11.62%	−22.5%

美国股指的多数消息在交易时段内发布，ω 通常在15%到25%之间，因此按本章所用的交易日时钟，0DTE隐含波动率比30天隐含波动率低约十分之一，这纯属计时约定所致。（按日历分钟计算距到期时间的系统会犯相反的错误，显示出的0DTE波动率远高于收盘到收盘波动率。）Cboe于2023年4月推出的一日波动率指数VIX1D公布的正是这种仅覆盖交易时段的波动率，拿它与30天期的VIX比较时，同样需要作上述调整。

这一现象可能被误读为短期限期权便宜的证据。其实它们并不便宜，只是度量窗口比所报的期限短。第19.6节的期限结构是真实现象，但这一效应不属于它；把两者混为一谈，会得到一条在短期限端出现虚假拐点的期限结构。

这一效应还有一个比上述误读更重要的实际含义：0DTE期权对冲不了隔夜跳空，因为跳空发生在它到期之后。用日度期权对冲事件风险的机构，必须持有在该事件之后到期的合约；对收盘后公布的消息而言，这意味着持有明天而不是今天到期的合约。

23.6 零期限处的微笑

第21.12节指出本章讨论的市场完全处于经典随机波动率模型无法生成偏斜的区域；第21.7节则给出了经验规律：平值偏斜随期限缩短按 $T^{-0.4}$ 增长，这是在约1个月到数年的范围内测得的。它在1个月以下是否继续成立尚有争议；粗糙波动率（第21.8节）认为成立。外推到这个市场，得到的数字十分惊人。

期限	偏斜相对30天	每1%价值状态的波动率点数
30天	1.00	2.5
7天	1.79	4.5
1天	3.90	9.7
1小时	8.24	20.6

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

期限为 1 天的微笑，陡峭程度约为 30 天期的四倍，到期前 1 小时则为八倍。这些倍数来自上述规律；30 天期每 1% 2.5 个点的水平则是一个程式化的基准，是表 19.3 曲面 1 个月期斜率（每 1% 约 0.4 个点）的数倍，下文的各个斜率都随它同比例缩放。斜率为负，因此陡峭体现在看跌期权上：低于现价 1% 的看跌期权，其隐含波动率可比平值水平高出二十个点。同一斜率不能反过来套用到相同距离的看涨期权上（比 15% 的平值波动率低二十个点，已不成其为波动率），因此看涨翼部变得平坦并向上翘起；这一期限上的微笑由陡峭的看跌翼部和平缓而凸的看涨翼部组成。图 23.4 把四个期限画在同一坐标系中：从 1 个月到 1 小时，看跌翼部从一道缓坡变得近乎垂直，而看涨翼部只移动了几个点。

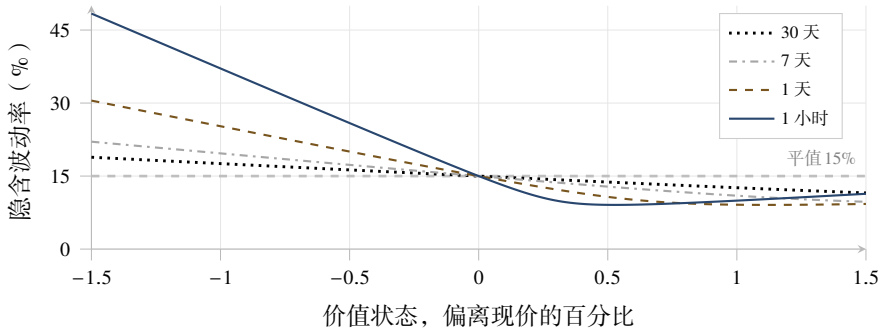


图 23.4: 四个期限的隐含波动率随价值状态的变化。示意图：平值斜率遵循上表的 $T^{-0.4}$ 规律（1 个月以下为外推），平值水平固定在 15%，各期限用同一条程式化的翼部形状。

由此产生三个后果，其中第三个对市场结构最为重要。

*布莱克–斯科尔斯隐含波动率成了一个糟糕的坐标。*第 15.7 节与第 19.12 节把隐含波动率描述为一种报价语言。在这样短的期限下，这种语言会失真：价格上很小的差异对应隐含波动率上巨大的差异，用波动率报价传递的信息反而比直接报价格更少。

*只有含跳跃、粗糙性或极快均值回复的模型才能拟合它。*例 21.3 表明跳跃能产生这种形状的微笑：跨执行价的波动率范围在 1 个月期时为 12.7 个波动率点，1 年期时为 1.5 个点，且几乎全部集中在看跌翼部；第 21.8 节表明粗糙波动率直接给出 −0.4 这一幂次。无论 0DTE 微笑由什么生成，都不是波动率平滑变化的经典扩散过程。这是支持这一论断最直接的证据：在如此短的期限内，这样的路径走不远，不足以让虚值期权具有任何价值，因此需要跳跃、极其粗糙的波动率，或者回复速度快到足以起到同样作用的因子（第 21.8 节）。

*而最陡之处正是零售订单流集中之处。*日内买保护或押注下跌的买家自然会买虚值看跌期权，而这些执行价上的隐含波动率恰恰最极端。支付二十个点偏斜的买家并非在做一笔明显糟糕的交易，因为这种陡峭反映了真实的向下跳跃概率；但他买的是曲面上最贵的部分，而“贵”是以市场自身的单位衡量的。相同距离上的看涨期权买家则处在曲面便宜的一侧，所付的波动率低于平值水平。

23.7　交易商头寸与反馈环

第 18.12 节确立了这一机制，其来源是式 (18.1) 中的 gamma 项：变动 ΔS 使交易商的 delta 改变 $\Gamma\Delta S$；交易商空 gamma 时，重新对冲要顺着变动交易，放大变动；多 gamma 时则逆着变动交易，抑制变动。要把这一机制用到 0DTE 上，需要知道交易商处在哪一边；在这一点上，市场结构比任何模型都重要。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

零售买期权。第 10.12 节所描述的零售订单流以支付权利金为主，即直接买入看涨和看跌期权。作为这股订单流的对手方，交易商持有期权空头、空 gamma，反馈起放大作用。

但机构卖期权。0DTE 成交量中有很大且仍在增长的一部分来自系统化的卖权利金策略：一些基金在可得的最短期限收取第 19.10 节的溢价，卖出看跌价差、看涨价差与铁鹰式（第 12.3 节：同时卖出现价下方的看跌价差与上方的看涨价差）。作为这股订单流的对手方，交易商持有期权多头、多 gamma，反馈起抑制作用。

两者大致抵消，净额很小且会变号。这是这个市场最重要、也最常被忽略的经验事实。关于 0DTE 订单流的研究（其中包括 Dim、Eraker 与 Vilkov，见延伸阅读）普遍发现，订单流接近**双向**：客户从交易商处买入与卖给交易商的期权数量大致相当。因此，交易商的净头寸是两股很大的订单流之差，0DTE 合约带来的交易商净 gamma 只占长期限头寸所产生 gamma 的一小部分。

例 23.3　对冲流有多大

交易台用指数变动 1% 后为重新对冲所必须交易的指数名义金额来表示 gamma。指数变动 1% 使一份期权的 delta 改变 $0.01\,S\Gamma$ 个指数单位，因此 n 张合约、乘数为 m 的头寸需要交易

$$\text{每 1\% 的对冲名义金额} = 0.01\,n\,m\,\Gamma S^2$$

的指数，才能恢复对冲。这与表 23.1 中的 gamma 项不是同一个数：后者是同一变动带来的盈亏，每单位为 $\frac{1}{2}\Gamma S^2 \times 0.01^2$；两者描述的是同一个 gamma，一个以交易量表示，一个以盈亏表示。

假设交易商整体的 0DTE 头寸净空 gamma，规模为每 1% 5 亿美元。由表 23.1 可知，这大约相当于到期前 1 小时 930 张平值合约的 gamma（每张 $0.01 \times 100 \times 0.021528 \times 5000^2 = 538{,}200$ 美元，其中 100 为乘数 m），或 30 天期时的 13,000 张。由于空 gamma，指数下跌时交易商的 delta 增加，上涨时减少，因此他们必须在下跌时卖出期货、在上涨时买入；一阶近似下（假定 gamma 不变），金额为每 1% 5 亿美元：

指数变动	交易商必须卖出（跌）或买入（涨）的指数期货
0.5%	2.5 亿美元
1.0%	5.0 亿美元
2.0%	10.0 亿美元
3.0%	15.0 亿美元

每一笔交易都与引发它的变动同向，因此这股对冲流起放大作用。这一期限内 gamma 并不保持不变（第 23.10 节）：对 1 小时的账簿，实际数字在 0.5% 变动时约为 1.9 亿美元，超过 1% 后停在约 2.3 亿美元，即账簿的全部 delta；对 30 天的账簿，上表的数字相当接近实际。

标普期货每天的名义成交量达数千亿美元，相比之下，这些金额在总量上很小。十亿美元的股指期货，正常情况下几分钟就能成交。

但到纽约时间下午 3:55，它们就不小了。charm 与 gamma 共同把这股对冲流集中到最后一小时，而且在这段时间里方向可能完全一致。收盘是期货一天中最繁忙的时段，但此刻必须卖出的交易商面对的不是全天成交量，而是那一刻其他参与者愿意按最优买价买入的数量，即几百张 E-mini 标普 500 期货合约（每张为指数的 50 倍，指数 5000 点时约 25 万美元），相当于几千万到约一亿美元。应当与之比较的是这个数量，而不是日成交量；按这个尺度，几亿美元全部集中在同一方向，就是实质性的规模。

23.8　日内的跳跃

第 21.5 节指出跳跃会在不同标的之间聚集（使一只股票跳空的事件往往也使其他股票跳空），并把日内层面留给了本章。对 0DTE 而言，这种聚集背后的预定事件不是次要细节，而是主导因素。

交易时段内的波动率分布并不均匀，而是集中在开盘、预定的数据发布、政策公告以及收盘

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

前。对月度期权而言，这些会在平均中抵消；对寿命只有六小时的期权则不会。因此，0DTE 隐含波动率不是一个数字，而是一份时间表，而且这份时间表是公开的。

例 23.4　下午两点的公告如何影响上午的期权

沿用第 23.5 节的设定：收盘到收盘波动率 15%，其中 20% 的方差落在隔夜，因此普通交易时段的标准差为 0.845%，0DTE 期权显示的隐含波动率为 13.4%。

为简便起见，假设普通方差在交易时段内均匀分布。现在加入一则预定公告，其变动的标准差为 s_e。方差可以相加，因此时段标准差变为 $\sqrt{0.845\%^2 + s_e^2}$；最后一列是隐含波动率相对无事件时 13.4% 的倍数：

事件幅度（标准差）	时段标准差	显示的隐含波动率	倍数
无	0.845%	13.4%	—
0.50%	0.982%	15.6%	1.16
0.75%	1.130%	17.9%	1.34
1.00%	1.309%	20.8%	1.55
1.50%	1.722%	27.3%	2.04

仅一则变动标准差为 1% 的预定事件，就使当天上午的 0DTE 隐含波动率上升一半以上。市场的普通波动率没有任何变化，只是度量窗口里加进了未来已知的一分钟。

更剧烈的效应出现在这一分钟过去之后。比较同一份期权在下午 1:59 与 2:01 的情况：剩余 2 小时，指数不变，事件取上表中 1.00% 一行：

	剩余标准差	年化
公告之前	1.104%	31.6%
公告之后	0.469%	13.4%

两分钟内，隐含波动率降至原来的 1/2.36。事件方差只是移出了度量窗口。由此可得三点。

*这不是波动率崩塌，而是日历效应。*对公告本身没有看法、在 1:59 买入并在 2:01 卖出的交易者，是买入了事件、卖出了余波，这笔交易逻辑自洽。在 1:59 买入、指望从波动率上升中获利的交易者，则误解了这种产品。

*它还使恒定波动率假设失效，而且并非建模上的细枝末节。*第 15.1 节把恒定波动率列为布莱克–斯科尔斯假设之一，第 21 章放松了这一假设。在这样短的期限内，问题不在于波动率是随机的，而在于波动率是预先排定的，而且人人手里都有这张日程表。交易台依据一份事件权重日历而不是单一数字为 0DTE 定价，这与第 21 章的任何模型都属于不同类型；第 23.9 节将加以介绍。

*最后，第 21.5 节归因于跳跃的聚集现象，在这里可以直接看到。*使一个指数跳空的事件，与使其他指数跳空的是同一批事件（经济数据、政策、地缘政治），因此日内跳跃风险恰恰在最大的时候跨标的相关。同时做空多个指数 0DTE 虚值期权的账簿并没有分散风险，实际上只是一个头寸。

23.9　为一份 0DTE 期权定价

到目前为止的所有数字都来自布莱克–斯科尔斯–默顿公式，波动率取 15%，按交易小时计时；对希腊字母而言，这是合适的工具，因为 gamma、charm 与衰减的形状不依赖于细节。但读者此时会有两个公式回答不了的问题：实际交易的是哪些期权？如果常数波动率不成立，交易台用的是什么？

交易的是哪些执行价。 大多不是平值的。Cboe 自己对 2023 年成交量的统计，与延伸阅读中列出的学术样本，在分布形状上一致。典型的合约位于平值附近的虚值一侧（距现价约四分之一到一个百分点，delta 在 0.10 到 0.35 之间）；看跌与看涨期权的合约数大致相当，但看跌期权离现价更远。在平静的日子里，距现价一到两个百分点的深度虚值期权占了许多合约张数，却只占很少的权利金，因为每张至多几美元，到下午只值几美分；按权利金而不是合约张数计，市场的重心更靠

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

近平值。这一分布还随日内时间而变化：上午交易的执行价大约覆盖现价上下各一个百分点，到最后一小时则几乎全部落在现价上下约半个百分点之内，即图 23.1 中 1 小时的 gamma 带，因为只有那里还剩时间价值。实值期权成交很少。根据看跌–看涨平价关系，实值看涨期权等于同一执行价的虚值看跌期权加上一个远期多头：它的时间价值就是该看跌期权的时间价值，其余部分是按期权较宽的买卖价差买入的指数敞口。这一时间价值在盘中不断流失：实值半个百分点的看涨期权在开盘时约有 15 个点的时间价值，收盘前一小时约 4 个点，剩 15 分钟时约 1 个点（按第 23.6 节的偏斜波动率计）。想要指数敞口的交易者会买期货，想要期权的交易者则买虚值的一方。零售订单流大多是单端的：直接买入一份看涨或看跌期权，当日建仓，也常在当日平仓。机构订单流大多是价差：现价下方半个到一个百分点的看跌价差、上方相同距离的看涨价差，或两者组合成的铁鹰式，持有到期。第 23.13 节将介绍这些交易者是谁；这里的要点是，市场的定价问题集中在平值附近一条很窄的执行价带上，以及紧贴其下方的一段陡峭的看跌翼部。

为什么一个波动率不够用。 布莱克–斯科尔斯–默顿模型有三条假设，对月度期权尚可接受，到了这个期限却同时失效。其一，波动率为常数，因而方差随时钟均匀累积；但第 23.5 节表明一天方差的五分之一落在合约不覆盖的时段，例 23.4 表明预定的一分钟所含的方差是下午其余时间的数倍。其二，价格路径连续，因而几个标准差以外的执行价几乎一文不值；但期限为 1 小时时，低于现价 1% 的执行价位于 2.7 个标准差之外，而第 23.6 节表明市场给它的定价仿佛这一距离要小得多，因为一次跳跃就能瞬间跨越。其三，对冲连续且无成本，因而价格就是复制成本；但表 23.1 中的 gamma 是月度期权的十四倍，例 23.1 中一角钱的买卖价差占权利金的 2.7%，因此复制成本既不小，也无法明确界定。例 23.5 展示了由此产生的误差有多大。

例 23.5　收盘前 1 小时，平坦波动率错在哪里

在本章的设定下（指数 5000 点，利率 4%，股息率 1.5%），为执行价低于现价的看跌期权定价：先用平坦的 15% 波动率，再用第 23.6 节的平值斜率线性外推给出的该执行价波动率，即在 15% 的基础上，30 天期时每 1% 价值状态加 2.5 个点，1 小时期时每 1% 加 20.6 个点。

剩余时间	执行价	平坦 15%	带偏斜	比率
30 天	低于现价 0.5%	83.99	92.45（16.2%）	1.1
30 天	低于现价 1.0%	73.30	89.90（17.5%）	1.2
1 小时	低于现价 0.5%	0.75	3.72（25.3%）	5.0
1 小时	低于现价 1.0%	0.02	2.75（35.6%）	148

剩余 30 天时，平坦模型的价格大致正确，微笑只是对它作百分之十到二十的修正。剩余 1 小时时，微笑就是价格本身。平坦模型给低于现价 1% 的看跌期权定价两美分，因为在每小时标准差 0.37% 的连续路径下，指数几乎到不了那里；市场给它的定价约为 2.75，是前者的一百多倍，因为一次跳跃就能到达。用平值波动率为这份看跌期权定价的交易台，会以最小变动价位报出它，并把它当作一文不值的头寸来对冲。

交易台改用什么。 没有单一的替代模型，实务做法更接近第 19 章而不是第 21 章：曲面本身就是模型，其余部件都围绕它搭建。

第一个部件是时钟。距到期时间不按分钟计，而按剩余的期望方差计：一条开盘和收盘前方差较大、午间较小的日内分布，再加上当日各项预定事件的权重。这就是**业务时间**；布莱克–斯科尔斯–默顿公式照常使用，只是把 $\sigma^2 T$ 换成这一方差预算。例 23.4 中的期权在公告前后、其他条件不变的两分钟里失去一半以上的隐含波动率，原因也在于此：是方差预算已经用掉，而不是波动率作了修正。

第二个部件是远期价格，取自 E-mini 期货（头寸将用它对冲），或者像第 22.6 节构造 VIX 那

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

样，由期权链内部的看跌–看涨平价关系推出。微笑相对于这一远期而不是现货指数报价。

第三个部件是微笑本身：对每个到期日，以第 19.1 节的标准化价值状态为坐标拟合微笑，

$$\frac{\ln(K/F)}{\sigma\sqrt{T}}$$

（即执行价距远期几个标准差，σ 为平值隐含波动率，T 为剩余业务时间）。拟合采用少参数、在构造上即无套利的形式（常用第 19.5 节的 SVI 参数化），并在日内重新拟合。在原始价值状态坐标中，微笑随到期临近而急剧变陡；在标准化坐标中，这一陡化大部分消失，剩下的是一个与 $T^{0.1}$ 成比例的斜率（即 $T^{-0.4}$ 乘以标准化时除去的 $\sqrt{T}$），这才是拟合必须容纳的残差。对跳跃的看法通过翼部体现：如果交易台预期某一事件的影响会大于日程权重所隐含的程度，就会直接抬高看跌翼部，而不是去调整动态模型中的某个参数。第 21 章的模型在交易台之外使用，用于检验拟合出的曲面能否由某个过程生成：跳跃给出第 21.7 节所见、比市场更陡的短端偏斜，粗糙波动率给出市场所呈现的 $T^{-0.4}$。但报价并不由它们决定。

最后一个部件是库存。围绕拟合中间价的价差与偏斜调整，由交易商自身的头寸和客户的订单决定：各执行价的报价按抵消账簿 gamma 与 charm 敞口的方向调整，在收盘前加宽，并随订单流变动。模型提供的是对冲比率，使上述做法得以运作；对交易活跃的 0DTE 执行价而言，这就是模型的全部职责。价格由市场上已有的买卖报价决定，而不是由某个人的公式决定。

23.10　每天都有的钉住

第 10.9 节讨论月度到期日的钉住风险时，引入了**钉住**效应：标的价格被拉向未平仓量大的执行价，因为对冲多头 gamma 头寸的交易商会在该执行价附近逢涨卖出、逢跌买入。有了日度到期，这一机制如今在每个交易时段都在运行。例 23.6 计算这种回复力的大小，因为它远大于按月度期权的直觉所估计的；图 23.5 把它画了出来。

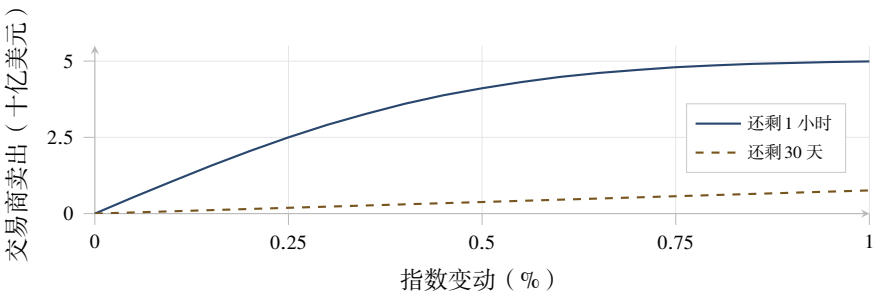


图 23.5: 平值看涨期权多头 20,000 张时，交易商卖出量与指数变动的关系。

例 23.6　还剩 1 小时时的回复力

交易商持有同一执行价的 20,000 张看涨合约多头，指数恰好位于该执行价，距到期还剩 1 小时。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

指数变动	delta 从…到	交易商卖出
+0.10%	0.502 → 0.609	10.63 亿美元
+0.25%	0.502 → 0.752	24.99 亿美元
+0.50%	0.502 → 0.912	41.14 亿美元
+1.00%	0.502 → 0.996	49.90 亿美元

同一账簿若还剩 30 天，0.5% 的变动对应卖出 3.82 亿美元，1% 的变动对应卖出 7.60 亿美元，即图 23.5 中的直线：变动翻倍，卖出量也翻倍。剩 1 小时的曲线显然不是这样，其数字有两项重要特征，而且方向相反。

*小幅变动遇到极大的回复力。*指数变动十分之一个百分点，就带来十亿美元起稳定作用的卖盘。这是真正的钉住：正因如此，指数常在未平仓量大的执行价附近窄幅波动。

*但这种力会饱和。*变动达到 1% 时 delta 已升至 0.996，再没有可卖的了：前半个百分点的变动带来 41.14 亿美元的对冲，后半个百分点只带来 8.76 亿美元。这个稳定器对本不需要稳定的变动作用最强，对真正需要稳定的变动却不起作用。

这种不对称，是第 23.14 节那项担忧中有根据的部分。一个能压住小波动却压不住大波动的市场，不仅在危机中帮不上忙，还会使危机显得更加出人意料，因为本应发出压力积累信号的小幅变动已经被抹平了。

23.11 如何度量交易商 gamma，以及这一数值为何不可靠

第 23.7 节的全部分析都取决于交易商净 gamma 的符号，而这个量无法观察。标准做法（第 18.12 节的案例已经介绍）是取每一份挂牌合约 i（某一执行价上的看涨或看跌期权）的未平仓量 OI_i，算出其 gamma Γ_i，再为交易商指定一方：多头 $s_i = +1$，空头 $s_i = -1$。通常的规则假定交易商持有全部看涨期权未平仓量的多头、全部看跌期权未平仓量的空头。按 SqueezeMetrics（2017）最早给出的形式，公布的“gamma 敞口”就是 $\sum_i s_i \,\mathrm{OI}_i \, m \, \Gamma_i \, S^2 \times 0.01$（$m$ 为合约乘数，SPX 为 100），即带假定符号的、例 23.3 中的每 1% 对冲名义金额（即第 18.7 节以美元计的 gamma）；“翻转水平”则是它变号时的指数水平。

问题在于，这个符号是人为设定的，而不是度量出来的。商业版本根据成交数据推断交易商站在哪一方，而不是直接假定，这缩小了问题，却没有消除它；例 23.7 表明答案在多大程度上由这一假定决定。

例 23.7 假设决定答案

假设同一执行价上有未平仓的看涨与看跌合约各 100,000 张，每张 gamma 相同，并假定交易商是每张合约的一方。设交易商以多头持有的看涨合约比例为 w_c（其余为空头），以空头持有的看跌合约比例为 w_p（其余为多头），则标准规则就是 $w_c = w_p = 100\%$。交易商净 gamma 于是为 $200{,}000\,(w_c - w_p)$ 张合约的 gamma。

假设的比例（看涨多头 / 看跌空头）	交易商净 gamma（千张合约）
100% / 0%	+200
80% / 20%	+120
60% / 40%	+40
50% / 50%	0
40% / 60%	−40
100% / 100%	0

符号在 60/40 与 40/60 两种假设之间翻转，而公开数据无法判断哪一种正确。最后一行就是标准规则本身：在看涨与看跌未平仓量相等时，它恰好给出零，因此在这里，公布的数字会是零。这并不是因为交易商头寸为零，而是因为该假设是对称的。未平仓量记录的是合约的存在，而不记录谁处在哪一方。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

因此，公布的 gamma 敞口水平应当理解为一次“若假设的比例成立，交易商头寸会是多少”的计算，不宜像人们通常那样看重。具体而言：

该假设恰恰在最关键的地方最不可靠。在由备兑开仓（投资者对所持股票卖出看涨期权）和机构买入看跌期权主导的市场中，它大致成立。但第 23.7 节论证过，0DTE 订单流接近双向，而这正是这一朴素比例离真实情况最远的情形。

翻转水平也继承了这一误差。公布的“gamma 翻转”所在的指数水平取决于假设的符号，因此假设不同的两位分析者会从完全相同的数据得出不同的翻转水平。

这些都不意味着这个概念没有用处。交易商 gamma 是真实存在的量，第 18.12 节与第 23.10 节都以它为基础；只是公布的估计精确度量了未平仓量，头寸却是按假设度量的。

23.12　0DTE 是放大还是抑制？

这是市场关心的问题，而现有证据并不一致，样本期也很短。

放大的理由。 第 23.7 节的机制真实存在。gamma 巨大且集中在一条窄带内，因此对冲需求是指数水平的阶跃函数。charm 在临近收盘时产生一股巨大的单向对冲流。头寸高度集中、对冲机械，1987 年（第 40.2 节）、2018 年 2 月（第 22.8 节）以及第 35.7 节的雪球敲入，都出自这种模式。

抑制的理由。 短期限期权的卖方总体上是在向市场提供 gamma。多 gamma 的交易商在上涨时卖出、下跌时买入，起稳定作用。若系统化的卖权利金订单流占主导，0DTE 会使日内市场的波动减小，而不是增大。

数据显示什么。标普 500 的已实现日内波动率并没有随 0DTE 的增长而上升（Dim、Eraker 与 Vilkov 2024）。迄今没有任何一次大幅变动能被令人信服地归因于 0DTE 对冲，尽管自 0DTE 成为这个市场最大的组成部分以来，市场已经历两次压力考验：2024 年 8 月 5 日，以及 2025 年 4 月关税引发的抛售（VIX 收盘超过 50）。对这两次事件的分析（其中包括 BIS 对 8 月 5 日的分析）都把行情归因于消息本身和杠杆头寸的平仓，8 月 5 日还归因于开盘前过宽的期权报价推高了 VIX 本身，而不是 0DTE 对冲。可归因于 0DTE 的交易商净 gamma 总量，与长期限账簿相比看来也很小。与此相反，Brogaard、Han 与 Won 发现波动率有所上升，并归因于投机性的零售交易而不是交易商对冲。

因此，恰当的概括是：机制存在，但尚未造成事故。原因主要有四条。订单流是双向的，这是主要原因，也是最脆弱的一条。到期本身就是天然的止损，因为到了明天头寸已不复存在。保证金每日收取，且头寸经过集中清算：2018 年的事故发生在交易所交易票据 XIV 上，其招募说明书允许提前终止（第 22.8 节），而挂牌期权头寸由第 2 章所述的清算所收取保证金，且头寸到期即自行了结。标的是世界上流动性最好的股票市场。后三条是结构性的而非行为性的，按第 22.5 节案例的论证，这类理由更为可靠。对这一概括应当保持谨慎。

这种稳定性是订单流的性质，而不是工具的性质。没有机制保证 0DTE 订单流会一直保持双向。它之所以双向，是因为两个群体恰好对同一期限有相反的需求，而任一方都可能退出。

头寸不会累积，这一点确实令人安心。0DTE 账簿在收盘时就清零了。相比之下，第 22.8 节反向产品的空头头寸是逐日延续、持有多年的，第 35 章雪球账簿的敲入敞口则随市场数月下跌而增长。0DTE 制造的任何风险，都在一个交易时段内产生并消失，这为风险的规模设定了硬性上限。

但这一上限限制的是规模，而不是速度。每日重置的结构不会酿成慢慢积累的灾难，却仍然可能造成剧烈动荡的一小时。真正能检验这个市场的事件（一次大跳空，恰好在临近收盘、交易商空 gamma 时到来）很少发生。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

案例 23.1　同一机制在流动性不足市场中的表现

第 23.12 节的论证在很大程度上依赖标普 500 的深度。去掉这一条件后，完全相同的机制会怎样运行，值得一看；美国证券交易委员会工作人员 2021 年的报告详细记录了这个案例。

2021 年 1 月，零售投资者大量买入一只被大量做空的美国小市值股票的看涨期权，其中许多是短期限、深度虚值的合约。卖出这些看涨期权的交易商处于空 gamma，第 23.7 节的计算完全适用：股价上涨时，他们的 delta 增大，必须买入股票以维持对冲。

除了一个数字，其余都与指数情形相同。标普 500 能在几分钟内吸收十亿美元的对冲；而一只自由流通股本很小、且其中很大一部分已借给空头的股票，根本吸收不了相应的量。对冲需求相对于实际可得的股份很大，于是推高了股价，股价上涨又增大了对冲需求，需求再次推高股价。人们通常把这一事件归结为参与者的动机问题，因此有三点需要区分。

*交易商不是在投机。*他们是在对冲自己卖出的头寸，用的正是本书自第 18 章以来描述的机制。对冲推动被对冲对象的价格，并不是一种策略，而是 delta 对冲在容量过小的市场中的结构性特征。

*卖空余额（已卖空、尚未买回的股数）与期权同样重要。*空头回补也是买入，两股买盘相互强化。把整个变动都归因于期权对冲，会高估一个真实但并非唯一的机制。这与第 23.12 节对 0DTE 的告诫相同。

*真正的约束是自由流通量，而不是杠杆。*这些期权的杠杆并不异常，异常的是标的太小；正是这个变量决定了第 23.7 节的反馈只是一桩奇闻，还是会酿成事件。

因此，这个案例的教训并不是 0DTE 是安全的，而是：机制已有定论，最终如何取决于对冲需求与可得流动性之比；这一比值对标普 500 很小，对小市值股票则不然。问 0DTE 是否危险，实际上是在问这一比值是否会改变；第 23.14 节列出的正是它可能改变的途径。

23.13　谁在交易 0DTE，为什么

零售方向性交易者把 0DTE 期权当作带杠杆的日内押注来买。例 23.1 给出了其中的经济逻辑：略为负值的期望收益率，以一连串迅速的全赢或全输的形式体现出来。

系统化的权利金卖方卖出 0DTE 价差，在最短期限收取波动率风险溢价：那里的年化溢价看起来最大，更关键的是，头寸不可能被拖入跨日回撤。卖出数小时后到期、风险有限的价差，与卖出月度跨式承担的确实是不同的风险，而差别不只在期限：损失有上限，而且头寸不可能在最糟糕的时刻之后继续持有。

机构套保者围绕交易时段内的特定事件（一次数据发布、一项政策决定）战术性地使用 0DTE，对收盘后公布的消息则买入次日到期的合约：这些风险确实只持续一天，为一个月的保护付费是浪费。这是最少被提及、却可能是规模最大的合理用途，也是对市场完备性的直接改进：只持续一天的风险，如今可以用只持续一天的工具来对冲。

交易商与做市商居间撮合，其头寸就是第 23.7 节所述的传导机制。

产品本身无所谓好坏：把第 12.8 节的复制论证从执行价维度移到到期日维度，结论是更细密的期限集合严格扩大了可实现收益结构的空间。新出现的是它引发的对冲集中，这一点应当另行评估。

23.14　什么情况下会酿成事故

有用的问法不是“0DTE 危险吗”，而是“什么条件会使它危险”，因为后者可事先核查。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

*单向的订单流。*若系统化卖方退出（因为季度业绩不佳、资本要求或基金授权变更），零售买入就会使交易商全部处于空 gamma。

*跳空撞上集中的 gamma。*危险的情形是大幅变动出现在最后一小时：此时图 23.1 中的 gamma 带最窄，例 23.2 中的 charm 流最快。这时 1% 的变动就能把指数带出这条带，本可吸收这次变动的对冲在中途就已耗尽，例 23.6 已说明这一点。

*需要时却没有流动性。*例 23.3 中的所有数字，相对于平均成交量都很小，相对于快速市场中可得的深度却都很大。真正起作用的机制，就是第 2.9 节讨论保证金顺周期性时指出的：在快速市场中，本应提供流动性的参与者，恰恰是突然需要流动性的那批人。短期限对冲也在向流动性较差的市场延伸：自 2026 年 1 月起，市值超过 7,000 亿美元的股票也增加了周一与周三到期（第 10.2 节），这更接近第 23.12 节案例的情形，而不是股指的情形。

*这些都不是预测。*这是一份观察清单，清单上的量（现价附近的未平仓量分布、成交量中卖权利金的占比，以及按执行价估计的交易商 gamma，须按第 23.11 节的告诫解读）都已公布或可以计算。这项风险并不隐蔽；与第 22.8、35.7 与 40.2 节的那些事件不同，这一次业界在风险尚小时就已关注它。

23.15　中国市场的若干差异

本章描述的市场结构在境内并不存在，原因是制度性的，可以说清楚。更有意思的是，同样的反馈机制在境内确实存在，只是借助完全不同的产品起作用。

境内没有 0DTE：原因在于到期日设计

第 10.13 节记录了境内期权的合约月份：ETF 期权挂当月、下月及随后两个季月，股指期权与商品期权的月份更多，但同样按月到期。ETF 期权的到期日为到期月份的第四个星期三，股指期权为第三个星期五。因此境内每个品种每个月只有一个到期日（沪深 300 与上证 50 也只有 ETF 期权与股指期权两个到期日），而不是每天一个。

仅这一点就消除了本章的全部前提。没有日度到期，就没有第 23.2 节那种每天都出现的 gamma 集中，没有第 23.4 节那种每天都发生的 charm 流，也没有第 23.10 节那种每天都有的钉住。

*但在月度到期日当天，本章的分析全部成立。*到期日当天的境内期权就是那一天的 0DTE，其 gamma 带以同样的方式收窄，charm 流以同样的方式加速。差别在于频率而不在于机制：境内每月经历一次本章所描述的日子，而美国每天经历一次。

境内市场对这种日子里的合约有一个俗称：**末日轮**，指临近到期的深度虚值合约在标的大幅变动时价格成倍上涨。2019 年 2 月 25 日，50ETF 单日上涨 7.56%，两天后到期的 50ETF 购 2 月 2800 合约涨了约 192 倍，次日又下跌九成以上，到期时几近归零。这是第 23.2 节 gamma 集中的买方视角。

由此得出一个境内特有的推断：境内到期日当天的效应可能比美国任何单日都集中，因为每个品种整个月的未平仓量都在同一天了结，而不是分摊到二十个到期日上。这一判断可以检验：它意味着在到期日当天及前后，标的的成交量与波动率会系统性升高。

零售参与的形态不同

第 10.13 节记录了境内期权市场的投资者适当性要求，即俗称“五有一无”的那一套：

- 申请前 20 个交易日日均托管资产不低于 50 万元（不含融资融券融入的证券和资金）；

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

- 开户满 6 个月并具备融资融券业务参与资格或金融期货交易经历；
- 通过交易所的期权知识测试；
- 具有期权模拟交易经历；
- 通过风险承受能力评估；
- 无不良诚信记录。

与此截然不同，美国零售投资者在手机应用上几分钟内就能开始交易 0DTE。这带来两方面的后果，而且方向相反。

境内零售的期权参与门槛高得多，因此第 23.13 节所描述的那种大规模零售方向性买入，在境内场内期权市场规模有限。但零售的期权性需求并没有消失，而是转到了别处：以雪球、收益凭证和各类结构化产品的形式出现（第 12.12 节），期限是数月到数年，而不是数小时。适当性管理没有减少这类需求，只是改变了它的形态，把它从最短期限推到了最长期限。

这两种形态的风险特征正好相反。0DTE 的风险是日内的，不累积，每天重置；雪球的风险会跨月累积，并集中在敲入线附近。第 23.12 节列出的四条“为何尚未酿成事故”的理由中，有三条对雪球不成立：雪球的订单流是单向的，投资者一律卖出敲入看跌期权；它不是每日到期，因而风险会累积；其标的（中证 500、中证 1000）的深度远不及标普 500。

这一比较令人不安，但很重要。如果只看“是否允许零售做超短期期权”，境内的制度显然更审慎。如果看“零售的期权性敞口最终以什么形态、承担什么风险”，结论就没有那么清楚了。

同一反馈机制，不同载体

本章的核心机制（对冲需求是价格的已知函数，且与变动同向）在境内也存在，只是载体不同。

雪球的敲入线附近是最直接的对应，见第 18.12 节与第 21 章。第 22.14 节已将它与 XIV 的每日再平衡作过对比：delta 跳变发生在某个价格水平上，而不是集中在某个时刻上；这一区别同样把它与 0DTE 区分开来。

月度到期日是第二个，如上所述。

股指期货的贴水与基差交易是第三个，也最容易被忽略。第 22.14 节指出，境内有一部分波动率与相关性溢价以期货贴水的形式出现；贴水快速变化时，做基差交易的资金必须调整头寸，而这些调整同样是价格的函数。

综合三者来看，境内并不缺少本章的机制，缺少的是本章的产品。这有一个实际含义：第 23.14 节列出的可观察量（各执行价的未平仓量分布、交易商净 gamma、卖权利金占比）在境内对应的是雪球存量的敲入线分布、券商场外衍生品的名义规模，以及股指期货的基差水平。要在境内做本章所建议的那种事前监测，应当关注这三项指标，而不是期权链。

若境内引入更短的到期日

这是一个前瞻性问题，应按本章的框架分析，而不是只问“好或坏”。若境内引入周度或日度到期的股指期权，本章分析逐条适用，而结论取决于三个可事先估计的量。

订单流是否双向。美国的良性局面依赖零售买入与系统化卖出大致抵消。境内是否存在规模相当的系统化卖权利金群体，可以根据公募与私募产品的备案数据来估计；如果不存在，交易商会一律空 gamma，第 23.12 节的抑制理由就不成立。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

标的的深度。案例的教训是后果取决于对冲需求与可得流动性之比。沪深 300 与中证 1000 的期货深度远小于标普 500，因此同样的名义对冲流在境内的冲击更大。这个比值可以直接计算。

以及与涨跌停板的相互作用。这是境内独有的，也是最有意思的。第 19.13 节指出涨跌停板截断的是日收益率。对日度到期的期权而言，涨跌停板给收益结构加了硬上限，实际上把期权变成了价差；同时，当对冲工具触及涨跌停时，delta 对冲无法执行（指数本身没有停板，有停板的是 ETF、股指期货与成分股，而对冲正是用它们进行的）。既有集中 gamma、又可能中止交易的市场，其反馈行为与美国不同；这种差别是有利还是不利，取决于停板在对冲耗尽之前还是之后触发。

这个问题目前没有答案，但可以建模；在引入这类产品之前建模，比事后研究成本低得多。

小结

当日到期的期权用不到十年时间从 SPX 期权成交量的个位数份额涨到过半。成交量高估了实际转移的风险，却没有高估对冲，因为对冲被压缩到了几个小时之内。

种种反常之处都源自 $T \to 0$ 时的希腊字母。到期前一小时的 gamma 是三十天时的许多倍，而 gamma 带收窄到现价附近的一个窄区间，于是对冲需求成为指数水平的阶跃函数。charm 引起的对冲流成为主导：做空执行价略高于现价的看涨期权的交易商，即使指数整天纹丝不动，也要平掉一大笔对冲，方向单一、可以预测，且在最后一小时最快。平值看涨期权买方支付的权利金远低于一个标准差的日变动，而若行情毫无变化，到最后一小时之前已损失其中大半。

有三件事常被误读。0DTE 期权覆盖的是交易时段，却按整整一个交易日报价，因此它显示的隐含波动率低于收盘到收盘波动率，而且对冲不了隔夜跳空。若把 $T^{-0.4}$ 规律外推到 1 个月以下（这一段的证据仍有争议），偏斜从三十天到到期前一小时变陡近一个数量级。日内波动率有日程可循：一则公告会抬高上午的隐含波动率，事件过去后，剩余期权的隐含波动率大幅下降。因此，单一波动率无法为这个市场定价：收盘前一小时，略低于现价的看跌期权在平坦波动率下几乎一文不值，在偏斜下的价值却高出许多倍。交易台按业务时间计时，以按标准化价值状态拟合的微笑定价；模型提供的是对冲比率，而不是价格。

对冲起放大还是抑制作用，取决于交易商 gamma 的符号，而这个符号无法观察：零售买入与系统化卖出大致抵消；公布的估计精确度量了未平仓量，头寸却只是按假设度量的。钉住每天发生，而且会饱和：小幅变动时对冲流最大，变动再大便已无可再卖。至今没有出事，是因为订单流有买有卖、头寸在累积之前就已到期、保证金每日收取、标的市场流动性好；四条中第一条最可能改变，需要警惕的情形是单向订单流在最后一小时遇上大幅变动。

境内不存在这种市场结构，因为境内每个品种每月只有一个到期日；但在到期日当天，本章的分析全部成立，而且由于未平仓量集中在一天了结，效应可能更强。境内零售的期权性需求转到了雪球与结构化产品上，而第 23.12 节的四条安心理由中有三条对雪球不成立。同一反馈机制在境内通过雪球敲入线、月度到期日与股指期货基差运行，事前监测应当关注这三处，而不是期权链。

延伸阅读

这是本书最新的话题，相关文献尚未定型；读者应当预期实证结论已有变化。Cboe 自己关于 0DTE 成交构成的研究简报（2023）是了解“实际交易的是什么、由谁交易”的来源，并且区分了合约张数与风险转移，而多数评论没有作这一区分。关于订单流与交易商头寸：Brogaard、Han 与 Won（2023，2026 年修订）发现 0DTE 交易抬高了标的的波动率，并把这一效应主要归因于投机

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

性的零售交易而不是交易商对冲；Dim、Eraker 与 Vilkov（2024）发现做市商的 0DTE 净 gamma 很小、平均为多头，且其后的交易更平稳而非更剧烈；Beckmeyer、Branger 与 Gayda（2023）记录了零售一侧的情况：谁在买、买哪些执行价、回报如何。这些研究合起来，就是第 23.12 节所说的并不一致的证据；它们在交易商对冲问题上的分歧，小于在“0DTE 交易究竟是否改变波动率”问题上的分歧。Bandi、Fusari 与 Renò（2023）是定价论文：在局部高斯密度上加入随时间变化的偏度与峰度，并以跳跃刻画翼部。关于反馈机制本身，期权对冲与市场冲击的文献比 0DTE 早出现几十年，至今完全适用，Grossman（1988）与布雷迪委员会报告是合适的起点。境内方面，各交易所关于期权合约月份与到期日安排的规则以及投资者适当性管理办法，是理解第 23.15 节所述制度差异的一手依据。

练习题

23.1 解释为什么 0DTE 合约成交量高估了被转移的风险量。

23.2 说明 $T \to 0$ 时平值 gamma 的行为，根据表 23.1 求出 1 小时与 30 天 gamma 之比，并解释为什么 gamma 带的收窄比 gamma 本身的增大更重要。

23.3 一份平值 0DTE 看涨期权的成本是现价的 0.38%。说明到期时回本所需的变动，将其与一个标准差的日变动作比较，并解释为什么它的买卖价差在当日更晚时按百分比计要贵得多。

23.4 定义 charm，解释它为什么对月度期权可忽略而对 0DTE 期权占主导，并用例 23.2 列出区分 charm 对冲与 gamma 对冲的三项性质。

23.5 隔夜时段占日方差的 25%。计算在收盘到收盘波动率为 16% 的市场中 0DTE 期权会显示多少隐含波动率，解释为什么这不是期限结构效应，并说明哪一份合约可以对冲收盘后公布的消息。

23.6 用 $T^{-0.4}$ 规律计算 4 小时期限的微笑比 30 天期限的陡多少，并解释为什么用隐含波动率给一份 15 分钟期权报价比直接报价格传递的信息更少。

23.7 解释为什么例 23.6 的钉住力会饱和，以及一个压住小幅变动却压不住大幅变动的市场为什么可能比两者都压不住更糟。

23.8 某个公布的 gamma 敞口数字假定交易商持有全部看涨期权的多头、全部看跌期权的空头。说明其中哪些是度量出来的、哪些是假设的，并解释该假设在什么情况下最不可靠。

23.9 在没有预定事件的日子里，一份 0DTE 期权显示 13.4% 的隐含波动率。下午 2 点的一则公告带来标准差为 0.8% 的变动。计算上午的隐含波动率，以及下午 2 点刚过、还剩 2 小时时的隐含波动率，并解释为什么这一下降并不是波动率的下降。

23.10 解释为什么零售订单流使交易商空 gamma 而系统化卖权利金使他们多 gamma。某交易商账簿每 1% 净空 8 亿美元的 gamma。计算 1.5% 的变动所需的对冲交易与方向，并解释为什么同一股对冲流相对日成交量微不足道而相对下午 3:55 可得的深度是实质性的。

23.11 列出第 23.12 节给出的四条未出事的理由，指出哪一条是行为性的，并解释为什么每日到期限制了风险的规模而不限制它的速度。

23.12 解释当一次变动把指数带出 gamma 带时交易商的对冲需求会发生什么，以及为什么这是危险的情形。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

23.13 解释为什么境内不存在 0DTE、为什么本章的分析在境内月度到期日当天仍然完全适用，以及境内的投资者适当性要求如何改变了零售期权性需求的形态而不是它的规模。

进阶习题

23.14 第 23.2 节给出 gamma 带的上边界从 +6.76% 收窄到 +0.44%。推导该带边界关于 σ 与 T 的表达式，说明该带为什么在执行价对数上关于略高于现价的一点而不是关于现价对称，验证这三组数字，并确定若隐含波动率翻倍该带会如何变化。讨论这对“0DTE 在高波动率环境下更危险还是更不危险”意味着什么。

23.15 例 23.2 得到指数不动时 10.7 亿美元的对冲平仓。给定未平仓量在各执行价上的分布，推导一本账簿从开盘到收盘前半小时的 charm 流，解释为什么在这段时间里该流在偏离现价约半个日标准差的执行价上最大，而不是在平值处最大，说明平值执行价的那部分对冲流去了哪里，并讨论这对“应当在执行价分布的哪一段寻找最大的可预测对冲流”意味着什么。

23.16 重现例 23.5 的 1 小时两行，然后在第 21.5 节的 Merton 跳跃扩散模型中、把扩散波动率定为 15%，为同样两份看跌期权定价，找出能重现带偏斜价格的跳跃强度与平均跳幅。讨论有多少组参数能做到，以及这对把一个动态模型校准到单一到期日意味着什么。

23.17 第 23.12 节论证这个市场之所以良性主要是因为订单流双向，而这一理由是脆弱的。构造一个由零售买方与系统化卖方两个群体组成、其均衡是稳定的模型，指出会破坏该均衡的参数变化，并说明哪些可观察序列会给出预警。

23.18 第 23.14 节称当变动把指数带出 gamma 带时，本可吸收这次变动的对冲会“在中途就已耗尽”。把它形式化：对一本集中在单一执行价的账簿，把交易商对冲需求写成指数水平的函数，说明它在何处递增、在何处消失，并判断一个能吸收小幅变动却不能吸收大幅变动的机制，是否比两者都不吸收的更糟。

23.19 第 23.13 节论证日度到期是市场完备性的一次真实改进。用第 12.8 节的复制结果把这个论证说精确，再构造“更细的期限会因引致对冲集中而降低福利”的反论，并说明要在两者之间作出裁决必须度量什么。

23.20 把 0DTE 与组合保险（第 40.2 节）、雪球式自动赎回结构（第 35.7 节）、反向波动率产品（第 22.8 节）三起事件沿头寸集中度、机械化对冲、累积性与可观察性四个维度作比较。说明 0DTE 具备哪些特征、不具备哪些，并用该比较论证业界当前的关注水平大致恰当、或者论证它指错了方向。

23.21 第 23.15 节指出境内把零售的期权性需求从最短期限推到了最长期限，并称第 23.12 节的四条安心理由中有三条对雪球不成立。逐条检验这一说法，说明哪一条仍然成立、为什么，并据此论证：从系统性风险的角度看，一个允许零售交易 0DTE 的市场与一个把同样的需求导向雪球的市场，哪一个更审慎。明确说明你的结论依赖于哪些可度量的量。

23.22 第 23.15 节提出，若境内引入日度到期的股指期权，涨跌停板会与集中的 gamma 相互作用。把这个相互作用建模：假设标的在触及停板时停止交易，写出交易商在停板附近的对冲需求，说明当停板在对冲需求耗尽之前触发与之后触发时后果有何不同，并据此给出一条关于停板宽度应当如何与期权到期频率相匹配的政策建议。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！