第 23 章　短期限期权、交易商头寸与市场反馈

前面各章都把期权市场看作转移风险的场所。本章讨论的是当这种转移规模足够大、速度足够快，以至于由此产生的对冲本身成为标的市场中的一股力量时会发生什么。

上一代教科书写作时，这种市场结构还不存在。当天交易、当天到期的期权，即第 10.12 节所说的 0DTE 期权，用不到十年时间从冷门品种成长为占标普 500 期权成交量一半以上的品种。第 10.12 节记录了这一增长，其机制留待本章讨论；第 18.12 节说明了这一机制，即交易商的对冲交易会反过来推动其所在的市场；第 21.12 节则指出，这个市场处于经典随机波动率模型无法生成偏斜的区域。

三种需求汇集在这份合约上：套保者的风险只持续一个交易时段（一次数据发布、一次政策决定），过去却要为此买一个月的保护；零售买方想做杠杆化日内押注；系统化卖方则在最短期限收取第 19.10 节的波动率风险溢价（第 23.13 节）。这些头寸的对冲是稳定还是扰动股指，取决于这些需求如何相互抵消。

本章的结构与其他各章不同，因为它的核心问题目前还没有答案。本章先推演 0DTE 可能破坏市场稳定的机制（第 23.2 至 23.11 节），再权衡证据，迄今证据大体给出的回答是“没有”，并说明为什么这并不令人安心（第 23.12 节），最后讨论什么情况下会酿成事故（第 23.14 节）。

23.1　0DTE 是什么，如何发展起来

当天到期的期权并不新鲜，月度与季度合约也总有到期的那一天。新鲜的是*每一天*都有合约到期。

标普 500 指数期权（SPX：欧式，现金结算，每点 100 美元，周度与日度系列按收盘指数结算）的周度到期日是逐步增加的：先有周五，2016 年加上周三与周一，2022 年加上周二与周四。此后每个交易日都是某批合约的到期日，交易者随时可以建立当日头寸。成交份额随之转移。据 Cboe 的数据，0DTE 合约在 2010 年代中期只占 SPX 期权成交量的个位数百分比，到 2024 年末已过半，2025 年全年接近五分之三。如今成交最活跃的标普 500 期权，是一份到明天就不复存在的合约。这句话里有两点需要区分。

*成交量不是风险转移。*0DTE 合约的 vega 只是月度期权的一小部分，寿命也只有几个小时而不是几周，因此按合约张数衡量这个市场，会高估实际易手的敞口。第 23.12 节还会回到这一点，因为这是相关评论中最常见的错误。

*但成交量就是对冲。*每一份成交的合约都有人对冲；0DTE 合约的对冲集中在几个小时内完成，而不是分摊到几个月里。即使风险本身没有压缩，对冲流也已经压缩；造成市场冲击的正是这种压缩。

23.2 短期限期权为什么表现不同

这个市场的种种反常之处，都源自 $T \to 0$ 时希腊字母的变化。假设标普 500 指数为 5000 点，隐含波动率 15%（正常的平静市场），利率 4%，股息率 1.5%。全章按交易小时计时，每天 6.5 小时，每年 252 天，因为 0DTE 期权依循的正是这个时钟；本章所有数字都按此定价，“30 天”指 30 个交易日，约合 6 周。

表 23.1: 临近到期时的平值看涨期权。最后两列是指数上涨 1% 时每单位指数的 delta 对冲盈亏。

剩余时间	价格	delta	gamma	gamma 项	精确盈亏
30 天	110.47	0.5323	0.001534	1.92	1.89
7 天	51.58	0.5158	0.003188	3.98	3.90
1 天	19.10	0.5060	0.008443	10.55	9.60
4 小时	14.94	0.5047	0.010763	13.45	11.65
1 小时	7.43	0.5024	0.021528	26.91	17.55
15 分钟	3.71	0.5012	0.043056	53.82	21.25

剩 1 小时时的 gamma 是 30 天时的十四倍（表 23.1），而且还在上升：由第 18.3 节的公式一望可知，平值 gamma 以 $1/\sqrt{T}$ 的速度趋于无穷。仅这一个数字就说明了问题的量级。

但更重要的不是 gamma 有多大，而是它集中在多窄的范围内（图 23.1）。表中最后两列说明了这一点。两列都是指数上涨 1% 时的对冲盈亏，一列是泰勒展开中的 gamma 项 $\frac{1}{2}\Gamma\,(0.01\,S)^2$，一列是对期权重新定价得到的精确值；剩 1 小时时，1% 的变动相当于 1 小时标准差的 2.7 倍；指数一离开执行价，gamma 就迅速衰减，到变动结束时只剩平值水平的 3%。精确盈亏沿途累积的是不断变小的 gamma，gamma 项则始终按起点的 gamma 计算，所以精确盈亏比 gamma 项低三分之一；剩 15 分钟时只有它的五分之二。

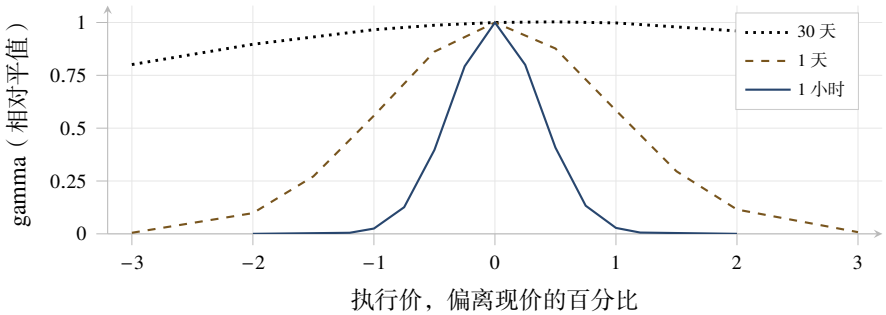


图 23.1: 各执行价上的 gamma，以平值取值归一化。

gamma 超过平值取值一半的执行价范围称为 **gamma 带**。以执行价的对数衡量，该带以略高于现价的一点为中心对称，而非以现价为中心，其边界的收窄情况如下：

距到期	gamma 带边界（现价上方 / 下方）
30 天	+6.76%/−5.52%
1 天	+1.13%/−1.09%
1 小时	+0.44%/−0.43%

这是本章的结构性事实。月度期权账簿在很宽的指数区间内都有 gamma，因此 1% 的变动只会逐渐改变对冲需求。到期前最后 1 小时，0DTE 账簿五分之四的 gamma 集中在现价上下半个百

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

分点之内，几乎全部在一个百分点之内，对冲需求因此是指数位置的阶跃函数。指数移动一个百分点，交易商的全部 gamma 敞口就可能消失、出现或者变号。

23.3　买方的盈亏计算

讨论市场结构之前，先看单笔交易。0DTE 期权的价值几乎全是时间价值，而且只剩几个小时。图 23.2 画出了这几个小时：指数保持不动，期权价值在一天的大部分时间里缓慢流失，到最后一小时则急剧下坠。

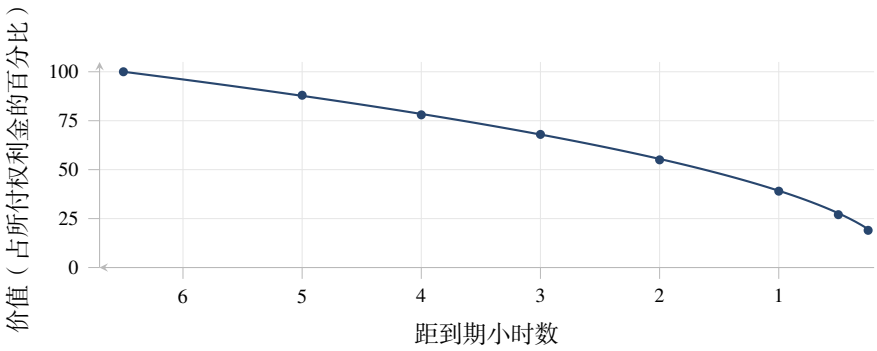


图 23.2: 指数不变时，一份平值 0DTE 看涨期权在盘中的价值。时间自左向右流逝。

例 23.1　买方面对的是什么

指数为 5000 点时，开盘买入一份平值 0DTE 看涨期权，价格 19.10，即**现价的 0.38%**。一个标准差的日变动为 47 点，即 0.94%。

下表给出指数完全不动时该期权在当日的价值，以及在各时点平仓时，买方回本所需的指数涨幅：

剩余时间	价值（指数不动）	占所付权利金	回本所需涨幅
6.5 小时	19.10	100%	—
4 小时	14.94	78%	+0.15%
2 小时	10.53	55%	+0.28%
1 小时	7.43	39%	+0.35%
15 分钟	3.71	19%	+0.38%
到期	0	0%	+0.38%

越早平仓，所需的涨幅越小，因为卖出时期权仍含有时间价值：剩 4 小时平仓时，收回的 19.10 中有 11.47 是时间价值。

日标准差为 0.94%，而持有到期的买方需要指数在当日朝正确方向变动 0.38%，才能仅仅收回本金。这相当于约 0.4 个标准差的门槛，越过之后才谈得上盈利。但这并不是彩票式的不利赌注：该期权定价并无明显错误，其期望收益率为负，主要由第 19.10 节的波动率风险溢价决定。

让人感觉不同的是盈亏的形状。若行情毫无变化，权利金的 61% 在最后一小时之前就已损失，因此这个头寸要么很快押对，要么一文不值。这种产品把对持有人略为不利的期望值，转化为一连串来得快、看得见的全赢或全输；这种设计对人的吸引力远大于缓慢的亏损。第 23.13 节将回到这一点。

还要注意这对买卖价差成本的影响。价格为 19.10 时，一个最小变动价位即一角钱的价差（价格在 3 美元及以上的 SPX 期权最小变动价位为 0.10 美元）占权利金的 0.52%；同一份期权只剩 15 分钟、价格为 3.71 时，同样的一角钱占 2.7%。同一份合约在当日晚些时候交易，按百分比计的成本要高出好几倍，而成交量恰恰在当日较晚时最大。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

23.4 charm：只在这里才重要的希腊字母

第 18.6 节提到过 charm，即 delta 随时间流逝的变化率，但只是一笔带过，因为对月度期权而言它只相当于舍入误差。记 f 为期权价值，则

$$\text{charm} = \frac{\partial \Delta}{\partial t} = \frac{\partial^2 f}{\partial S\, \partial t}$$

其中 t 为已流逝的时间。charm 是与 gamma 配对的交叉导数：gamma 刻画价格变动时对冲如何变化，charm 刻画价格不动、时间流逝时对冲如何变化。它对应 $\Delta S\, \Delta t$ 交叉项；第 18 章的展开式即式 (18.1) 略去了这一项，因为对月度期权而言，仅凭时间流逝，delta 几乎不会漂移。对 0DTE 而言，它引起的对冲流却占主导。

原因可从图 23.1 看出。临近到期时，虚值期权的 delta 必然趋向零，实值期权的 delta 必然趋向一。整个 delta 曲面退化成一个阶跃，而这一退化是时间推移造成的，不是价格变动造成的。图 23.3 以单份合约展示了这一退化：指数从开盘到收盘纹丝不动，执行价略高于现价的看涨期权的 delta 却一路下滑；曲线上的每一点下降，都对应某个人必须完成的一笔对冲交易。

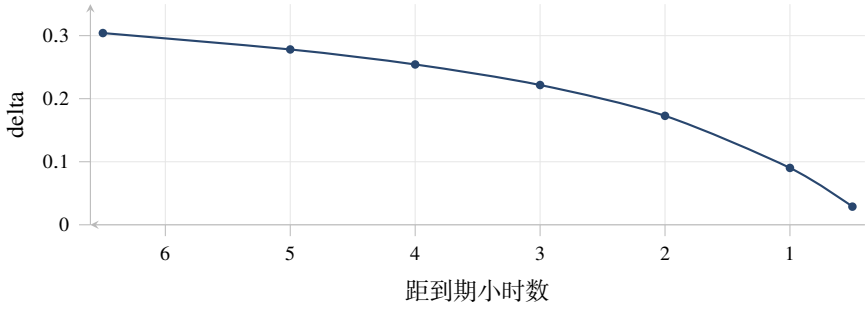


图 23.3: 执行价高于现价 0.5% 的看涨期权的 delta，指数全天不变。时间自左向右流逝。

例 23.2 指数未动，对冲却达十亿美元

考虑一份执行价高于现价 0.5%（约半个日标准差）的看涨期权，这是 0DTE 交易中常见的执行价。指数全天停在 5000 点：

剩余时间	delta	charm（每小时）
6.5 小时	0.3041	−0.0146
4 小时	0.2543	−0.0274
2 小时	0.1728	−0.0614
1 小时	0.0902	−0.1099
0.5 小时	0.0288	−0.1254

某交易商做空 10,000 张此类合约（指数乘数 100），开盘时以 304,095 个指数单位的多头对冲（15.2 亿美元），剩 1 小时时对冲降至 90,164 个单位，即 4.51 亿美元。指数根本没有动，该交易商却必须在最后一小时之前卖出约 10.7 亿美元的指数。这股对冲流有三项性质，使它有别于第 18.12 节的 gamma 对冲。

*它是单向的。*gamma 对冲在上涨时买、下跌时卖，一涨一跌之间相互抵消。charm 对冲则整天朝同一个方向进行，方向由时钟决定。

*它是可预测的。*只要知道未平仓量在各执行价上的分布，任何人都能事先算出它，因为唯一的输入是时间的流逝。

*而且它在加速。*charm 的绝对值从每小时 0.015 升至 0.125（八倍以上），因此这股对冲流在最后一小时

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

最快；此时 0DTE 成交量最大，其他收盘交易也在争夺同一批交易对手。

这股对冲流起稳定还是扰动作用，取决于交易商头寸的符号，这是第 23.7 节的内容。毫无疑问的是：如今在美国股市交易时段的最后一小时里，存在一股规模巨大、可以预测、由时钟决定的对冲流，而十年前它的规模还只是如今的零头。

23.5　隔夜跳空不在这份合约里

把 0DTE 的隐含波动率与任何其他量作比较时，都潜藏着一个不易察觉的度量问题；由此造成的差异很容易被误读。开盘时买入的 0DTE 期权在收盘时到期。它覆盖的是这一交易时段，而不是隔夜，报价时却以整整一个交易日作为距到期时间。若隔夜时段（收盘至次日开盘）承担日方差的比例为 ω，则交易时段承担 $1-\omega$，能复现该期权价格的隐含波动率为

$$\sigma_{\text{时段}} = \sigma_{\text{日}}\sqrt{1-\omega}$$

其中 $\sigma_{\text{日}}$ 是收盘到收盘收益率的年化波动率，即 30 天隐含波动率所度量的量。

隔夜占比 ω	显示出的隐含波动率	相对 15% 的收盘到收盘波动率
0%	15.00%	—
10%	14.23%	−5.1%
20%	13.42%	−10.6%
30%	12.55%	−16.3%
40%	11.62%	−22.5%

美国股指的多数消息在交易时段内发布，ω 通常在 15% 到 25% 之间，因此按本章所用的交易日时钟，0DTE 隐含波动率比 30 天隐含波动率低约十分之一，这纯属计时约定所致。（按日历分钟计算距到期时间的系统会犯相反的错误，显示出的 0DTE 波动率远高于收盘到收盘波动率。）Cboe 于 2023 年 4 月推出的一日波动率指数 VIX1D 公布的正是这种仅覆盖交易时段的波动率，拿它与 30 天期的 VIX 比较时，同样需要作上述调整。

这一现象可能被误读为短期限期权便宜的证据。其实它们并不便宜，只是度量窗口比所报的期限短。第 19.6 节的期限结构是真实现象，但这一效应不属于它；把两者混为一谈，会得到一条在短期限端出现虚假拐点的期限结构。

这一效应还有一个比上述误读更重要的实际含义：0DTE 期权对冲不了隔夜跳空，因为跳空发生在它到期之后。用日度期权对冲事件风险的机构，必须持有在该事件之后到期的合约；对收盘后公布的消息而言，这意味着持有明天而不是今天到期的合约。

23.6　零期限处的微笑

第 21.12 节指出本章讨论的市场完全处于经典随机波动率模型无法生成偏斜的区域；第 21.7 节则给出了经验规律：平值偏斜随期限缩短按 $T^{-0.4}$ 增长，这是在约 1 个月到数年的范围内测得的。它在 1 个月以下是否继续成立尚有争议；粗糙波动率（第 21.8 节）认为成立。外推到这个市场，得到的数字十分惊人。

期限	偏斜相对 30 天	每 1% 价值状态的波动率点数
30 天	1.00	2.5
7 天	1.79	4.5
1 天	3.90	9.7
1 小时	8.24	20.6

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

期限为1天的微笑，陡峭程度约为30天期的四倍，到期前1小时则为八倍。这些倍数来自上述规律；30天期每1% 2.5个点的水平则是一个程式化的基准，是表19.3曲面1个月期斜率（每1%约0.4个点）的数倍，下文的各个斜率都随它同比例缩放。斜率为负，因此陡峭体现在看跌期权上：低于现价1%的看跌期权，其隐含波动率可比平值水平高出二十个点。同一斜率不能反过来套用到相同距离的看涨期权上（比15%的平值波动率低二十个点，已不成其为波动率），因此看涨翼部变得平坦并向上翘起；这一期限上的微笑由陡峭的看跌翼部和平缓而凸的看涨翼部组成。图23.4把四个期限画在同一坐标系中：从1个月到1小时，看跌翼部从一道缓坡变得近乎垂直，而看涨翼部只移动了几个点。

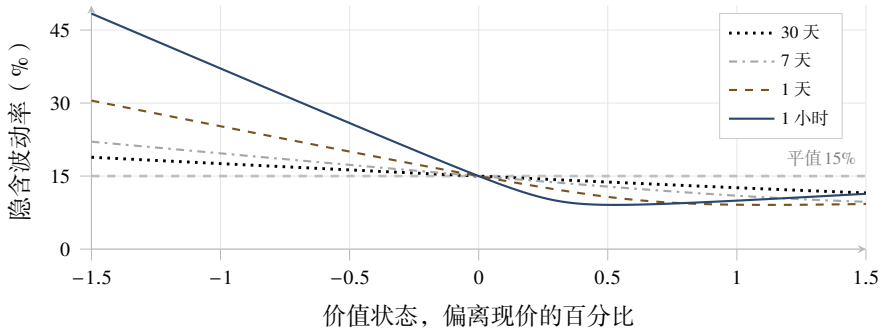


图23.4: 四个期限的隐含波动率随价值状态的变化。示意图：平值斜率遵循上表的$T^{-0.4}$规律（1个月以下为外推），平值水平固定在15%，各期限用同一条程式化的翼部形状。

由此产生三个后果，其中第三个对市场结构最为重要。

*布莱克–斯科尔斯隐含波动率成了一个糟糕的坐标。*第15.7节与第19.12节把隐含波动率描述为一种报价语言。在这样短的期限下，这种语言会失真：价格上很小的差异对应隐含波动率上巨大的差异，用波动率报价传递的信息反而比直接报价格更少。

*只有含跳跃、粗糙性或极快均值回复的模型才能拟合它。*例21.3表明跳跃能产生这种形状的微笑：跨执行价的波动率范围在1个月期时为12.7个波动率点，1年期时为1.5个点，且几乎全部集中在看跌翼部；第21.8节表明粗糙波动率直接给出−0.4这一幂次。无论0DTE微笑由什么生成，都不是波动率平滑变化的经典扩散过程。这是支持这一论断最直接的证据：在如此短的期限内，这样的路径走不远，不足以让虚值期权具有任何价值，因此需要跳跃、极其粗糙的波动率，或者回复速度快到足以起到同样作用的因子（第21.8节）。

*而最陡之处正是零售订单流集中之处。*日内买保护或押注下跌的买家自然会买虚值看跌期权，而这些执行价上的隐含波动率恰恰最极端。支付二十个点偏斜的买家并非在做一笔明显糟糕的交易，因为这种陡峭反映了真实的向下跳跃概率；但他买的是曲面上最贵的部分，而“贵”是以市场自身的单位衡量的。相同距离上的看涨期权买家则处在曲面便宜的一侧，所付的波动率低于平值水平。

23.7 交易商头寸与反馈环

第18.12节确立了这一机制，其来源是式(18.1)中的gamma项：变动ΔS使交易商的delta改变$\Gamma\Delta S$；交易商空gamma时，重新对冲要顺着变动交易，放大变动；多gamma时则逆着变动交易，抑制变动。要把这一机制用到0DTE上，需要知道交易商处在哪一边；在这一点上，市场结构比任何模型都重要。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

零售买期权。第 10.12 节所描述的零售订单流以支付权利金为主，即直接买入看涨和看跌期权。作为这股订单流的对手方，交易商持有期权空头、空 gamma，反馈起放大作用。

但机构卖期权。0DTE 成交量中有很大且仍在增长的一部分来自系统化的卖权利金策略：一些基金在可得的最短期限收取第 19.10 节的溢价，卖出看跌价差、看涨价差与铁鹰式（第 12.3 节：同时卖出现价下方的看跌价差与上方的看涨价差）。作为这股订单流的对手方，交易商持有期权多头、多 gamma，反馈起抑制作用。

两者大致抵消，净额很小且会变号。这是这个市场最重要、也最常被忽略的经验事实。关于 0DTE 订单流的研究（其中包括 Dim、Eraker 与 Vilkov，见延伸阅读）普遍发现，订单流接近**双向**：客户从交易商处买入与卖给交易商的期权数量大致相当。因此，交易商的净头寸是两股很大的订单流之差，0DTE 合约带来的交易商净 gamma 只占长期限头寸所产生 gamma 的一小部分。

例 23.3　对冲流有多大

交易台用指数变动 1% 后为重新对冲所必须交易的指数名义金额来表示 gamma。指数变动 1% 使一份期权的 delta 改变 $0.01\,S\Gamma$ 个指数单位，因此 n 张合约、乘数为 m 的头寸需要交易

$$\text{每 1\% 的对冲名义金额} = 0.01\,n\,m\,\Gamma S^2$$

的指数，才能恢复对冲。这与表 23.1 中的 gamma 项不是同一个数：后者是同一变动带来的盈亏，每单位为 $\frac{1}{2}\Gamma S^2 \times 0.01^2$；两者描述的是同一个 gamma，一个以交易量表示，一个以盈亏表示。

假设交易商整体的 0DTE 头寸净空 gamma，规模为每 1% 5 亿美元。由表 23.1 可知，这大约相当于到期前 1 小时 930 张平值合约的 gamma（每张 $0.01 \times 100 \times 0.021528 \times 5000^2 = 538{,}200$ 美元，其中 100 为乘数 m），或 30 天期时的 13,000 张。由于空 gamma，指数下跌时交易商的 delta 增加，上涨时减少，因此他们必须在下跌时卖出期货、在上涨时买入；一阶近似下（假定 gamma 不变），金额为每 1% 5 亿美元：

指数变动	交易商必须卖出（跌）或买入（涨）的指数期货
0.5%	2.5 亿美元
1.0%	5.0 亿美元
2.0%	10.0 亿美元
3.0%	15.0 亿美元

每一笔交易都与引发它的变动同向，因此这股对冲流起放大作用。这一期限内 gamma 并不保持不变（第 23.10 节）：对 1 小时的账簿，实际数字在 0.5% 变动时约为 1.9 亿美元，超过 1% 后停在约 2.3 亿美元，即账簿的全部 delta；对 30 天的账簿，上表的数字相当接近实际。

标普期货每天的名义成交量达数千亿美元，相比之下，这些金额在总量上很小。十亿美元的股指期货，正常情况下几分钟就能成交。

但到纽约时间下午 3:55，它们就不小了。charm 与 gamma 共同把这股对冲流集中到最后一小时，而且在这段时间里方向可能完全一致。收盘是期货一天中最繁忙的时段，但此刻必须卖出的交易商面对的不是全天成交量，而是那一刻其他参与者愿意按最优买价买入的数量，即几百张 E-mini 标普 500 期货合约（每张为指数的 50 倍，指数 5000 点时约 25 万美元），相当于几千万到约一亿美元。应当与之比较的是这个数量，而不是日成交量；按这个尺度，几亿美元全部集中在同一方向，就是实质性的规模。

23.8　日内的跳跃

第 21.5 节指出跳跃会在不同标的之间聚集（使一只股票跳空的事件往往也使其他股票跳空），并把日内层面留给了本章。对 0DTE 而言，这种聚集背后的预定事件不是次要细节，而是主导因素。

交易时段内的波动率分布并不均匀，而是集中在开盘、预定的数据发布、政策公告以及收盘

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

前。对月度期权而言，这些会在平均中抵消；对寿命只有六小时的期权则不会。因此，0DTE 隐含波动率不是一个数字，而是一份时间表，而且这份时间表是公开的。

例 23.4　下午两点的公告如何影响上午的期权

沿用第 23.5 节的设定：收盘到收盘波动率 15%，其中 20% 的方差落在隔夜，因此普通交易时段的标准差为 0.845%，0DTE 期权显示的隐含波动率为 13.4%。

为简便起见，假设普通方差在交易时段内均匀分布。现在加入一则预定公告，其变动的标准差为 s_e。方差可以相加，因此时段标准差变为 $\sqrt{0.845\%^2 + s_e^2}$；最后一列是隐含波动率相对无事件时 13.4% 的倍数：

事件幅度（标准差）	时段标准差	显示的隐含波动率	倍数
无	0.845%	13.4%	—
0.50%	0.982%	15.6%	1.16
0.75%	1.130%	17.9%	1.34
1.00%	1.309%	20.8%	1.55
1.50%	1.722%	27.3%	2.04

仅一则变动标准差为 1% 的预定事件，就使当天上午的 0DTE 隐含波动率上升一半以上。市场的普通波动率没有任何变化，只是度量窗口里加进了未来已知的一分钟。

更剧烈的效应出现在这一分钟过去之后。比较同一份期权在下午 1:59 与 2:01 的情况：剩余 2 小时，指数不变，事件取上表中 1.00% 一行：

	剩余标准差	年化
公告之前	1.104%	31.6%
公告之后	0.469%	13.4%

两分钟内，隐含波动率降至原来的 1/2.36。事件方差只是移出了度量窗口。由此可得三点。

*这不是波动率崩塌，而是日历效应。*对公告本身没有看法、在 1:59 买入并在 2:01 卖出的交易者，是买入了事件、卖出了余波，这笔交易逻辑自洽。在 1:59 买入、指望从波动率上升中获利的交易者，则误解了这种产品。

*它还使恒定波动率假设失效，而且并非建模上的细枝末节。*第 15.1 节把恒定波动率列为布莱克–斯科尔斯假设之一，第 21 章放松了这一假设。在这样短的期限内，问题不在于波动率是随机的，而在于波动率是预先排定的，而且人人手里都有这张日程表。交易台依据一份事件权重日历而不是单一数字为 0DTE 定价，这与第 21 章的任何模型都属于不同类型；第 23.9 节将加以介绍。

*最后，第 21.5 节归因于跳跃的聚集现象，在这里可以直接看到。*使一个指数跳空的事件，与使其他指数跳空的是同一批事件（经济数据、政策、地缘政治），因此日内跳跃风险恰恰在最大的时候跨标的相关。同时做空多个指数 0DTE 虚值期权的账簿并没有分散风险，实际上只是一个头寸。

23.9　为一份 0DTE 期权定价

到目前为止的所有数字都来自布莱克–斯科尔斯–默顿公式，波动率取 15%，按交易小时计时；对希腊字母而言，这是合适的工具，因为 gamma、charm 与衰减的形状不依赖于细节。但读者此时会有两个公式回答不了的问题：实际交易的是哪些期权？如果常数波动率不成立，交易台用的是什么？

交易的是哪些执行价。 大多不是平值的。Cboe 自己对 2023 年成交量的统计，与延伸阅读中列出的学术样本，在分布形状上一致。典型的合约位于平值附近的虚值一侧（距现价约四分之一到一个百分点，delta 在 0.10 到 0.35 之间）；看跌与看涨期权的合约数大致相当，但看跌期权离现价更远。在平静的日子里，距现价一到两个百分点的深度虚值期权占了许多合约张数，却只占很少的权利金，因为每张至多几美元，到下午只值几美分；按权利金而不是合约张数计，市场的重心更靠

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

近平值。这一分布还随日内时间而变化：上午交易的执行价大约覆盖现价上下各一个百分点，到最后一小时则几乎全部落在现价上下约半个百分点之内，即图 23.1 中 1 小时的 gamma 带，因为只有那里还剩时间价值。实值期权成交很少。根据看跌–看涨平价关系，实值看涨期权等于同一执行价的虚值看跌期权加上一个远期多头：它的时间价值就是该看跌期权的时间价值，其余部分是按期权较宽的买卖价差买入的指数敞口。这一时间价值在盘中不断流失：实值半个百分点的看涨期权在开盘时约有 15 个点的时间价值，收盘前一小时约 4 个点，剩 15 分钟时约 1 个点（按第 23.6 节的偏斜波动率计）。想要指数敞口的交易者会买期货，想要期权的交易者则买虚值的一方。零售订单流大多是单端的：直接买入一份看涨或看跌期权，当日建仓，也常在当日平仓。机构订单流大多是价差：现价下方半个到一个百分点的看跌价差、上方相同距离的看涨价差，或两者组合成的铁鹰式，持有到期。第 23.13 节将介绍这些交易者是谁；这里的要点是，市场的定价问题集中在平值附近一条很窄的执行价带上，以及紧贴其下方的一段陡峭的看跌翼部。

为什么一个波动率不够用。 布莱克–斯科尔斯–默顿模型有三条假设，对月度期权尚可接受，到了这个期限却同时失效。其一，波动率为常数，因而方差随时钟均匀累积；但第 23.5 节表明一天方差的五分之一落在合约不覆盖的时段，例 23.4 表明预定的一分钟所含的方差是下午其余时间的数倍。其二，价格路径连续，因而几个标准差以外的执行价几乎一文不值；但期限为 1 小时时，低于现价 1% 的执行价位于 2.7 个标准差之外，而第 23.6 节表明市场给它的定价仿佛这一距离要小得多，因为一次跳跃就能瞬间跨越。其三，对冲连续且无成本，因而价格就是复制成本；但表 23.1 中的 gamma 是月度期权的十四倍，例 23.1 中一角钱的买卖价差占权利金的 2.7%，因此复制成本既不小，也无法明确界定。例 23.5 展示了由此产生的误差有多大。

例 23.5　收盘前 1 小时，平坦波动率错在哪里

在本章的设定下（指数 5000 点，利率 4%，股息率 1.5%），为执行价低于现价的看跌期权定价：先用平坦的 15% 波动率，再用第 23.6 节的平值斜率线性外推给出的该执行价波动率，即在 15% 的基础上，30 天期时每 1% 价值状态加 2.5 个点，1 小时期时每 1% 加 20.6 个点。

剩余时间	执行价	平坦 15%	带偏斜	比率
30 天	低于现价 0.5%	83.99	92.45（16.2%）	1.1
30 天	低于现价 1.0%	73.30	89.90（17.5%）	1.2
1 小时	低于现价 0.5%	0.75	3.72（25.3%）	5.0
1 小时	低于现价 1.0%	0.02	2.75（35.6%）	148

剩余 30 天时，平坦模型的价格大致正确，微笑只是对它作百分之十到二十的修正。剩余 1 小时时，微笑就是价格本身。平坦模型给低于现价 1% 的看跌期权定价两美分，因为在每小时标准差 0.37% 的连续路径下，指数几乎到不了那里；市场给它的定价约为 2.75，是前者的一百多倍，因为一次跳跃就能到达。用平值波动率为这份看跌期权定价的交易台，会以最小变动价位报出它，并把它当作一文不值的头寸来对冲。

交易台改用什么。 没有单一的替代模型，实务做法更接近第 19 章而不是第 21 章：曲面本身就是模型，其余部件都围绕它搭建。

第一个部件是时钟。距到期时间不按分钟计，而按剩余的期望方差计：一条开盘和收盘前方差较大、午间较小的日内分布，再加上当日各项预定事件的权重。这就是**业务时间**；布莱克–斯科尔斯–默顿公式照常使用，只是把 $\sigma^2 T$ 换成这一方差预算。例 23.4 中的期权在公告前后、其他条件不变的两分钟里失去一半以上的隐含波动率，原因也在于此：是方差预算已经用掉，而不是波动率作了修正。

第二个部件是远期价格，取自 E-mini 期货（头寸将用它对冲），或者像第 22.6 节构造 VIX 那

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

样，由期权链内部的看跌–看涨平价关系推出。微笑相对于这一远期而不是现货指数报价。

第三个部件是微笑本身：对每个到期日，以第 19.1 节的标准化价值状态为坐标拟合微笑，

$$\frac{\ln(K/F)}{\sigma\sqrt{T}}$$

（即执行价距远期几个标准差，σ 为平值隐含波动率，T 为剩余业务时间）。拟合采用少参数、在构造上即无套利的形式（常用第 19.5 节的 SVI 参数化），并在日内重新拟合。在原始价值状态坐标中，微笑随到期临近而急剧变陡；在标准化坐标中，这一陡化大部分消失，剩下的是一个与 $T^{0.1}$ 成比例的斜率（即 $T^{-0.4}$ 乘以标准化时除去的 $\sqrt{T}$），这才是拟合必须容纳的残差。对跳跃的看法通过翼部体现：如果交易台预期某一事件的影响会大于日程权重所隐含的程度，就会直接抬高看跌翼部，而不是去调整动态模型中的某个参数。第 21 章的模型在交易台之外使用，用于检验拟合出的曲面能否由某个过程生成：跳跃给出第 21.7 节所见、比市场更陡的短端偏斜，粗糙波动率给出市场所呈现的 $T^{-0.4}$。但报价并不由它们决定。

最后一个部件是库存。围绕拟合中间价的价差与偏斜调整，由交易商自身的头寸和客户的订单决定：各执行价的报价按抵消账簿 gamma 与 charm 敞口的方向调整，在收盘前加宽，并随订单流变动。模型提供的是对冲比率，使上述做法得以运作；对交易活跃的 0DTE 执行价而言，这就是模型的全部职责。价格由市场上已有的买卖报价决定，而不是由某个人的公式决定。

23.10 每天都有的钉住

第 10.9 节讨论月度到期日的钉住风险时，引入了**钉住**效应：标的价格被拉向未平仓量大的执行价，因为对冲多头 gamma 头寸的交易商会在该执行价附近逢涨卖出、逢跌买入。有了日度到期，这一机制如今在每个交易时段都在运行。例 23.6 计算这种回复力的大小，因为它远大于按月度期权的直觉所估计的；图 23.5 把它画了出来。

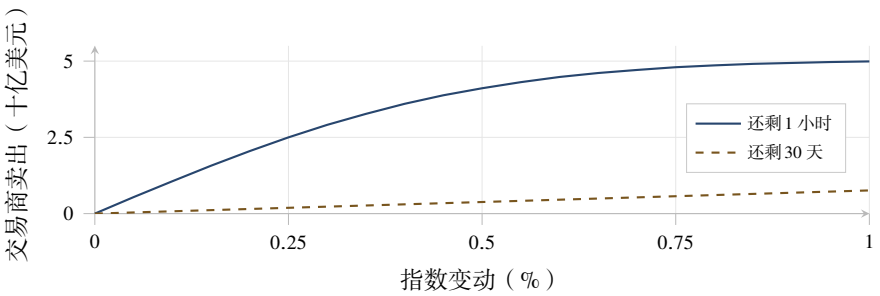


图 23.5: 平值看涨期权多头 20,000 张时，交易商卖出量与指数变动的关系。

例 23.6 还剩 1 小时时的回复力

交易商持有同一执行价的 20,000 张看涨合约多头，指数恰好位于该执行价，距到期还剩 1 小时。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

指数变动	delta 从…到	交易商卖出
+0.10%	0.502 → 0.609	10.63 亿美元
+0.25%	0.502 → 0.752	24.99 亿美元
+0.50%	0.502 → 0.912	41.14 亿美元
+1.00%	0.502 → 0.996	49.90 亿美元

同一账簿若还剩 30 天，0.5% 的变动对应卖出 3.82 亿美元，1% 的变动对应卖出 7.60 亿美元，即图 23.5 中的直线：变动翻倍，卖出量也翻倍。剩 1 小时的曲线显然不是这样，其数字有两项重要特征，而且方向相反。

*小幅变动遇到极大的回复力。*指数变动十分之一个百分点，就带来十亿美元起稳定作用的卖盘。这是真正的钉住：正因如此，指数常在未平仓量大的执行价附近窄幅波动。

*但这种力会饱和。*变动达到 1% 时 delta 已升至 0.996，再没有可卖的了：前半个百分点的变动带来 41.14 亿美元的对冲，后半个百分点只带来 8.76 亿美元。这个稳定器对本不需要稳定的变动作用最强，对真正需要稳定的变动却不起作用。

这种不对称，是第 23.14 节那项担忧中有根据的部分。一个能压住小波动却压不住大波动的市场，不仅在危机中帮不上忙，还会使危机显得更加出人意料，因为本应发出压力积累信号的小幅变动已经被抹平了。

23.11　如何度量交易商 gamma，以及这一数值为何不可靠

第 23.7 节的全部分析都取决于交易商净 gamma 的符号，而这个量无法观察。标准做法（第 18.12 节的案例已经介绍）是取每一份挂牌合约 i（某一执行价上的看涨或看跌期权）的未平仓量 OI_i，算出其 gamma Γ_i，再为交易商指定一方：多头 $s_i = +1$，空头 $s_i = -1$。通常的规则假定交易商持有全部看涨期权未平仓量的多头、全部看跌期权未平仓量的空头。按 SqueezeMetrics（2017）最早给出的形式，公布的“gamma 敞口”就是 $\sum_i s_i \,\mathrm{OI}_i \, m \, \Gamma_i \, S^2 \times 0.01$（$m$ 为合约乘数，SPX 为 100），即带假定符号的、例 23.3 中的每 1% 对冲名义金额（即第 18.7 节以美元计的 gamma）；“翻转水平”则是它变号时的指数水平。

问题在于，这个符号是人为设定的，而不是度量出来的。商业版本根据成交数据推断交易商站在哪一方，而不是直接假定，这缩小了问题，却没有消除它；例 23.7 表明答案在多大程度上由这一假定决定。

例 23.7　假设决定答案

假设同一执行价上有未平仓的看涨与看跌合约各 100,000 张，每张 gamma 相同，并假定交易商是每张合约的一方。设交易商以多头持有的看涨合约比例为 w_c（其余为空头），以空头持有的看跌合约比例为 w_p（其余为多头），则标准规则就是 $w_c = w_p = 100\%$。交易商净 gamma 于是为 200,000 $(w_c - w_p)$ 张合约的 gamma。

假设的比例（看涨多头 / 看跌空头）	交易商净 gamma（千张合约）
100% / 0%	+200
80% / 20%	+120
60% / 40%	+40
50% / 50%	0
40% / 60%	−40
100% / 100%	0

符号在 60/40 与 40/60 两种假设之间翻转，而公开数据无法判断哪一种正确。最后一行就是标准规则本身：在看涨与看跌未平仓量相等时，它恰好给出零，因此在这里，公布的数字会是零。这并不是因为交易商头寸为零，而是因为该假设是对称的。未平仓量记录的是合约的存在，而不记录谁处在哪一方。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

因此，公布的 gamma 敞口水平应当理解为一次“若假设的比例成立，交易商头寸会是多少”的计算，不宜像人们通常那样看重。具体而言：

该假设恰恰在最关键的地方最不可靠。在由备兑开仓（投资者对所持股票卖出看涨期权）和机构买入看跌期权主导的市场中，它大致成立。但第 23.7 节论证过，0DTE 订单流接近双向，而这正是这一朴素比例离真实情况最远的情形。

翻转水平也继承了这一误差。公布的“gamma 翻转”所在的指数水平取决于假设的符号，因此假设不同的两位分析者会从完全相同的数据得出不同的翻转水平。

这些都不意味着这个概念没有用处。交易商 gamma 是真实存在的量，第 18.12 节与第 23.10 节都以它为基础；只是公布的估计精确度量了未平仓量，头寸却是按假设度量的。

23.12 0DTE 是放大还是抑制？

这是市场关心的问题，而现有证据并不一致，样本期也很短。

放大的理由。 第 23.7 节的机制真实存在。gamma 巨大且集中在一条窄带内，因此对冲需求是指数水平的阶跃函数。charm 在临近收盘时产生一股巨大的单向对冲流。头寸高度集中、对冲机械，1987 年（第 40.2 节）、2018 年 2 月（第 22.8 节）以及第 35.7 节的雪球敲入，都出自这种模式。

抑制的理由。 短期限期权的卖方总体上是在向市场提供 gamma。多 gamma 的交易商在上涨时卖出、下跌时买入，起稳定作用。若系统化的卖权利金订单流占主导，0DTE 会使日内市场的波动减小，而不是增大。

数据显示什么。标普 500 的已实现日内波动率并没有随 0DTE 的增长而上升（Dim、Eraker 与 Vilkov 2024）。迄今没有任何一次大幅变动能被令人信服地归因于 0DTE 对冲，尽管自 0DTE 成为这个市场最大的组成部分以来，市场已经历两次压力考验：2024 年 8 月 5 日，以及 2025 年 4 月关税引发的抛售（VIX 收盘超过 50）。对这两次事件的分析（其中包括 BIS 对 8 月 5 日的分析）都把行情归因于消息本身和杠杆头寸的平仓，8 月 5 日还归因于开盘前过宽的期权报价推高了 VIX 本身，而不是 0DTE 对冲。可归因于 0DTE 的交易商净 gamma 总量，与长期限账簿相比看来也很小。与此相反，Brogaard、Han 与 Won 发现波动率有所上升，并归因于投机性的零售交易而不是交易商对冲。

因此，恰当的概括是：机制存在，但尚未造成事故。原因主要有四条。订单流是双向的，这是主要原因，也是最脆弱的一条。到期本身就是天然的止损，因为到了明天头寸已不复存在。保证金每日收取，且头寸经过集中清算：2018 年的事故发生在交易所交易票据 XIV 上，其招募说明书允许提前终止（第 22.8 节），而挂牌期权头寸由第 2 章所述的清算所收取保证金，且头寸到期即自行了结。标的是世界上流动性最好的股票市场。后三条是结构性的而非行为性的，按第 22.5 节案例的论证，这类理由更为可靠。对这一概括应当保持谨慎。

这种稳定性是订单流的性质，而不是工具的性质。没有机制保证 0DTE 订单流会一直保持双向。它之所以双向，是因为两个群体恰好对同一期限有相反的需求，而任一方都可能退出。

头寸不会累积，这一点确实令人安心。0DTE 账簿在收盘时就清零了。相比之下，第 22.8 节反向产品的空头头寸是逐日延续、持有多年的，第 35 章雪球账簿的敲入敞口则随市场数月下跌而增长。0DTE 制造的任何风险，都在一个交易时段内产生并消失，这为风险的规模设定了硬性上限。

但这一上限限制的是规模，而不是速度。每日重置的结构不会酿成慢慢积累的灾难，却仍然可能造成剧烈动荡的一小时。真正能检验这个市场的事件（一次大跳空，恰好在临近收盘、交易商空 gamma 时到来）很少发生。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

案例 23.1　同一机制在流动性不足市场中的表现

第 23.12 节的论证在很大程度上依赖标普 500 的深度。去掉这一条件后，完全相同的机制会怎样运行，值得一看；美国证券交易委员会工作人员 2021 年的报告详细记录了这个案例。

2021 年 1 月，零售投资者大量买入一只被大量做空的美国小市值股票的看涨期权，其中许多是短期限、深度虚值的合约。卖出这些看涨期权的交易商处于空 gamma，第 23.7 节的计算完全适用：股价上涨时，他们的 delta 增大，必须买入股票以维持对冲。

除了一个数字，其余都与指数情形相同。标普 500 能在几分钟内吸收十亿美元的对冲；而一只自由流通股本很小、且其中很大一部分已借给空头的股票，根本吸收不了相应的量。对冲需求相对于实际可得的股份很大，于是推高了股价，股价上涨又增大了对冲需求，需求再次推高股价。人们通常把这一事件归结为参与者的动机问题，因此有三点需要区分。

*交易商不是在投机。*他们是在对冲自己卖出的头寸，用的正是本书自第 18 章以来描述的机制。对冲推动被对冲对象的价格，并不是一种策略，而是 delta 对冲在容量过小的市场中的结构性特征。

*卖空余额（已卖空、尚未买回的股数）与期权同样重要。*空头回补也是买入，两股买盘相互强化。把整个变动都归因于期权对冲，会高估一个真实但并非唯一的机制。这与第 23.12 节对 0DTE 的告诫相同。

*真正的约束是自由流通量，而不是杠杆。*这些期权的杠杆并不异常，异常的是标的太小；正是这个变量决定了第 23.7 节的反馈只是一桩奇闻，还是会酿成事件。

因此，这个案例的教训并不是 0DTE 是安全的，而是：机制已有定论，最终如何取决于对冲需求与可得流动性之比；这一比值对标普 500 很小，对小市值股票则不然。问 0DTE 是否危险，实际上是在问这一比值是否会改变；第 23.14 节列出的正是它可能改变的途径。

23.13　谁在交易 0DTE，为什么

零售方向性交易者把 0DTE 期权当作带杠杆的日内押注来买。例 23.1 给出了其中的经济逻辑：略为负值的期望收益率，以一连串迅速的全赢或全输的形式体现出来。

系统化的权利金卖方卖出 0DTE 价差，在最短期限收取波动率风险溢价：那里的年化溢价看起来最大，更关键的是，头寸不可能被拖入跨日回撤。卖出数小时后到期、风险有限的价差，与卖出月度跨式承担的确实是不同的风险，而差别不只在期限：损失有上限，而且头寸不可能在最糟糕的时刻之后继续持有。

机构套保者围绕交易时段内的特定事件（一次数据发布、一项政策决定）战术性地使用 0DTE，对收盘后公布的消息则买入次日到期的合约：这些风险确实只持续一天，为一个月的保护付费是浪费。这是最少被提及、却可能是规模最大的合理用途，也是对市场完备性的直接改进：只持续一天的风险，如今可以用只持续一天的工具来对冲。

交易商与做市商居间撮合，其头寸就是第 23.7 节所述的传导机制。

产品本身无所谓好坏：把第 12.8 节的复制论证从执行价维度移到到期日维度，结论是更细密的期限集合严格扩大了可实现收益结构的空间。新出现的是它引发的对冲集中，这一点应当另行评估。

23.14　什么情况下会酿成事故

有用的问法不是“0DTE 危险吗”，而是“什么条件会使它危险”，因为后者可事先核查。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

*单向的订单流。*若系统化卖方退出（因为季度业绩不佳、资本要求或基金授权变更），零售买入就会使交易商全部处于空 gamma。

*跳空撞上集中的 gamma。*危险的情形是大幅变动出现在最后一小时：此时图 23.1 中的 gamma 带最窄，例 23.2 中的 charm 流最快。这时 1% 的变动就能把指数带出这条带，本可吸收这次变动的对冲在中途就已耗尽，例 23.6 已说明这一点。

*需要时却没有流动性。*例 23.3 中的所有数字，相对于平均成交量都很小，相对于快速市场中可得的深度却都很大。真正起作用的机制，就是第 2.9 节讨论保证金顺周期性时指出的：在快速市场中，本应提供流动性的参与者，恰恰是突然需要流动性的那批人。短期限对冲也在向流动性较差的市场延伸：自 2026 年 1 月起，市值超过 7,000 亿美元的股票也增加了周一与周三到期（第 10.2 节），这更接近第 23.12 节案例的情形，而不是股指的情形。

*这些都不是预测。*这是一份观察清单，清单上的量（现价附近的未平仓量分布、成交量中卖权利金的占比，以及按执行价估计的交易商 gamma，须按第 23.11 节的告诫解读）都已公布或可以计算。这项风险并不隐蔽；与第 22.8、35.7 与 40.2 节的那些事件不同，这一次业界在风险尚小时就已关注它。

23.15 中国市场的若干差异

本章描述的市场结构在境内并不存在，原因是制度性的，可以说清楚。更有意思的是，同样的反馈机制在境内确实存在，只是借助完全不同的产品起作用。

境内没有 0DTE：原因在于到期日设计

第 10.13 节记录了境内期权的合约月份：ETF 期权挂当月、下月及随后两个季月，股指期权与商品期权的月份更多，但同样按月到期。ETF 期权的到期日为到期月份的第四个星期三，股指期权为第三个星期五。因此境内每个品种每个月只有一个到期日（沪深 300 与上证 50 也只有 ETF 期权与股指期权两个到期日），而不是每天一个。

仅这一点就消除了本章的全部前提。没有日度到期，就没有第 23.2 节那种每天都出现的 gamma 集中，没有第 23.4 节那种每天都发生的 charm 流，也没有第 23.10 节那种每天都有的钉住。

*但在月度到期日当天，本章的分析全部成立。*到期日当天的境内期权就是那一天的 0DTE，其 gamma 带以同样的方式收窄，charm 流以同样的方式加速。差别在于频率而不在于机制：境内每月经历一次本章所描述的日子，而美国每天经历一次。

境内市场对这种日子里的合约有一个俗称：**末日轮**，指临近到期的深度虚值合约在标的大幅变动时价格成倍上涨。2019 年 2 月 25 日，50ETF 单日上涨 7.56%，两天后到期的 50ETF 购 2 月 2800 合约涨了约 192 倍，次日又下跌九成以上，到期时几近归零。这是第 23.2 节 gamma 集中的买方视角。

由此得出一个境内特有的推断：境内到期日当天的效应可能比美国任何单日都集中，因为每个品种整个月的未平仓量都在同一天了结，而不是分摊到二十个到期日上。这一判断可以检验：它意味着在到期日当天及前后，标的的成交量与波动率会系统性升高。

零售参与的形态不同

第 10.13 节记录了境内期权市场的投资者适当性要求，即俗称“五有一无”的那一套：

- 申请前 20 个交易日日均托管资产不低于 50 万元（不含融资融券融入的证券和资金）；

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

- 开户满 6 个月并具备融资融券业务参与资格或金融期货交易经历；
- 通过交易所的期权知识测试；
- 具有期权模拟交易经历；
- 通过风险承受能力评估；
- 无不良诚信记录。

与此截然不同，美国零售投资者在手机应用上几分钟内就能开始交易 0DTE。这带来两方面的后果，而且方向相反。

境内零售的期权参与门槛高得多，因此第 23.13 节所描述的那种大规模零售方向性买入，在境内场内期权市场规模有限。但零售的期权性需求并没有消失，而是转到了别处：以雪球、收益凭证和各类结构化产品的形式出现（第 12.12 节），期限是数月到数年，而不是数小时。适当性管理没有减少这类需求，只是改变了它的形态，把它从最短期限推到了最长期限。

这两种形态的风险特征正好相反。0DTE 的风险是日内的，不累积，每天重置；雪球的风险会跨月累积，并集中在敲入线附近。第 23.12 节列出的四条“为何尚未酿成事故”的理由中，有三条对雪球不成立：雪球的订单流是单向的，投资者一律卖出敲入看跌期权；它不是每日到期，因而风险会累积；其标的（中证 500、中证 1000）的深度远不及标普 500。

这一比较令人不安，但很重要。如果只看“是否允许零售做超短期期权”，境内的制度显然更审慎。如果看“零售的期权性敞口最终以什么形态、承担什么风险”，结论就没有那么清楚了。

同一反馈机制，不同载体

本章的核心机制（对冲需求是价格的已知函数，且与变动同向）在境内也存在，只是载体不同。

雪球的敲入线附近是最直接的对应，见第 18.12 节与第 21 章。第 22.14 节已将它与 XIV 的每日再平衡作过对比：delta 跳变发生在某个价格水平上，而不是集中在某个时刻上；这一区别同样把它与 0DTE 区分开来。

月度到期日是第二个，如上所述。

股指期货的贴水与基差交易是第三个，也最容易被忽略。第 22.14 节指出，境内有一部分波动率与相关性溢价以期货贴水的形式出现；贴水快速变化时，做基差交易的资金必须调整头寸，而这些调整同样是价格的函数。

综合三者来看，境内并不缺少本章的机制，缺少的是本章的产品。这有一个实际含义：第 23.14 节列出的可观察量（各执行价的未平仓量分布、交易商净 gamma、卖权利金占比）在境内对应的是雪球存量的敲入线分布、券商场外衍生品的名义规模，以及股指期货的基差水平。要在境内做本章所建议的那种事前监测，应当关注这三项指标，而不是期权链。

若境内引入更短的到期日

这是一个前瞻性问题，应按本章的框架分析，而不是只问“好或坏”。若境内引入周度或日度到期的股指期权，本章分析逐条适用，而结论取决于三个可事先估计的量。

订单流是否双向。美国的良性局面依赖零售买入与系统化卖出大致抵消。境内是否存在规模相当的系统化卖权利金群体，可以根据公募与私募产品的备案数据来估计；如果不存在，交易商会一律空 gamma，第 23.12 节的抑制理由就不成立。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

标的的深度。案例的教训是后果取决于对冲需求与可得流动性之比。沪深 300 与中证 1000 的期货深度远小于标普 500，因此同样的名义对冲流在境内的冲击更大。这个比值可以直接计算。

以及与涨跌停板的相互作用。这是境内独有的，也是最有意思的。第 19.13 节指出涨跌停板截断的是日收益率。对日度到期的期权而言，涨跌停板给收益结构加了硬上限，实际上把期权变成了价差；同时，当对冲工具触及涨跌停时，delta 对冲无法执行（指数本身没有停板，有停板的是 ETF、股指期货与成分股，而对冲正是用它们进行的）。既有集中 gamma、又可能中止交易的市场，其反馈行为与美国不同；这种差别是有利还是不利，取决于停板在对冲耗尽之前还是之后触发。

这个问题目前没有答案，但可以建模；在引入这类产品之前建模，比事后研究成本低得多。

小结

当日到期的期权用不到十年时间从 SPX 期权成交量的个位数份额涨到过半。成交量高估了实际转移的风险，却没有高估对冲，因为对冲被压缩到了几个小时之内。

种种反常之处都源自 $T \to 0$ 时的希腊字母。到期前一小时的 gamma 是三十天时的许多倍，而 gamma 带收窄到现价附近的一个窄区间，于是对冲需求成为指数水平的阶跃函数。charm 引起的对冲流成为主导：做空执行价略高于现价的看涨期权的交易商，即使指数整天纹丝不动，也要平掉一大笔对冲，方向单一、可以预测，且在最后一小时最快。平值看涨期权买方支付的权利金远低于一个标准差的日变动，而若行情毫无变化，到最后一小时之前已损失其中大半。

有三件事常被误读。0DTE 期权覆盖的是交易时段，却按整整一个交易日报价，因此它显示的隐含波动率低于收盘到收盘波动率，而且对冲不了隔夜跳空。若把 $T^{-0.4}$ 规律外推到 1 个月以下（这一段的证据仍有争议），偏斜从三十天到到期前一小时变陡近一个数量级。日内波动率有日程可循：一则公告会抬高上午的隐含波动率，事件过去后，剩余期权的隐含波动率大幅下降。因此，单一波动率无法为这个市场定价：收盘前一小时，略低于现价的看跌期权在平坦波动率下几乎一文不值，在偏斜下的价值却高出许多倍。交易台按业务时间计时，以按标准化价值状态拟合的微笑定价；模型提供的是对冲比率，而不是价格。

对冲起放大还是抑制作用，取决于交易商 gamma 的符号，而这个符号无法观察：零售买入与系统化卖出大致抵消；公布的估计精确度量了未平仓量，头寸却只是按假设度量的。钉住每天发生，而且会饱和：小幅变动时对冲流最大，变动再大便已无可再卖。至今没有出事，是因为订单流有买有卖、头寸在累积之前就已到期、保证金每日收取、标的市场流动性好；四条中第一条最可能改变，需要警惕的情形是单向订单流在最后一小时遇上大幅变动。

境内不存在这种市场结构，因为境内每个品种每月只有一个到期日；但在到期日当天，本章的分析全部成立，而且由于未平仓量集中在一天了结，效应可能更强。境内零售的期权性需求转到了雪球与结构化产品上，而第 23.12 节的四条安心理由中有三条对雪球不成立。同一反馈机制在境内通过雪球敲入线、月度到期日与股指期货基差运行，事前监测应当关注这三处，而不是期权链。

延伸阅读

这是本书最新的话题，相关文献尚未定型；读者应当预期实证结论已有变化。Cboe 自己关于 0DTE 成交构成的研究简报（2023）是了解“实际交易的是什么、由谁交易”的来源，并且区分了合约张数与风险转移，而多数评论没有作这一区分。关于订单流与交易商头寸：Brogaard、Han 与 Won（2023，2026 年修订）发现 0DTE 交易抬高了标的的波动率，并把这一效应主要归因于投机

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

性的零售交易而不是交易商对冲；Dim、Eraker 与 Vilkov（2024）发现做市商的 0DTE 净 gamma 很小、平均为多头，且其后的交易更平稳而非更剧烈；Beckmeyer、Branger 与 Gayda（2023）记录了零售一侧的情况：谁在买、买哪些执行价、回报如何。这些研究合起来，就是第 23.12 节所说的并不一致的证据；它们在交易商对冲问题上的分歧，小于在“0DTE 交易究竟是否改变波动率”问题上的分歧。Bandi、Fusari 与 Renò（2023）是定价论文：在局部高斯密度上加入随时间变化的偏度与峰度，并以跳跃刻画翼部。关于反馈机制本身，期权对冲与市场冲击的文献比 0DTE 早出现几十年，至今完全适用，Grossman（1988）与布雷迪委员会报告是合适的起点。境内方面，各交易所关于期权合约月份与到期日安排的规则以及投资者适当性管理办法，是理解第 23.15 节所述制度差异的一手依据。

练习题

23.1 解释为什么 0DTE 合约成交量高估了被转移的风险量。

23.2 说明 $T \to 0$ 时平值 gamma 的行为，根据表 23.1 求出 1 小时与 30 天 gamma 之比，并解释为什么 gamma 带的收窄比 gamma 本身的增大更重要。

23.3 一份平值 0DTE 看涨期权的成本是现价的 0.38%。说明到期时回本所需的变动，将其与一个标准差的日变动作比较，并解释为什么它的买卖价差在当日更晚时按百分比计要贵得多。

23.4 定义 charm，解释它为什么对月度期权可忽略而对 0DTE 期权占主导，并用例 23.2 列出区分 charm 对冲与 gamma 对冲的三项性质。

23.5 隔夜时段占日方差的 25%。计算在收盘到收盘波动率为 16% 的市场中 0DTE 期权会显示多少隐含波动率，解释为什么这不是期限结构效应，并说明哪一份合约可以对冲收盘后公布的消息。

23.6 用 $T^{-0.4}$ 规律计算 4 小时期限的微笑比 30 天期限的陡多少，并解释为什么用隐含波动率给一份 15 分钟期权报价比直接报价格传递的信息更少。

23.7 解释为什么例 23.6 的钉住力会饱和，以及一个压住小幅变动却压不住大幅变动的市场为什么可能比两者都压不住更糟。

23.8 某个公布的 gamma 敞口数字假定交易商持有全部看涨期权的多头、全部看跌期权的空头。说明其中哪些是度量出来的、哪些是假设的，并解释该假设在什么情况下最不可靠。

23.9 在没有预定事件的日子里，一份 0DTE 期权显示 13.4% 的隐含波动率。下午 2 点的一则公告带来标准差为 0.8% 的变动。计算上午的隐含波动率，以及下午 2 点刚过、还剩 2 小时时的隐含波动率，并解释为什么这一下降并不是波动率的下降。

23.10 解释为什么零售订单流使交易商空 gamma 而系统化卖权利金使他们多 gamma。某交易商账簿每 1% 净空 8 亿美元的 gamma。计算 1.5% 的变动所需的对冲交易与方向，并解释为什么同一股对冲流相对日成交量微不足道而相对下午 3:55 可得的深度是实质性的。

23.11 列出第 23.12 节给出的四条未出事的理由，指出哪一条是行为性的，并解释为什么每日到期限制了风险的规模而不限制它的速度。

23.12 解释当一次变动把指数带出 gamma 带时交易商的对冲需求会发生什么，以及为什么这是危险的情形。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！

23.13 解释为什么境内不存在0DTE、为什么本章的分析在境内月度到期日当天仍然完全适用，以及境内的投资者适当性要求如何改变了零售期权性需求的形态而不是它的规模。

进阶习题

23.14 第 23.2 节给出 gamma 带的上边界从 +6.76% 收窄到 +0.44%。推导该带边界关于 σ 与 T 的表达式，说明该带为什么在执行价对数上关于略高于现价的一点而不是关于现价对称，验证这三组数字，并确定若隐含波动率翻倍该带会如何变化。讨论这对“0DTE 在高波动率环境下更危险还是更不危险”意味着什么。

23.15 例 23.2 得到指数不动时 10.7 亿美元的对冲平仓。给定未平仓量在各执行价上的分布，推导一本账簿从开盘到收盘前半小时的 charm 流，解释为什么在这段时间里该流在偏离现价约半个日标准差的执行价上最大，而不是在平值处最大，说明平值执行价的那部分对冲流去了哪里，并讨论这对“应当在执行价分布的哪一段寻找最大的可预测对冲流”意味着什么。

23.16 重现例 23.5 的 1 小时两行，然后在第 21.5 节的 Merton 跳跃扩散模型中、把扩散波动率定为 15%，为同样两份看跌期权定价，找出能重现带偏斜价格的跳跃强度与平均跳幅。讨论有多少组参数能做到，以及这对把一个动态模型校准到单一到期日意味着什么。

23.17 第 23.12 节论证这个市场之所以良性主要是因为订单流双向，而这一理由是脆弱的。构造一个由零售买方与系统化卖方两个群体组成、其均衡是稳定的模型，指出会破坏该均衡的参数变化，并说明哪些可观察序列会给出预警。

23.18 第 23.14 节称当变动把指数带出 gamma 带时，本可吸收这次变动的对冲会“在中途就已耗尽”。把它形式化：对一本集中在单一执行价的账簿，把交易商对冲需求写成指数水平的函数，说明它在何处递增、在何处消失，并判断一个能吸收小幅变动却不能吸收大幅变动的机制，是否比两者都不吸收的更糟。

23.19 第 23.13 节论证日度到期是市场完备性的一次真实改进。用第 12.8 节的复制结果把这个论证说精确，再构造“更细的期限会因引致对冲集中而降低福利”的反论，并说明要在两者之间作出裁决必须度量什么。

23.20 把0DTE 与组合保险（第 40.2 节）、雪球式自动赎回结构（第 35.7 节）、反向波动率产品（第 22.8 节）三起事件沿头寸集中度、机械化对冲、累积性与可观察性四个维度作比较。说明0DTE 具备哪些特征、不具备哪些，并用该比较论证业界当前的关注水平大致恰当、或者论证它指错了方向。

23.21 第 23.15 节指出境内把零售的期权性需求从最短期限推到了最长期限，并称第 23.12 节的四条安心理由中有三条对雪球不成立。逐条检验这一说法，说明哪一条仍然成立、为什么，并据此论证：从系统性风险的角度看，一个允许零售交易0DTE 的市场与一个把同样的需求导向雪球的市场，哪一个更审慎。明确说明你的结论依赖于哪些可度量的量。

23.22 第 23.15 节提出，若境内引入日度到期的股指期权，涨跌停板会与集中的 gamma 相互作用。把这个相互作用建模：假设标的在触及停板时停止交易，写出交易商在停板附近的对冲需求，说明当停板在对冲需求耗尽之前触发与之后触发时后果有何不同，并据此给出一条关于停板宽度应当如何与期权到期频率相匹配的政策建议。

索吾林：WSuo@Queensu.ca；王勇（微信：CFAFRM）。仅供个人使用，请勿分发！