# 作为极小值的期望损失及其一致性

索吾林

《衍生品：合约、模型与市场》第 *38* 章断言期望损失是一致性风险度量，在线技术附注 [技术附注 39] 则用期望损失的一个表示来训练对冲网络——把它写成关于一个辅助数的极小值，即其方程 *(TN39.2)*。这两个结果在两处都没有证明。本附注证明二者，而第二个是第一个的推论：一旦把期望损失写成一个凸函数之期望的极小值，次可加性只需一行。推导对任意损失分布进行，含原子（概率集中的点）的情形也包括在内，因为第 *38* 章自己的反例就有原子，也因为恰恰在分布有跳跃的地方，期望损失的积分形式才是定义。随后，由这个极小化重新得到该章正态账簿与两只债券的数字。最后一节推导第 *38* 章尾部估计背后的广义帕累托结果——幂律尾部与正态尾部的阈值极限、尾部分位数与期望损失公式、似然函数及其限制与精度——并对照例 *38.7* 加以核对。最后一节说明期望损失为何难以回测、又为何不能单独评分，这两点该章只作了陈述。

`tools/verify/tn38-expected-shortfall.py` 重新算过此处的每一项结果。

## 1　任意分布下的两个度量

令 $L$ 为组合在该期间上的损失，越大越坏，分布函数为 $F(l) = \mathbb{P}(L \le l)$，均值有限。第 38 章把置信度记作 $c$，[技术附注 39] 沿用最优化文献的记法记作 $\alpha$；二者是同一个数，本附注通篇用 $c$。[技术附注 39] 还用最优化文献的名称条件风险价值（CVaR）来称呼期望损失。

第 38 章用 $\mathbb{P}(L > \mathrm{VaR}_c) = 1 - c$ 定义风险价值，即该章的方程 (38.1)。当 $F$ 跳过水平 $c$ 时，这个方程无解，而覆盖一切情形的定义是下分位数，即 $F$ 的广义逆：

$$\mathrm{VaR}_c = q(c) = \inf\{\, l : F(l) \ge c \,\}, \qquad 0 < c < 1. \tag{TN38.1}$$

只要 (38.1) 有解，它就与 (38.1) 一致；(38.1) 无解时，它取 $F$ 越过 $c$ 的那个损失——例 38.2 正是这样读出它的分位数的。函数 $q$ 单调不减，又因为 $F$ 右连续，$q(u) \le l$ 当且仅当 $u \le F(l)$。

期望损失由第 38 章方程 (38.2) 定义：

$$\mathrm{ES}_c = \frac{1}{1-c} \int_c^1 q(u)\, du, \tag{TN38.2}$$

即 $c$ 之外所有风险价值的平均。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

这个积分可以读成一个期望。令 $U$ 在 $(0,1)$ 上均匀分布。由上面那个等价关系，$\mathbb{P}\big(q(U) \le l\big) = \mathbb{P}\big(U \le F(l)\big) = F(l)$，所以 $q(U)$ 与 $L$ 同分布，对任何期望有限的函数 $h$，

$$\mathbb{E}\big[h(L)\big] = \int_0^1 h\big(q(u)\big)\, du. \tag{TN38.3}$$

在这个表示下，(TN38.2) 就是 $\mathbb{E}\big[q(U)\,\mathbf{1}\{U > c\}\big]/(1-c)$：按概率计的最坏 $1-c$ 部分结果上的平均损失。当 $F$ 跳过 $c$ 时，均匀变量把分位数处的原子切开，只把尾部需要的那一部分留在尾部之内。条件均值 $\mathbb{E}[L \mid L > \mathrm{VaR}_c]$ 做不到这一点，它要么取整个原子，要么一点不取；这正是 (38.2) 的两个形式在分布有跳跃处分道扬镳的原因。

## 2 作为极小值的期望损失

对每个实数 $w$，定义

$$g(w) = w + \frac{1}{1-c}\,\mathbb{E}\big[(L-w)^+\big]. \tag{TN38.4}$$

方程 (TN39.2) 断言 $\min_w g(w) = \mathrm{ES}_c$，并在 $w = \mathrm{VaR}_c$ 处取到。证明分三步。

**凸性。** 对每个损失值 $l$，映射 $w \mapsto (l-w)^+$ 是凸的，而凸函数的期望仍是凸的。加上线性项 $w$ 不破坏凸性，所以 $g$ 是凸函数；由于 $L$ 的均值有限，它处处有限。

**斜率。** $(l-w)^+$ 对 $w$ 的右导数是 $-\mathbf{1}\{l > w\}$，左导数是 $-\mathbf{1}\{l \ge w\}$。差商的绝对值不超过一，所以导数可以与期望交换，从而

$$g'_+(w) = 1 - \frac{\mathbb{P}(L > w)}{1-c} = \frac{F(w) - c}{1-c}, \qquad g'_-(w) = \frac{F(w^-) - c}{1-c}, \tag{TN38.5}$$

其中 $F(w^-) = \mathbb{P}(L < w)$。凸函数在 $w$ 处取到极小，当且仅当它在该处的左斜率不为正、右斜率不为负，由 (TN38.5)，这就是条件 $F(w^-) \le c \le F(w)$。

**极小值点。** 分位数 $q(c)$ 满足这个条件：由右连续性 $F(q(c)) \ge c$，而由下确界的定义，对每个 $l < q(c)$ 都有 $F(l) < c$，所以 $F(q(c)^-) \le c$。因此风险价值使 $g$ 取到极小。极小值点的全体是从 $q(c)$ 到 $\inf\{l : F(l) > c\}$ 的闭区间，除非 $F$ 恰在高度 $c$ 上有一段平台，否则它只是一个点；在这个区间上 $g$ 为常数，取其中任何一点都可以。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

**极小值。** 由于 $q$ 单调不减，$u > c$ 时 $q(u) - q(c)$ 非负，$u \le c$ 时非正。因此对每一个 $u$（而不只是几乎每一个 $u$），$\big(q(u)-q(c)\big)^{+} = \big(q(u)-q(c)\big)\,\mathbf{1}\{u > c\}$，由 (TN38.3) 得

$$\mathbb{E}\big[(L - q(c))^{+}\big] = \int_c^1 \big(q(u) - q(c)\big)\,du = \int_c^1 q(u)\,du - (1-c)\,q(c). \tag{TN38.6}$$

这一步没有假设密度存在：它只用到 $q$ 的单调性，所以在有原子时同样成立。代入 (TN38.4)，含 $q(c)$ 的两项相消，得到

$$\min_{w\in\mathbb{R}} \left\{ w + \frac{1}{1-c}\,\mathbb{E}\big[(L-w)^{+}\big] \right\} = g\big(q(c)\big) = \frac{1}{1-c}\int_c^1 q(u)\,du = \mathrm{ES}_c, \tag{TN38.7}$$

这就是方程 (TN39.2)，取到极小的 $w$ 就是风险价值。

不经分位数变换、直接在 $q = q(c)$ 处计算 $g$，得到同一个数的另一种写法，它显示了原子是怎样被处理的：

$$\mathrm{ES}_c = \frac{1}{1-c}\Big(\mathbb{E}\big[L\,\mathbf{1}\{L > q\}\big] + q\,\big(F(q) - c\big)\Big). \tag{TN38.8}$$

第一项是严格位于分位数之外的尾部。第二项是分位数处的原子中落在最坏 $1-c$ 之内的那一份，按分位数计值。当 $F$ 在 $q$ 处连续时 $F(q) = c$，第二项消失，(TN38.8) 就是条件均值 $\mathbb{E}[L \mid L > q]$，即第 38 章对连续分布给出的那个形式。

## 3 TN39 用到的是什么

(TN38.7) 的三条性质使它成为训练循环可以使用的形式。

第一，它消除了移动的边界。写成 $\mathbb{E}[L \mid L > \mathrm{VaR}_c]$ 时，期望损失是在一条尾部上求平均，而尾部的边界随对冲参数 $\theta$ 的每一次变动而移动。写成 (TN38.7) 时，它是在 $(\theta, w)$ 上联合求极小的一个普通期望，被求期望的是

$$G(\theta, w; L_\theta) = w + \frac{(L_\theta - w)^{+}}{1-c},$$

一个只有一个折点的、关于损失的分段线性函数。在固定的 $\theta$ 与 $w$ 下，$G$ 的批量平均是目标的无偏估计，而对批量中自身最坏的那些路径取平均则不是。

第二，梯度只由尾部路径承担。逐路径地，

$$\frac{\partial G}{\partial w} = 1 - \frac{\mathbf{1}\{L_\theta > w\}}{1-c}, \qquad \frac{\partial G}{\partial \theta} = \frac{\mathbf{1}\{L_\theta > w\}}{1-c}\,\frac{\partial L_\theta}{\partial \theta}, \tag{TN38.9}$$

因子 $\mathbf{1}\{L > w\}/(1-c)$ 就是 [技术附注 39] 所引的那个。损失低于 $w$ 的路径对 $\theta$ 方向的梯度毫无贡献；在 $c = 0.95$、批量为 2,048 条路径时，有贡献的路径的期望条数为 $2{,}048 \times 0.05 = 102.4$，即该附注所说的“大约一百条”。第一个式子的期望就是右斜率 (TN38.5)，所以对 $w$ 做随机梯度下降，会把它推向当前损失分



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

布的分位数。而在取到极小的 $w$ 处，对 $w$ 的斜率为零，于是 $\mathrm{ES}_c$ 对 $\theta$ 的导数等于 $\mathbb{E}\big[\mathbf{1}\{L_\theta > \mathrm{VaR}_c\}\,\partial L_\theta/\partial\theta\big]/(1-c)$：尾部边界的移动在一阶上没有贡献——引入这个表示，要消除的正是这个困难。

第三，折点无害。$(l-w)^+$ 在 $l=w$ 处不可导，但当 $L_\theta$ 的分布连续时，这个事件的概率为零，所以 (TN38.9) 在几乎每条路径上成立。被积函数对 $L_\theta$ 与 $w$ 满足 Lipschitz 条件，所以只要 $\partial L_\theta/\partial\theta$ 有界，由控制收敛定理，导数就可以与期望交换。这与容许在执行价处对看涨收益求路径导数的论证相同。

由 $g$ 的形状可以得出两条实际结论。每一个 $w$ 都给出一个上界 $g(w)\ge \mathrm{ES}_c$，所以尚未收敛的 $w$ 只会高估风险，而不会低估。并且这个上界在二阶意义上是紧的：当 $L$ 有密度 $f$ 时，在分位数附近 $g(w)-\mathrm{ES}_c \approx f(q)\,(w-q)^2/\big(2(1-c)\big)$，所以 $w$ 上的误差在目标上造成的代价，远小于它在分位数本身上的大小。第 5 节给这两点配上数字。

## 4 一致性

第 38 章称一个风险度量 $\rho$ 为一致性的，如果它满足单调性、正齐次性、平移不变性与次可加性。在本附注的约定下，$\rho$ 作用于损失 $X$ 与 $Y$，四条性质是：

- 单调性：若在每个状态下 $X\le Y$，则 $\rho(X)\le\rho(Y)$；
- 正齐次性：对每个 $\lambda\ge 0$，$\rho(\lambda X)=\lambda\rho(X)$；
- 平移不变性：对每个常数 $m$，$\rho(X+m)=\rho(X)+m$，即加上一笔确定的损失 $m$，度量就增加 $m$；
- 次可加性：$\rho(X+Y)\le\rho(X)+\rho(Y)$，即第 38 章的方程 (38.3)。

对 $\mathrm{ES}_c$，每一条都由 (TN38.7) 推出。记 $g_X$ 为在损失 $X$ 上构造的函数 (TN38.4)。

**单调性。** 若 $X\le Y$，则 $(X-w)^+\le(Y-w)^+$，于是对每个 $w$ 有 $g_X(w)\le g_Y(w)$，较小函数的极小值也较小。

**平移不变性。** 代入 $v=w-m$，

$$g_{X+m}(w)=w+\frac{1}{1-c}\,\mathbb{E}\big[(X-v)^+\big]=m+g_X(v),$$

对 $w$ 求极小就是对 $v$ 求极小，所以 $\mathrm{ES}_c(X+m)=\mathrm{ES}_c(X)+m$。

**正齐次性。** 对 $\lambda>0$，代入 $v=w/\lambda$，

$$g_{\lambda X}(w)=\lambda v+\frac{\lambda}{1-c}\,\mathbb{E}\big[(X-v)^+\big]=\lambda\,g_X(v),$$

所以 $\mathrm{ES}_c(\lambda X)=\lambda\,\mathrm{ES}_c(X)$。$\lambda=0$ 时两边都为零。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

**次可加性。** 令 $w_X$ 与 $w_Y$ 分别使 $g_X$ 与 $g_Y$ 取到极小；取 $X$ 与 $Y$ 的风险价值即可。对任意两个数 $a$ 与 $b$ 有 $(a+b)^+ \le a^+ + b^+$，所以逐状态地

$$\big(X+Y-(w_X+w_Y)\big)^+ \le (X-w_X)^+ + (Y-w_Y)^+.$$

取期望、除以 $1-c$、两边再加上 $w_X+w_Y$，得到 $g_{X+Y}(w_X+w_Y) \le g_X(w_X)+g_Y(w_Y)$；而 $g_{X+Y}$ 的极小值不会大于它在 $w_X+w_Y$ 这一特定点上的值。所以

$$\mathrm{ES}_c(X+Y) \le g_{X+Y}(w_X+w_Y) \le g_X(w_X)+g_Y(w_Y) = \mathrm{ES}_c(X)+\mathrm{ES}_c(Y). \qquad \blacksquare \tag{TN38.10}$$

这个论证对 $X$ 与 $Y$ 的联合分布没有任何要求：它们可以独立，可以相依，也可以是同一个头寸持有两次。它也不要求连续性，因为 (TN38.7) 是在有原子的情形下证明的；它不加修改地适用于例 38.2 的两只债券。

**同一论证为什么对风险价值不成立。** 期望损失是一个极小化问题的值，次可加性来自被极小化的函数之间的一个不等式。风险价值则是极小值*在哪里取到*，而 (TN38.10) 对 $g_{X+Y}$ 在哪里最小没有说任何话。在例 38.2 中，两只债券的极小值点是 $w_X = w_Y = 0$，但 $g_{X+Y}$ 在 $w_X+w_Y=0$ 处的右斜率为负，所以这一对的极小值点在别处，在 1,000 万美元。用分位数的话说：期望损失是分位数的平均，正是在尾部上求平均产生了 (TN38.10) 中的凸性；风险价值则是单个分位数，而和的分位数与分位数的和之间一般没有任何关系。对联合正态的损失，在任何高于二分之一的置信度上，这个关系碰巧成立，这就是为什么第 38 章发现风险价值在光滑、大致椭圆的分布上表现良好，而在有跳跃的账簿上不可靠。

## 5 对照第 38 章的两项核对

**正态账簿。** 例 38.1 持有一个头寸，其日损失服从均值为零、标准差 $\sigma = 200$ 万美元的正态分布。对这样的损失，记 $k = w/\sigma$，$N$ 与 $N'$ 为标准正态分布函数与密度，

$$g(w) = w + \frac{\sigma N'(k) - w\,\big(1-N(k)\big)}{1-c}. \tag{TN38.11}$$

在 $w = z\sigma$、$z = N^{-1}(c)$ 处，$w(1-N(k))/(1-c)$ 这一项等于 $w$，与首项相消，剩下 $g = \sigma N'(z)/(1-c)$，正是该章期望损失的闭式解。在不知道 $z$ 的情况下用黄金分割搜索对 (TN38.11) 做数值极小化，得到的是同样的数字。下表是 99% 下搜索所看到的情形：

| $w$（**\$m**） | $g(w)$（**\$m**） | $g(w)-\mathrm{ES}$ | 斜率 $(F(w)-c)/(1-c)$ |
|---|---|---|---|
| 4.00 | 5.70 | 0.37 | −1.28 |
| 4.40 | 5.38 | 0.05 | −0.39 |
| 4.65 | 5.33 | 0.00 | 0.00 |
| 4.90 | 5.37 | 0.04 | 0.29 |
| 5.50 | 5.68 | 0.35 | 0.70 |



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

斜率在风险价值处变号，而在其他所有地方 $g$ 都位于期望损失之上。把 $w$ 设在比真实分位数低约 5% 的 440 万美元处，期望损失被高估不到 1%——这就是第 3 节所说的二阶平坦性的数字形态。

**两只债券。** 例 38.2 的两只债券相互独立，各 1,000 万美元，违约概率 0.8%，零回收，在 99% 上度量。每个损失分布都是离散的，所以 $g$ 是分段线性的，折点位于各原子处，它的极小值可以通过在这些点上求值而精确得到。对单只债券，在 $0 \le w \le 10$ 上，

$$g(w) = w + \frac{0.008 \times (10 - w)}{0.01} = 8 + 0.2\,w,$$

而 $w < 0$ 时斜率为 $-99$，所以极小值点是 $w = 0$，即这只债券的风险价值，极小值为 800 万美元，与该章的数字相同。对这一对债券，$w = 0$ 处的右斜率是 $(0.984064 - 0.99)/0.01 = -0.5936$，$w = 10$ 处是 $(0.999936 - 0.99)/0.01 = 0.9936$，所以极小值点在 1,000 万美元，极小值为

$$g(10) = 10 + \frac{0.000064 \times 10}{0.01} = 10.064.$$

由 (TN38.8)，同一个数是 $\big(0.000064 \times 20 + 10 \times 0.009936\big)/0.01$：第二项是 1,000 万美元那个原子中落在最坏 1% 之内的份额，也就是该章计算中“其余 0.009936 落在 \$10m”的那一部分。

| 头寸 | $c$ | 极小值点 $w$ | 极小值 $g$ | 第 38 章所列 |
|---|---|---|---|---|
| 正态账簿 | 97.5% | 3.9199 | 4.6756 | VaR \$3.92m，ES \$4.68m |
| 正态账簿 | 99% | 4.6527 | 5.3304 | VaR \$4.65m，ES \$5.33m |
| 单只债券 | 99% | 0 | 8.000 | VaR \$0，ES \$8m |
| 两只债券 | 99% | 10 | 10.064 | VaR \$10m，ES \$10.06m |

在这两只债券上，次可加性链 (TN38.10) 读作 $10.064 \le 16 \le 8 + 8$。这里中间的不等式取等号，因为损失从不为负，在 $w_X = w_Y = 0$ 处满足 $(a+b)^+ = a^+ + b^+$；分散化的好处全部来自第一个不等式，来自把 $w$ 从 0 移到 10。风险价值读的是极小值点那一列，它从 $0 + 0$ 变成了 10。

另外两个数说明了为什么这里必须以积分形式为定义。条件均值 $\mathbb{E}[L \mid L > \mathrm{VaR}_{99\%}]$ 对单只债券是 1,000 万美元，对这一对是 2,000 万美元，两者都不是最坏 1% 上的平均损失：它所取条件的事件，概率在前一情形是 0.008，在后一情形是 0.000064，而不是 0.01。而在 $c = 0.992$ 时，$F(0)$ 恰好等于 $c$，单只债券的 $g$ 在 0 与 10 之间的每一个 $w$ 上都等于 1,000 万美元：这就是第 2 节的平台区间，其上任何一点都是风险价值，给出的期望损失也都相同。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

## 6 广义帕累托尾部

第38.9节用500天损失中最大的25个拟合广义帕累托分布，来估计99.9%的风险价值与期望损失，例38.7把这一计算完整走了一遍。该章用到五项结果而未加推导：高阈值之上的超出量服从这一分布；自由度为 $\nu$ 的 $t$-分布有 $\xi = 1/\nu$，正态分布有 $\xi = 0$；尾部分位数公式与期望损失公式；以及似然函数及其限制 $\xi \geq -1/2$。本节逐一推导。唯一的例外是一般的极限定理，这里只陈述它，再对该章用到的两种尾部亲手算出结果。

**极限分布。** 对阈值 $u$，**超出量分布**是在 $u$ 被超过的条件下、损失超出 $u$ 的部分的分布：

$$F_u(y) = \mathbb{P}(L - u \leq y \mid L > u) = \frac{F(u+y) - F(u)}{1 - F(u)}, \qquad y \geq 0. \tag{TN38.12}$$

形状参数为 $\xi$、尺度参数为 $\psi > 0$ 的广义帕累托分布是

$$G_{\xi,\psi}(y) = 1 - \left(1 + \frac{\xi y}{\psi}\right)^{-1/\xi}, \qquad G_{0,\psi}(y) = 1 - e^{-y/\psi}, \tag{TN38.13}$$

$\xi \geq 0$ 时定义在 $y \geq 0$ 上，$\xi < 0$ 时定义在 $0 \leq y \leq -\psi/\xi$ 上；指数分布是第一种形式在 $\xi \to 0$ 时的极限。Pickands–Balkema–de Haan 定理说：对处在某个极值分布吸引域中的每一个分布——实践中用来描述损失的连续分布都在其中——存在尺度函数 $\psi(u)$，使得当 $u$ 升向分布的右端时

$$\sup_y \left| F_u(y) - G_{\xi,\psi(u)}(y) \right| \to 0,$$

其中形状 $\xi$ 由 $F$ 决定。它的证明超出了本附注的范围。该章用到的两种情形可以直接算出，而且能看出尺度函数从何而来。

**幂律尾部有 $\xi = 1/\alpha$。** 设对所有足够大的 $x$ 有 $\mathbb{P}(L > x) = Cx^{-\alpha}$。则对这一范围内的 $u$，

$$\mathbb{P}(L - u > y \mid L > u) = \left(\frac{u+y}{u}\right)^{-\alpha} = \left(1 + \frac{\xi y}{\xi u}\right)^{-1/\xi}, \qquad \xi = \frac{1}{\alpha},$$

恰好就是 $G_{\xi,\,\xi u}$。若尾部只是渐近地为幂律，即 $\mathbb{P}(L > x) = x^{-\alpha}\mathcal{L}(x)$，其中 $\mathcal{L}(tx)/\mathcal{L}(x) \to 1$，那么只多出一个趋于一的因子 $\mathcal{L}(u+y)/\mathcal{L}(u)$，极限不变。自由度为 $\nu$ 的 $t$-分布，密度与 $(1 + t^2/\nu)^{-(\nu+1)/2}$ 成正比，按 $t^{-(\nu+1)}$ 衰减；因此其尾部按 $t^{-\nu}$ 衰减，$\xi = 1/\nu$。$\nu = 4$ 时分布函数有闭式 $F(t) = 1/2 + 3(\kappa - \kappa^3/3)/4$，其中 $\kappa = t/\sqrt{t^2+4}$，按 $1 - \kappa \approx 2/t^2$ 展开得到

$$\mathbb{P}(T > t) \approx 3\,t^{-4}, \tag{TN38.14}$$

即 $\alpha = 4$ 的幂律尾部，也就是该章的 $\xi = 0.25$。对损失做缩放只改变尾部的常数、不改变指数，所以该账簿缩放后的 $t$-分布形状相同。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

**正态尾部有 $\xi = 0$。** 对标准正态分布，$1 - N(x) = N'(x)/x \cdot \big(1 + O(x^{-2})\big)$，于是

$$\frac{1 - N(u+y)}{1 - N(u)} \approx \frac{u}{u+y}\, e^{-uy - y^2/2}.$$

令 $y = \tau/u$，上式成为 $(1 + \tau/u^2)^{-1} e^{-\tau - \tau^2/(2u^2)} \to e^{-\tau}$。以 $1/u$ 为单位计量，超出量服从指数分布：$\xi = 0$，$\psi(u) = 1/u$；对均值为零、标准差为 $\sigma$ 的正态损失则是 $\sigma^2/u$。尺度随阈值升高而缩小，所以看得越远，剩下的损失越紧地挤在阈值上方。尾部衰减快于任何幂律，说的就是这件事；对数正态分布与伽马分布也因同样的原因落在 $\xi = 0$。

**极限来得很慢。** 在例 38.7 的账簿的 95% 阈值处，(TN38.14) 离真实情况还很远。标准化后的阈值是 $t = 2.1318$，那里 $3t^{-4} = 0.145$，而真实的尾部概率是 0.05。照极限字面取 $\xi = 0.25$、$\psi = \xi u = 0.754$，99.9% 的风险价值落在 802 万美元，而不是 1,014 万美元。对超出量做拟合，也得不到这两个参数。按最大化期望对数似然的意义——也就是超出值个数增长时极大似然所收敛到的目标——与该阈值之上精确的超出量分布最吻合的广义帕累托分布有 $\xi^* = 0.192$、$\psi^* = 1.222$。它给出的风险价值是 1,013 万美元，期望损失是 1,333 万美元，真值则是 1,014 万美元与 1,370 万美元。该方法在这个阈值上之所以有效，不是因为极限已经到来，而是因为拟合出的形状与尺度相互抵偿——$\xi$ 偏低、$\psi$ 偏高——从而复现了分位数。这就是超阈值峰值法让 $\psi$ 自由拟合、而不把它设为 $\xi u$ 的原因；也是为什么在有限阈值上，$\hat\xi$ 估计的是最能拟合尾部肩部的形状，它不一定等于尾部指数。

**阈值稳定性。** 若 $Y$ 服从 $G_{\xi,\psi}$，且 $v \ge 0$ 在其支撑之内，则

$$\mathbb{P}(Y - v > y \mid Y > v) = \left(\frac{1 + \xi(v+y)/\psi}{1 + \xi v/\psi}\right)^{-1/\xi} = \left(1 + \frac{\xi\, y}{\psi + \xi v}\right)^{-1/\xi}, \tag{TN38.15}$$

所以超出更高阈值的部分仍服从广义帕累托分布，形状不变，尺度为 $\psi + \xi v$。$G_{\xi,\psi}$ 的均值是其尾部的积分，$\int_0^\infty (1 + \xi y/\psi)^{-1/\xi}\, dy = \psi/(1-\xi)$，仅当 $\xi < 1$ 时有限；同理，$k$ 阶矩仅当 $\xi < 1/k$ 时有限，这与 $t$-分布恰好具有低于 $\nu$ 阶的各阶矩相吻合。两者合起来，平均超出量是水平的线性函数：

$$\mathbb{E}[L - x \mid L > x] = \frac{\psi + \xi(x - u)}{1 - \xi}, \qquad x \ge u. \tag{TN38.16}$$

**尾部分位数。** 对 $x \ge u$，$\mathbb{P}(L > x) = \mathbb{P}(L > u)\,\mathbb{P}(L - u > x - u \mid L > u)$。用 $n$ 个观测值中超过 $u$ 的比例 $N_u/n$ 估计第一个因子，用拟合出的分布估计第二个因子，

$$\hat{\mathbb{P}}(L > x) = \frac{N_u}{n}\left(1 + \frac{\xi(x-u)}{\psi}\right)^{-1/\xi}. \tag{TN38.17}$$



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

令其等于 $1-c$ 并解出 $x$，

$$\mathrm{VaR}_c = u + \frac{\psi}{\xi}\left[\left(\frac{n}{N_u}(1-c)\right)^{-\xi} - 1\right], \tag{TN38.18}$$

$\xi \to 0$ 时它趋于 $u - \psi \ln\big((n/N_u)(1-c)\big)$。它只适用于 $1-c \le N_u/n$，即阈值之外的分位数。在例 38.7 中，$(n/N_u)(1-c) = 20 \times 0.001 = 0.02$：损失的 99.9% 分位数，就是超出量中有 2% 位于其外的那一点。

**期望损失。** 拟合出的分布是连续的，所以由 (TN38.8)，期望损失就是超出风险价值的条件均值；在 $x = \mathrm{VaR}_c$ 处用 (TN38.16)，得到

$$\mathrm{ES}_c = \mathrm{VaR}_c + \frac{\psi + \xi(\mathrm{VaR}_c - u)}{1-\xi} = \frac{\mathrm{VaR}_c + \psi - \xi u}{1-\xi}, \tag{TN38.19}$$

即该章的公式。它仅当 $\xi < 1$ 时有限；又因为它除以 $1-\xi$，接近一的形状估计会把它无限放大。这就是在例 38.7 之后的模拟中，400 个窗口的期望损失均值高于中位窗口的原因。当 $c \to 1$ 时，风险价值无限增大而 $\psi$ 与 $u$ 不变，所以

$$\frac{\mathrm{ES}_c}{\mathrm{VaR}_c} \to \frac{1}{1-\xi}.$$

$\xi = 0.25$ 时极限是 $4/3$，而该章的账簿在 99.9% 上的精确比值是 1.350。正态尾部的这一比值趋于一。随着置信度升高，薄尾的两个度量趋于一致，肥尾则让二者保持固定的比例差距——这正是例 38.6 的表中呈现的规律。

**似然函数。** 对 (TN38.13) 求导得到密度 $(1/\psi)(1+\xi y/\psi)^{-1/\xi-1}$，超出量 $y_1, \dots, y_N$（这里 $N$ 是超出值的个数，即上文的 $N_u$）的对数似然为

$$\ell(\psi, \xi) = -N \ln \psi - \left(1 + \frac{1}{\xi}\right) \sum_{i=1}^{N} \ln\left(1 + \frac{\xi\, y_i}{\psi}\right), \tag{TN38.20}$$

约束为对每个 $i$ 有 $1 + \xi y_i/\psi > 0$。这一约束只在 $\xi < 0$ 时起作用，它要求最大的超出量位于端点 $-\psi/\xi$ 之下；正是它排除了 $\xi < -1$。令 $\psi$ 下降趋向 $-\xi\, y_{\max}$，把端点压到最大的观测值上。该观测值的项 $\ln(1 + \xi y_{\max}/\psi)$ 趋于 $-\infty$，而当 $\xi < -1$ 时其系数 $-(1 + 1/\xi)$ 为负，于是乘积趋于 $+\infty$，$\ell \to +\infty$，似然函数没有极大值。（等价地，密度的指数 $-1/\xi - 1$ 为负，所以拟合出的密度在端点处无界。）$-1 < \xi < -1/2$ 时极大值存在，但估计量不具有通常的正态近似，这正是要施加更强的限制 $\xi \ge -1/2$ 的原因；$\xi > -1/2$ 时则具有。当真实分布是肥尾时，限制 $\xi \ge -1/2$ 毫无代价；在第 38.9 节的 400 个模拟窗口中，它在 14 个里起作用。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

**从二维降到一维。** 记 $\theta = \xi/\psi$。则 $\ln(1+\xi y_i/\psi) = \ln(1+\theta y_i)$，并且由 $\psi = \xi/\theta$，

$$\ell = -N\ln\xi + N\ln\theta - \Big(1+\frac{1}{\xi}\Big)S(\theta), \qquad S(\theta) = \sum_{i=1}^{N}\ln(1+\theta y_i).$$

对固定的 $\theta$，它关于 $\xi$ 的极大值在 $-N/\xi + S/\xi^2 = 0$ 处取到，即 $\xi(\theta) = S(\theta)/N$；代回后只剩一个变量的函数，

$$\ell_p(\theta) = -N\ln\frac{\xi(\theta)}{\theta} - N\,\xi(\theta) - N, \qquad \ell_p(0) = -N\ln\bar{y} - N, \tag{TN38.21}$$

后一式是指数分布的情形。由于 $\xi'(\theta) = \sum_i y_i/(1+\theta y_i)/N > 0$，限制 $\xi \ge -1/2$ 是 $\theta$ 的一个下界，而支撑约束是 $\theta > -1/y_{\max}$。核对脚本在第 38.9 节的全部 400 个模拟窗口中先用网格、再用黄金分割搜索来最大化 (TN38.21)；在窗口 1 中它给出 $\hat\theta = 0.0854$，从而 $\hat\xi = 0.0983$、$\hat\psi = 1.1511$。

**形状估计有多精确。** $\xi > -1/2$ 时，估计量在大样本下近似服从正态分布，协方差为Fisher 信息的逆：

$$\operatorname{Cov}\begin{pmatrix}\hat\psi\\ \hat\xi\end{pmatrix} \approx \frac{1+\xi}{N}\begin{pmatrix}2\psi^2 & -\psi\\ -\psi & 1+\xi\end{pmatrix}. \tag{TN38.22}$$

它对例 38.7 及其后的模拟有两点含义。$\hat\xi$ 的标准误是 $(1+\xi)/\sqrt{N}$，在 $N = 25$、$\xi = 0.25$ 时为0.25，与被估计的形状本身一样大。在 400 个窗口中，$\hat\xi$ 的标准差为0.28，中位数为0.12，所以窗口 1 的0.098 是一次寻常的抽样，而不是运气不好。两个估计量的相关系数是 $-1/\sqrt{2(1+\xi)} = -0.63$：低估形状的窗口往往高估尺度，两项误差在分位数中部分抵消，与上面大样本拟合中的情形一样。这些窗口显示了这种抵消：它们的 $\hat\xi$ 均值为0.107，既低于尾部指数，也低于无限样本会收敛到的0.192，而它们的风险价值估计均值与真值相差不到0.3%。

## 7 期望损失的回测与可引出性

第 38 章对“拿结果检验期望损失”说了两件事：它不能靠数突破次数来回测；它单独不具有可引出性，而风险价值与期望损失这一对具有。这是两个不同的问题。前者关乎检验单个模型，后者关乎为若干个模型排序。

**检验单个模型。** 风险价值的预测预言的是一个事件 $L_t > \mathrm{VaR}_t$，在模型之下这些事件的个数服从二项分布。期望损失的预测预言的是一个条件均值，所以检验必须把尾部损失与预测相比，而不是去数它们。Acerbi 与 Székely（2014）给出两个统计量。记 $I_t = \mathbf{1}\{L_t > \mathrm{VaR}_t\}$ 为 $T$ 天中第 $t$ 天的突破，$N_T = \sum_t I_t$。于是

$$Z_1 = \frac{1}{N_T}\sum_{t=1}^{T}\frac{L_t\,I_t}{\mathrm{ES}_t} - 1, \qquad Z_2 = \sum_{t=1}^{T}\frac{L_t\,I_t}{T\,(1-c)\,\mathrm{ES}_t} - 1. \tag{TN38.23}$$



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

若预测正确，则 $\mathbb{E}[L_t \mid L_t > \mathrm{VaR}_t] = \mathrm{ES}_t$，所以 $Z_1$ 平均的是期望为一的比值，以零为中心。它只看突破日损失的大小，不看突破有多少次，这就是该章要把它与突破计数并用的原因。$Z_2$ 用的是由 (TN38.8) 得出的 $\mathbb{E}[L_t I_t] = (1-c)\,\mathrm{ES}_t$，所以它也以零为中心，并且对突破太多与突破太大都有反应。两者取正值都意味着预测低估了尾部。两个统计量都没有标准分布，其显著性要通过从模型自己的预测分布中模拟 $T$ 天、看观察值落在哪里来确定。

**为模型排序。** 一个分布的统计量 $T(F)$ 称为**可引出**的，如果存在一个把预测 $x$ 与结果 $y$ 相比较的评分函数 $S(x,y)$，使得对该类中的每一个 $F$，期望得分 $\mathbb{E}_F[S(x,Y)]$ 都在 $x = T(F)$ 处取最小。于是一个可引出统计量的相互竞争的预测，可以按它们在一段历史上的平均得分排序，而预测者除了报出真值之外没有别的动机。均值用 $S = (x-y)^2$ 即可引出。分位数用 pinball 评分

$$S(x,y) = \big(\mathbf{1}\{y \le x\} - c\big)(x - y) \tag{TN38.24}$$

可引出：它的期望对 $x$ 的导数是 $F(x) - c$，在 $c$ 分位数处为零，所以风险价值是可引出的。期望损失不是。Gneiting（2011）指出，任何可引出统计量的水平集都是凸的：两个分布若有相同的统计量值，它们的每一个混合也有，因为混合的期望得分就是两个在同一点取最小的函数的同样的混合。期望损失不满足这一点。两个分布可以有相同的期望损失而风险价值不同，于是它们的混合的分位数落在别处，期望损失也不再是那个共同的值。

**那一对。** Fissler 与 Ziegel（2016）证明风险价值与期望损失合在一起是可引出的。他们那一族评分函数中的一个，以损失表示、预测 $v$ 与 $e$ 取正值，是

$$S(v,e;y) = \frac{\mathbf{1}\{y > v\}\,(y - v)}{(1-c)\,e} + \frac{v}{e} + \ln e - 1. \tag{TN38.25}$$

它的期望在对 $v$ 的导数 $\big(1 - \mathbb{P}(L > v)/(1-c)\big)/e$ 为零处取最小，即 $v = q(c)$；在对 $e$ 的导数为零处取最小，即

$$e = v + \frac{1}{1-c}\,\mathbb{E}\big[(L - v)^+\big],$$

这正是 (TN38.7) 中被极小化的那个表达式，在 $v = q(c)$ 处等于 $\mathrm{ES}_c$。因此，使期望损失具有一致性的那个极小化，一旦把分位数与它一起报出，也就是使它可以评分的东西。对 $c = 97.5\%$ 的标准正态损失，期望得分 (TN38.25) 在 $(v,e) = (1.9600,\ 2.3378)$ 处最小，即第 38 章例 38.1 的那两个数字，核对脚本用直接搜索确认了这一点。

**框架拿它做了什么。** 第 39 章的资本框架按期望损失计提资本，却用计数在 97.5% 与 99% 上回测风险价值。这检验的是分位数——它可引出、也可以靠计数检验——而把尾部的大小留给损益归因检验与监管判断；$Z_1$ 与 $Z_2$ 由银行出于自身目的运行，但不属于规则的一部分。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

## 延伸阅读

Artzner、Delbaen、Eber 与 Heath（1999）提出了四条公理，把满足它们的度量称为一致性的，并证明风险价值不满足次可加性。Rockafellar 与 Uryasev（2000）针对连续分布提出了极小化 (TN38.7)，用以通过线性规划来优化组合，他们 2002 年的论文把它推广到一般分布，也就是本附注处理的情形。Acerbi 与 Tasche（2002）篇幅很短，解决了有原子时会发生什么：它证明积分形式 (TN38.2) ——等价地，(TN38.8)——对每一种分布都是一致性的，而条件均值不是；第 1 节所作的区分，应到那里去读。第 6 节的阈值极限来自 Balkema 与 de Haan（1974）和 Pickands（1975）。Smith（1985）确定了似然函数何时正则，限制 $\xi \geq -1/2$ 即由此而来；Smith（1987）给出了协方差 (TN38.22)。Grimshaw（1993）给出了降到一维的做法。McNeil 与 Frey（2000）把超阈值峰值法用于金融损失，Embrechts、Klüppelberg 与 Mikosch（1997）则是这套理论整体的标准参考文献。就第 7 节而言，Acerbi 与 Székely（2014）是两个检验统计量的出处，Gneiting（2011）是可引出性论证的出处，Fissler 与 Ziegel（2016）是联合评分函数的出处。



索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！