机器学习在衍生品中的应用

索吾林

本附注随《衍生品：合约、模型与市场》在线发布，不收入书中。“衍生品中的机器学习”这一名称之下其实有三件事：逼近交易台本来就会计算的定价函数，由模拟路径估计条件期望，以及在摩擦使复制无法实现时学习对冲策略。本附注把三者分开，并对每一件追问：它改变的是答案，还是只改变了得出答案所需的时间。依次讨论的内容是：定价代理模型及其可信的定义域、微分学习、以调好的无交易带为基准评判的深度对冲、高维行权决策中的神经网络回归，以及哪些环节会失效、这类模型如何治理。书中第 *38* 章定义了深度对冲所最小化的期望损失，[技术附注 38] 推导了使其可以训练的表示；第 *39* 章从监管者的角度讨论学习型模型的验证。本附注保留了它作为一章时所附的练习题。配套笔记本复现了其中的全部数字。

三件性质相当不同的事情共用一个名字。这方面的文献之所以难读，主要原因就在于把它们当成了一个主题。

第一件是逼近一个已经知道如何计算的函数。定价模型是从参数到价格的映射，求值很慢；网络可以学会这个映射，并在微秒级完成求值。答案没有任何改变，改变的只是得到答案所花的时间。

第二件是由模拟路径估计条件期望，也就是换了一组基的第 20.11 节美式蒙特卡洛。回归本来就有；把多项式换成网络是换基，不是换方法。

第三件在性质上不同。它要求在交易成本、离散再平衡与头寸限制之下给出对冲策略。经典理论无法陈述这个问题：一旦存在摩擦，复制就不复存在，而对“那该怎么办”，理论无话可说。在这里，这一方法不是在加速求得答案，而是在本来没有答案的地方给出答案。

本附注围绕一个检验展开：**这个方法是改变了答案，还是只改变了得到答案所花的时间？**两者都有价值，但并不是一回事，而这一差别决定了结果需要多少验证。本附注面向将要实现或验证学习型模型的读者；只想了解结论的读者可以只读第 14 节。

第 2 至 5 节讨论第一项任务：定价代理、代理可信的范围、代理从定价器继承的错误，以及微分学习。第 6 至 10 节讨论第三项任务即深度对冲，以正确的基准评判它，并从目标函数与模拟器两方面解读它；第 11 节讨论第二项任务，即高维下的行权决策。第 12 至 14 节说明哪些环节会失效、这类模型如何治理，以及这些方法真正在哪里有帮助；第 15 节说明谁在使用这些方法及其原因，第 16 节讨论境内市场的不同之处，第 17 节交代这些结果的来历。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

1　三项任务，一套工具

三者使用的是同一套工具：含参函数 f_θ、标量目标，以及对 θ 的梯度下降。不同之处在于训练数据从何而来，以及目标的含义。

*有监督逼近。*标签来自可信的定价器，目标是拟合。最好的结果是精确复现定价器，因此这种方法继承了定价器的上限，也继承了它的下限（见第 4 节）。

*对模拟路径的回归。*标签是含噪的实现值，其条件均值即所求的量。目标就是第 20.11 节已在使用的最小二乘，网络只是众多基中的一种。

*随机控制。*根本没有标签。目标是作用于终端盈亏的风险度量，网络则是一条决策规则。三者之中，只有它能给出经典方法所没有的结果。

本附注的网络刻意做得很小：最大的有 1,345 个参数，对冲策略网络有 1,217 个。没有任何结果依赖于网络的深度或宽度。这一点本身就有意义：这些方法在衍生品中之所以有用，靠的是结构上的原因，而不是模型容量。

2　定价代理

一次校准要对模型求值上千次。若每次求值耗时半毫秒，一次校准就要几秒钟；对日内要重新校准数百张曲面的交易台而言，这是负担不起的。代理替换的是循环中的定价器，而不是模型。

应当学习隐含波动率，而不是价格。价格随执行价与期限跨越好几个数量级，拟合时网络会把容量耗费在数值大的价格上；隐含波动率则处在一个窄带内，而且校准目标本来就是用隐含波动率表示的。

例 2.1　为 Heston 模型定价的网络

在

$$v_0, \theta \in [0.01, 0.16], \quad \kappa \in [0.5, 3], \quad \sigma_v \in [0.1, 1.0], \quad \rho \in [-0.9, 0],$$

以及 $K/S \in [0.7, 1.3]$、$T \in [0.1, 2]$ 上均匀抽样，用求积法定价，再反解为隐含波动率。剔除时间价值不足现价 0.1% 的点，因为这样的报价实际上并不存在，其隐含波动率在任何有用的意义上都没有定义。剩下 23,310 个训练点，求积耗时 17 秒。

一个有 **1,345 个参数**的网络（两层，各 32 个单元）训练耗时 31 秒，在 4,867 个未参与训练的点上复现该映射，误差如下：

均方根误差	**15.1 个基点**的波动率
平均绝对误差	11.1 bp
95 分位	29.8 bp
最差	123 bp

15 个基点远在买卖价差之内，因此就校准而言，代理与定价器无从区

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

分。关键在于速度：

	求积法	代理
每个价格	0.501 ms	0.00255 ms
一次校准（200 个报价、60 次目标求值）	6.0 s	**0.031 s**

提速 196 倍。这就是全部贡献，而且是很大的贡献：“隔夜重新校准一次账簿”与“每次询价都重新校准”的区别就在于此。但这完全是计算上的结论，与金融无关：价格还是原来的价格。

第 21 章之所以能说粗糙波动率已投入生产使用，原因就在这里。模型本身没有任何改变，改变的是校准不再需要几分钟。模型要等校准成本可以承受时才真正可用；这取决于硬件与数值方法，与模型是否真实无关。

3 训练集就是有效域

代理是一种插值，而插值不能外推。危险在于这种失效悄无声息：网络返回的数字大小正常、位数正常，输出中没有任何迹象表明输入已在拟合区域之外。

例 3.1 训练盒之外

将例 2.1 的网络原封不动地用于训练范围之外的参数：

	RMSE	最差
训练盒之内	15.1 bp	123 bp
波动率的波动率提高到 1.6	66.5 bp	371 bp
期限延长到 5 年	406.6 bp	1068 bp
执行价延伸到现价的 1.9×	346.7 bp	1141 bp

十五个基点的误差变成了四百个，扩大 27 倍。十个波动率点的误差已不是校准上的小麻烦，而相当于换了一个市场。期限方向上的退化最严重，而交易台恰恰最可能在这个方向上不知不觉地走出训练盒：五年期报价看上去与两年期报价并无二致。

图 1 不得不采用对数刻度，这本身就说明了问题。在训练盒内，误差只是舍入量级的差别；一旦跨出盒外，到了网络从未见过的期限上，误差就超过了所定价工具的买卖价差。网络不会发出任何已离开拟合区域的信号，因此边界必须从外部强制执行。

补救办法很简单，难的是纪律。代理在训练范围之外应当拒绝作答而不是外推，代价只是每次求值时做一次边界检查。困难在于组织层面：网络做得快，正是为了让那些并不了解它的代码调用，而边界检查必须随网络一起带走。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

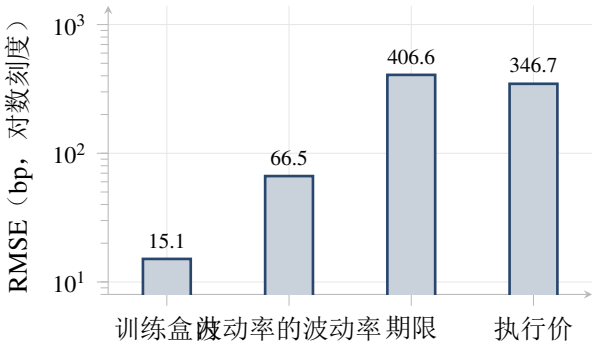


图 1: 代理在训练盒内与三种外推下的RMSE。对数刻度。

这里代理有一项经典方法所不具备的真正优点。闭式近似的有效区域靠判断，通常不会写明；代理的有效区域则是一个明确写下来的盒子。边界明确，因而可以审计，而“这个展开对小的 $\sigma\sqrt{T}$ 有效”这样的说法则无法审计。

这一点值得正式表述，因为它关系到模型究竟是什么。训练好的网络是函数 $f_{\hat{\theta}}$：样本取自支撑集为 $\mathcal{X}$ 的分布，参数在该样本上使某个经验目标达到极小。整个构造对 $\mathcal{X}$ 之外的 $f_{\hat{\theta}}$ 没有任何约束：目标函数看不到那里，塑造 $\hat{\theta}$ 的梯度也从未到过那里，网络在区域之外的行为只是其光滑性偶然的产物。

因此，$\mathcal{X}$ 与参数一样，都是模型的一部分。两个网络即使架构相同、权重相同，只要记录在案的训练盒不同，就是不同的模型：同一个查询，一个会拒绝，另一个会作答。只记录架构而略去训练集，记下的恰恰是最不重要的部分。

4 代理会学到它的定价器，包括其中的错误

准备本附注时，最有教益的一次失败并不是建模上的失败。

案例 4.1　学会了错误的网络

为例 2.1 训练的第一个代理，在自身训练盒内的一个测试点上出现了**1,814个基点**（十八个波动率点）的最差误差。平均误差为15.8 bp，尚可接受，因此汇总数字里看不出这个毛病。

将测试集按误差排序，检视误差最大的那些点，共同点随即显现：它们全都是深度虚值、短期限、波动率的波动率很高的期权。直接为这些点定价，原因就清楚了：求积法返回了负的看涨期权价格（-0.0023、-0.0090、-0.000033），而这些期权的真实价值在 10^{-4} 到 10^{-6} 量级。200 个节点的 Gauss–Legendre 求积在特征函数振荡最快之处没有收敛。

标签是错的，网络学会了这些错误标签，并把它们抹平了。把求积节点增加到600 个后，定价器收敛到 6×10^{-9}；重新训练后，网络的最差误差从1,814 bp 降到**123 bp**。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

> 教训有两条，令人不安的是第二条。代理不可能比标签更准确，这一点显而易见。但代理是光滑的，错误一经抹平，就比原来更难发现。求积法返回负价格，等于自己宣告了失败：这是任何检查都能抓到的不可能取值。网络却把它换成了一个量级正确、看似合理的波动率。错误保留了下来，而且再也无法被检测到。

由此直接得出实务规则：先验证标签，再验证拟合，而且要在标签最难计算之处验证，而不是在容易之处。用默认设置的定价器在宽参数盒上生成的训练集会含有坏标签，因为默认设置是针对盒子中部选定的。

5 微分学习

标签来自模拟时含有噪声，而噪声决定了所需的样本量。但一条模拟路径给出的不止是收益，还有收益对输入的导数，而且几乎不需额外成本：这就是第 20.10 节的路径导数，对整本账簿则由第 32 章的伴随算法微分算出。

导数标签含有价值标签所没有的形状信息。单个含噪收益只在一个点上约束拟合函数；收益连同其斜率则同时约束函数及其切线，抵得上附近好几个点。

例 5.1　同样的路径，信息多一倍

在随机现价上模拟单路径收益，学习执行价 100、期限一年的看涨期权价格与现价的函数关系；在这一设定下，标签是围绕正确答案的纯噪声。每条路径还由同一次抽样给出其路径 delta $\mathbf{1}\{S_T > K\}\, S_T/S_0$。

导数标签通过 Taylor 增广使用：每条路径除自身的点外，再贡献由其斜率推出的两个邻点。固定模拟路径数，结果如下：

路径数	普通 RMSE	含导数	改善
256	7.6439	2.5109	3.04×
1,024	2.0616	1.1881	1.74×
4,096	0.9150	0.3891	2.35×
16,384	0.3421	0.2394	1.43×

改善的方向一致，幅度则有噪声，以 RMSE 计平均约为两倍。横向而非纵向读表，经济含义更清楚：含导数拟合用 4,096 条路径达到的精度，与普通拟合用 16,384 条路径相当。导数标签换来的是模拟预算约三到四倍的节省，所用的信息是模拟本已算出、却一直被丢弃的。

导数标签的用法比看上去重要得多。准备本附注时就在这里犯过错，靠“去掉导数标签，看拟合是否变差”才发现。

这一构造值得写出来，因为显而易见的替代做法很容易出错。设目标为 $V(x) = \mathbb{E}[Y \mid X = x]$，由数对 (x_i, y_i) 估计，其中 y_i 是单次带噪抽样；路径微分

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

不增加任何模拟成本即可给出 y'_i，且 $\mathbb{E}[y'_i \mid X = x_i] = V'(x_i)$。最简便而又正确的用法是一阶展开：每条路径贡献的不是一个约束，而是一小段线段，

$$\big(x_i,\ y_i\big), \qquad \big(x_i \pm h,\ y_i \pm h\, y'_i\big)$$

再用普通最小二乘拟合。这样添加的是数据而不是惩罚项，因此不需要对网络做二阶微分。

文献中通常写下的是替代做法，即直接惩罚 $\|f'_\theta(x_i) - y'_i\|^2$。其梯度要求将网络的雅可比对参数求导，这是二阶对象；若改用有限差分估计并经价值输出反向传播，得到的其实是光滑性惩罚，它改善拟合的原因与导数标签无关。检验方法是把导数标签换成噪声：正确的实现会急剧退化，光滑性惩罚则不会。

由于第 32 章所述的约束，这一点的意义不止于样本量。不能隔夜算出自身风险的模型不会被采用，而正是伴随微分使这些敏感度的计算成本可以承受。微分学习的出发点是这样一个观察：这些导数一旦算出，就是现成的最佳训练数据。

6　深度对冲

前面各节讨论的都是加速计算。本节改变的是答案。

第 13 章把期权价格定义为复制期权的成本，第 18 章则在实务中对冲了一份期权：再平衡到布莱克–斯科尔斯 delta，接受离散再平衡带来的误差，第 18.9 节还度量了这一误差的代价。这一构造假定交易没有成本。一旦引入按比例的交易成本，复制就无法实现（不是代价高昂，而是不可能），因为复制策略的变差无界，会产生无限的成本。

经典的应对是近似对冲，再讨论如何近似：按固定日程再平衡，或在 delta 的变动超出某个带宽时再平衡，通过选择频率或带宽在对冲误差与成本之间权衡。两者保留的都是经典目标，即在成本允许的范围内尽量消去第 18 章展开式 (18.1) 中的 delta 项。深度对冲则把经典理论拒绝陈述的问题陈述出来：放弃这一目标，一次性选定整个策略，使终端盈亏的某个风险度量最小。

$$\min_{\theta}\ \rho\left(-\Pi + \sum_{t} \delta_t^{\theta}\,(S_{t+1} - S_t)\ -\ c \sum_{t} S_t \left|\delta_t^{\theta} - \delta_{t-1}^{\theta}\right| \ -\ \text{收益} \right) \tag{TN39.1}$$

其中 δ^θ 是含参 θ 的决策规则，Π 为收到的权利金，c 为成本率，ρ 为风险度量。

按定义直接写出，期望损失是在尾部求平均，而尾部的边界随参数移动，这不便于求导。Rockafellar–Uryasev 表示消除了这一困难。下式中的条件风险价值（CVaR）就是第 38 章的期望损失在最优化文献中的名称：

$$\mathrm{CVaR}_\alpha(L) \ =\ \min_{w \in \mathbb{R}} \left\{ w + \frac{1}{1-\alpha}\, \mathbb{E}\big[(L - w)^+\big] \right\} \tag{TN39.2}$$

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

其中取到极小值的 w 就是风险价值（[技术附注 38] 推导了这两点），它作为一个额外的标量与 θ 一同训练。目标由此成为分段线性函数的普通期望，梯度为 $\mathbf{1}\{L > w\}/(1-\alpha)$：只有落入尾部的路径贡献梯度。在 $\alpha = 0.95$、批量 2,048 时，全部信号只来自大约一百条路径；因此，与最小二乘拟合相比，这一目标需要更大的批量，训练曲线也更嘈杂。$L = w$ 处的折点不会造成问题，理由与允许在执行价处对看涨期权收益做路径微分相同。

策略自身的输出是下一个日期的输入，梯度的有趣之处正在于此。由于调整至明天持仓的交易按其与今天持仓的差距收费，

$$\frac{\partial \Pi}{\partial \delta_t} = (S_{t+1} - S_t) - c\,S_t\,\mathrm{sgn}\big(\delta_t - \delta_{t-1}\big) + c\,S_{t+1}\,\mathrm{sgn}\big(\delta_{t+1} - \delta_t\big)$$

因此，考虑成本的策略不可能是短视的：今天的持仓会改变明天的费用。这就是当前持仓必须作为输入的形式化理由。全导数因而在整个日程上满足一个向后递推，在每个日期累加 $\partial L/\partial\theta$，一次反向扫描即可得到精确梯度。

由此产生两点后果，二者源于经济结构而非网络架构。该递推把雅可比因子连乘，因此，如果策略对自身前一期持仓的敏感度绝对值超过 1，梯度就会沿日程向后几何增长：这正是梯度爆炸问题，只不过是从经济学一侧出现的。另外，整条路径必须保留在内存中，因为反向传播需要每个日期的激活值，内存因此随再平衡日期数线性增长。限制可训练日程长度的是这一点，而不是网络规模。

在给出数字之前，关于 (TN39.1) 有两点值得强调。第一，风险度量是设定的一部分，而不是细节（见第 9 节）。第二，策略是状态的函数，因此必须把状态输入给它：这里是价值状态、剩余时间和当前持有的头寸。没有当前头寸，任何考虑成本的规则都无从表达，因为交易成本取决于起点在哪里。

7 网络学到了什么

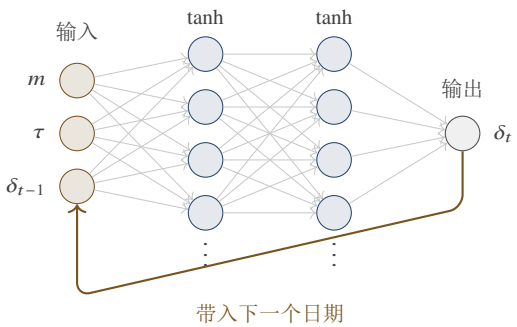


图 2: 对冲策略：两个隐藏层，所选持仓被带回作为输入。示意图；每层实为 32 个单元。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

图 2 就是全部架构：两个隐藏层、1,217 个参数，外加一项并非点缀的特征，即某个日期选定的持仓在下一个日期重新作为输入。正是这一特征，使策略能够把一笔交易与将来撤销它所需的费用放在一起权衡。

例 7.1　一份卖出的看涨期权，三种对冲

卖出一份平值看涨期权：$S_0 = K = 100$，一个月，波动率 20%，利率为零（$r = 0$，本附注所有对冲例题均如此），30 个每日再平衡日，布莱克–斯科尔斯权利金 2.3030。在同一组 200,000 条路径上用三种规则对冲。

布莱克–斯科尔斯 *delta* 每天再平衡到模型 delta。带宽规则只在持仓偏离模型 delta 超过 w 时才再平衡，w 由网格搜索选定，使网络所优化的同一目标达到最小；真正有意义的基准是它。学习型策略是一个有 **1,217 个参数**的网络，按 (TN39.1) 训练，ρ 取 95% 期望损失。

成本	策略	均值	标准差	CVaR_{95}	费用
0 bp	布莱克–斯科尔斯 delta	−0.0008	0.3600	0.8370	—
	学习型	−0.0002	0.4097	**0.7522**	—
10 bp	布莱克–斯科尔斯 delta	−0.2741	0.3786	1.1964	0.2734
	带宽 $w = 0.03$	−0.2630	0.3838	1.1915	0.2622
	学习型	−0.2448	0.4291	**1.0220**	0.2445
50 bp	布莱克–斯科尔斯 delta	−1.3675	0.5651	2.7361	1.3668
	带宽 $w = 0.13$	−1.0039	0.6473	2.5089	1.0032
	学习型	−1.0301	0.5315	**1.9852**	1.0299

请细看 50 bp 一栏。调好的带宽费用为 1.0032，学习型策略为 1.0299，只多 2.7%；两者的均值相差不到 3%。但期望损失分别为 2.5089 和 1.9852，在几乎相同的成本下改善了 21%。

可见，网络的优势不在于交易得更少，而在于在哪里交易。

有两项算术校验。零成本时每种策略都应接近公平博弈，两者的均值（相对 2.303 的权利金）都在零附近 0.002 以内；表中零成本一栏不列带宽规则，因为没有成本时最优带宽为零，它就是每日 delta。最优带宽随成本上升而变宽（10 bp 时为 0.03，50 bp 时为 0.13），这正符合经典不交易区理论的要求。

这条策略实际在做什么，一张图就能看清；而所见的情形，并不是读者对一个号称“不透明”的方法所预期的。

图 3 左图中的策略系统性地比模型 delta 平坦。它在平值附近的斜率为 0.0690，布莱克–斯科尔斯–默顿则为 0.0967，需要再平衡的 gamma 少 29%；模型持有 0.0009 时它持有 0.0109，模型持有 0.9974 时它持有 0.9776。它从不完全空仓，也从不完全对冲，因为两个极端都是随后还得交易出去的头寸。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

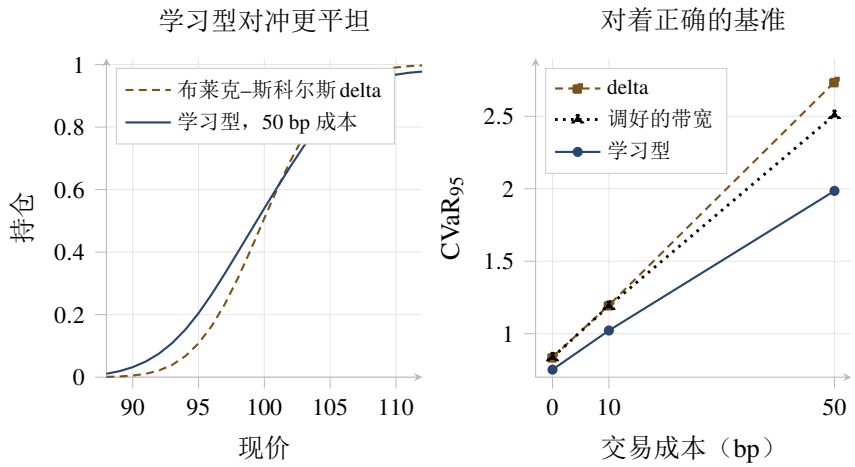


图 3: 左：到期前半个月、自己对冲状态出发的持仓。右：期望损失对交易成本。

这是一个可以辨认的形状。网络重新发现了不交易区文献用解析方法导出的结果：对冲量少于模型给出的，而且成本越高，对冲得越少。这令人安心，而非令人失望。如果一个方法在这里给出无法辨认的结果，它只会更难、而不是更容易被信任。

8 对着正确的基准

宣传材料会拿朴素的每日 delta 作比较。按这个标准，数字相当惊人：在 50 bp 时，学习型策略使期望损失改善 **27.4%**，费用减少 24.6%。

有意义的比较对象是调好的经典规则，这样比较得出的结论不同，也更有用：

50 bp 下，学习型相对于…	**朴素 delta**	**调好的带宽**
费用	−24.6%	+2.7%
CVaR_{95}	−27.4%	−20.9%

全部成本节省都可以从不交易带宽中得到；这个想法比本附注的方法古老，四行代码即可实现。带宽做不到的是塑造尾部，而这正是同口径比较之后剩下的优势。

这一警告的一般形式远不只适用于对冲。学习型方法应当与真正经过调校的最佳经典方案比较，而不是与手边随便一个方案比较；这两个基准之间的差距，通常大于论文所报告的差距。

9 目标函数就是设定

例 7.1 中零成本那一行是本附注最重要的一行，乍看却像一次失败。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

完全没有交易成本时，学习型策略的期望损失为0.7522，布莱克–斯科尔斯 delta 为0.8370，*好 10.1%*；但其标准差为0.4097，对方为0.3600，*差 13.8%*。

两个数字都正确，都不是程序错误。网络的训练目标是最小化95% 期望损失，它也确实做到了。方差不在目标之内，于是被拿去换取尾部的改善。学习型策略在你提出的要求上表现更好，在你没提的方面表现更差；这种交换，不专门去看就发现不了。

这对风险报告的影响是直接的。如果交易台优化的是期望损失，风险系统报告的却是标准差，那么这个方法恰恰在发挥作用时会显得正在失效。第39 章的模型治理问题通常表述为模型是否正确；在这里更尖锐的问题是：交给模型的目标，是不是机构真正的目标。

目标的选择没有中立选项。期望损失、方差和指数效用，对同一本账簿会给出三种不同的对冲。经典 delta 对冲根本没有目标函数，从而掩盖了这一选择：它做的是复制，而复制只要存在就是唯一的。复制一旦不存在，就必须作出选择；深度对冲并没有引入这种任意性，只是把它摆到了明处。

10　模拟器是一项假设

深度对冲没有数据。代理的训练对象是一个可以检查的定价器，回归的训练对象是“所估之量的实现值”。(TN39.1) 则是在模拟路径上训练的，因此生成这些路径的过程无论是什么，都是策略所继承的一项假设；而这恰恰是该方法无法检验的假设，因为它从未见过别的路径。

经典规则也带有同样的假设，只是依赖得更轻。布莱克–斯科尔斯 delta 同样是在几何布朗运动下导出的。区别在于程度：公式只是使用这个模型，优化器则会利用它。

例 10.1　同一条策略，另一个世界

取例 7.1 中在50 bp 下训练的策略，不作任何改动，在 Merton 跳跃扩散的路径上求值。跳跃扩散的总波动率匹配到同样的20%，因此唯一的差别在于日度变动的形状。跳跃每年平均发生0.5 次，均值为 −5%，波动率为5%；扩散部分的波动率相应降至19.4%，使总波动率保持20%。日收益率的峰度由3.00 升至10.09。

	如训练时（GBM）		含跳跃	
策略	**CVaR_{95}**	**费用**	**CVaR_{95}**	**费用**
布莱克–斯科尔斯 delta	2.7361	1.3668	3.1526	1.3555
带宽 $w = 0.13$	2.5089	1.0032	2.9034	0.9934
学习型	**1.9852**	1.0299	**2.5957**	1.0222
学习型相对带宽	−20.9%		−10.6%	

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

一半的优势消失了。学习型策略仍然获胜，但优势从20.9% 降到10.6%，而总波动率丝毫未变。

更有说服力的读法是看每种策略退化了多少：delta 退化15.2%，带宽退化15.7%，学习型策略则退化**30.8%**。针对训练分布优化得最彻底的策略，在分布出错时受损最重，其敏感程度约为那些仅在该分布下推导出来的规则的两倍。

这并不是反对该方法的理由，而是说明了必须随之一并交付什么：深度对冲的结果是关于某个模拟器的结论；交易台若只报告策略而不报告其训练所用的过程，披露的就是不那么重要的那一半。

实务上的应对是针对不确定性训练，而不是针对单个模型训练。从一组可信动态的混合中模拟，或对历史收益率做自助抽样来模拟，得到的策略在任何单一模型上都更差，但在整个集合上更不敏感。这与第 9 节指出的是同一种交换，只是高了一个层次。唯一不能做的，是跳过这一选择。

11　行权决策与维数

第20.11 节用一组多项式基估计继续持有价值。把多项式换成网络，改变的只是基，别的都不变：偏差仍然向下，理由仍是第20.11 节所说的（非最优的行权规则赚得更少），估计值仍是下界。

在低维情形下，这样做毫无收益，而且差距不小。

例 11.1　多项式基究竟在哪里失效

一份百慕大看跌期权，$S_0 = K = 100$、$r = 5\%$、$\sigma = 20\%$、一年、二十个行权日，以6,000 步二叉树的结果**6.0613** 为基准：

基	取值	误差	耗时
二叉树	6.0613	—	0.28 s
多项式，三次	6.0485	−0.0128	0.1 s
网络，2×16	5.7468	−0.3145	174 s

网络的误差是多项式的25 倍，速度比树慢600 倍。

值得关注的是五维情形，其结果出乎意料。考虑五个标的、两两相关性0.30 的最差价看跌期权，10 万条路径：

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

基	项数或参数	取值	耗时
多项式，三次	56 项	14.7999	1.8 s
多项式，四次	126 项	**14.8949**	4.7 s
网络 2×16，180 步	385 参数	13.5619	371 s
网络 2×32，600 步	1,281 参数	14.5327	2,237 s

每个取值都是下界，因此越高越好：更好的基能找到更好的行权规则，赚得更多。

多项式胜出，通常用来支持网络的理由被证明是错的。五个变量的三次基有 $\binom{8}{3} = 56$ 项，四次基有 126 项；相对 10 万条路径，两者都远未触及样本量或内存的限制。“多项式基在五维时变得不可行”的说法根本不成立。

网络的问题也不只是训练不足。训练时间加长，答案并不会单调改善：

网络，2×32	取值	耗时
600 步	**14.5327**	2,237 s
1,500 步	13.7205	7,596 s

路径相同、初始化相同，训练量增加一倍多，答案却明显更差。

原因不在过拟合。取单个行权日、留出 43,320 条路径检验，网络的样本外误差基本单调下降，训练误差与测试误差之差始终接近零：1,281 个参数面对四万个点，不会过拟合。

留出检验真正表明的是：多项式不仅更便宜，而且是更好的估计量：

基	留出 MSE	训练–测试差
多项式，二次（21 项）	75.74	−0.19
多项式，三次（56 项）	73.26	−0.15
多项式，四次（126 项）	**73.00**	+0.17
多项式，五次（252 项）	73.26	+0.77
网络 2×32，2,000 步内最优	74.14	−0.12

在所试的各种训练长度下，网络都没有达到多项式的精度；多项式则有一个明显的最优点：四次最好，五次开始过拟合，其为正的训练–测试差说明了这一点。在上表中，四次基也给出了最好的行权规则，两项诊断结论一致。

因此，不稳定来自行权规则，而不是拟合。继续持有价值要与立即行权收益比较，而这种比较是一道阈值：拟合曲面上微小的摆动，会同时翻转许多条路径上的决策，每一次翻转都会降低下界。稍差的回归可能产生差得多的行权规则，所以取值在变，留出误差却几乎不变。

这才是可以推广的结论，而且与网络无关。当拟合出的函数用于离散

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

决策时，拟合精度是错误的监控对象；真正重要的是决策边界的稳定性，而训练曲线反映不出这一点。

那么网络适用于哪里？按这一证据，不在五维。交叉点比教科书例子所暗示的更高；任何人提议使用网络基，都应当被要求给出相同路径预算下的多项式对照。这就是第 8 节的规则，只是用在了中间那项任务上，而不是对冲上。

一般性的教训与本附注已两次得出的结论相同。代理之所以有价值，是因为它与所取代的求积法做过对照；深度对冲之所以有价值，是因为它与调好的带宽做过对照。在这里，同样的纪律推翻了预期的结论，而这项对照当初完全可能根本不做。

12　什么会坏掉

无套利并非由构造本身保证：损失函数中没有任何内容涉及蝶式。但由此得出的显然推论是错的，例 12.1 要说明的正是这一点。

例 12.1　本应出现套利却没有出现的曲面

从例 2.1 的代理中读出一张 Heston 曲面（$v_0 = 0.040$、$\kappa = 1.50$、$\theta = 0.045$、$\sigma_v = 0.60$、$\rho = -0.70$），并用第 19.5 节的蝶式条件检验，做法与例 19.5 检验市场报价完全相同。

逐点拟合表现平常：各执行价上的 RMSE 为 17.7 bp，最差 42.3 bp。蝶式是二阶差分，会放大误差；在间距为 h 的执行价网格上，蝶式本身按 h^2 缩小，拟合误差却丝毫不缩小。加密网格理应破坏无套利条件：

执行价间距	精确蝶式	代理蝶式	为负
现价的 2.0%	$+2.257 \times 10^{-2}$	$+2.177 \times 10^{-2}$	无
0.5%	$+9.552 \times 10^{-4}$	$+8.737 \times 10^{-4}$	无
0.1%	$+3.456 \times 10^{-5}$	$+3.121 \times 10^{-5}$	无
0.05%	$+8.533 \times 10^{-6}$	$+7.694 \times 10^{-6}$	无

无套利条件并未被破坏。即使进一步推到五年期限，逐点误差达到**698 bp**，曲面仍然无套利。

网络是其输入的光滑函数，因此它在相邻执行价上的误差几乎相同，而二阶差分会把光滑的部分消去。拟合在 0.995、1.000、1.005 倍现价处都偏离 42 bp，且方向相同，蝶式因此几乎察觉不到。

因此，在第 4 节中使定价器错误无法检测的光滑性，正是使这张曲面保持无套利的光滑性。

这种保护比看上去要窄：光滑性保护的只是那些对网络输入取差分的

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

无套利条件。这里执行价是输入，因此蝶式条件安全。按期限分别拟合的代理在期限方向上根本没有光滑性，可能在每条微笑都是凸的同时，违反第 19.5 节的日历条件。

如第 3 节所示，外推的失效悄无声息，表现不是一个大误差，而是一个看似合理的误差。

结果在通常意义上不可复现；例 12.2 表明，值得关注的是哪些结果不可复现。

例 12.2　同样的代码、同样的数据、三条策略

在 50 bp 下将例 7.1 的策略训练三次，只改变随机种子：

			在各现价上的持仓		
种子	**CVaR_{95}**	**费用**	**95**	**100**	**105**
7	1.9852	1.0299	0.2047	0.5401	0.8485
17	2.0013	1.0631	0.2007	0.5478	0.8641
27	2.0003	1.0436	0.2062	0.5441	0.8652
布莱克–斯科尔斯 delta			0.1082	0.5081	0.8879

表现可以复现，策略却不能。期望损失介于 1.9852 与 2.0013 之间，极差为均值的 **0.8%**，因此就目标而言，三次运行给出的是同一个答案。但在现价 105 处，三条策略分别持有 0.8485、0.8641、0.8652，在本该完全相同的头寸上相差 1.7 个 delta 点。对一本 1 亿美元的账簿而言，这意味着 170 万美元的持股差异，而两个交易台运行的是同一份代码、同一批数据。

可复现的是形状。三者在 95 处都远高于布莱克–斯科尔斯–默顿的 0.1082，在 105 处都低于 0.8879：每次运行都学会了变平坦，区别只在“平多少”。

这清楚地区分了两种用途。对代理而言，交付物是价格：两次运行之间相差 0.8% 的价格不可接受，吻合到拟合误差以内的价格则没有问题。对对冲策略而言，策略本身就是交付物，因此种子依赖不是数值上的细枝末节，而是机构所持头寸本身的差异。

图 4 区分了可复现与不可复现的部分。三次训练的持仓并不一致，最多相差 1.7 个 delta 点，相对于 delta 的位置却一致：执行价以下高于 delta，以上低于 delta。形状是模型的发现，持仓是种子的产物，两者之中只有一个能写进风险报告。

实务上的做法是：固定种子，把权重作为数据而非代码进行版本管理，并把重新训练视为需要审批的模型变更。这是用治理手段回答一个技术问题，也是唯一可行的回答。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

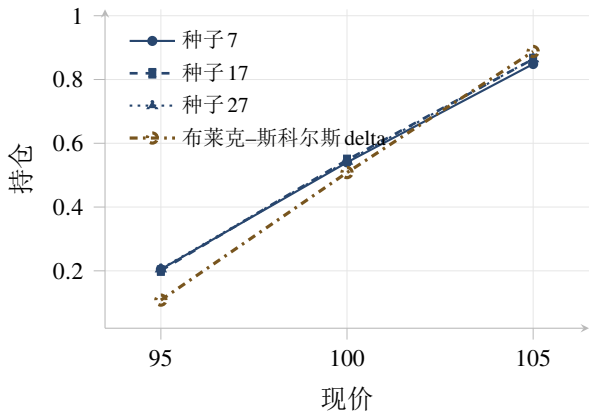


图 4: 仅随机种子不同的三次训练，与布莱克–斯科尔斯 delta 的对比。

验证问题则没有明确的解法。经典模型通过检查其假设与极限情形来验证。网络没有假设可查，验证于是退化为样本外测试；而样本外测试检验的是抽过样的区域，第 3 节的失效恰恰发生在无人抽样的区域。

13 治理

第 39 章讨论一般意义上的模型风险；以下三点是学习型模型特有的。

*训练数据是模型的一部分。*代理的参数盒、对冲策略的模拟动态，以及生成标签的定价器，都是模型输入，因为改变其中任何一个都会改变输出。只记录结构而略去训练集，记下的是最不重要的部分。

*重新训练是一次模型变更。*在新数据上重新拟合的网络是另一个模型，给出的数字也不同。重新训练的自然节奏是频繁、无声、自动的，这与治理框架所假定的审批周期相冲突。

此外，失效方式与这些框架当初针对的不同。设定错误的经典模型，错在一个可以推理的方向上；在坏标签上训练出的网络，错的是形状，第 4 节被抹平的错误就是一例。“这个模型是否审慎？”这一监管问题，对一个参数没有任何含义的对象而言无从回答。

14 它在哪里真正有帮助

用本附注的检验来衡量：

代理不改变任何答案，但把得到答案的成本降低了两个数量级，使此前负担不起的模型变得可用。*验证负担：低*，因为参照答案存在且可以检查。

微分学习不改变任何答案，它利用计算中本已产生的导数，使模拟预算节省三到四倍。*验证负担：低*，理由相同。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

用于行权决策的神经回归在低维中不改变任何答案；按例 11.1 的证据，在五维中也不改变。只有在多项式基确实失效之处，它才值得考虑，而这一维数比教科书例子所暗示的更高。验证负担：中等，所得的界是单侧的，这一点有帮助。

深度对冲改变答案。在经典理论给不出策略之处，它给出了策略；在几乎相同的成本下，它使期望损失比调好的带宽改善 21%；它还要求从业者明确陈述风险目标，而 delta 对冲允许他们对此避而不谈。验证负担：高，因为没有任何东西可以用来核对答案。

其中的规律是：验证负担最低的方法，正是改变最少的方法。这并非巧合：只让已知计算变快的方法，可以用这个计算本身来核对。

15 谁在使用这些方法，为什么

波动率交易台把代理用于校准，动机与例 2.1 相同：模型若慢到无法校准，无论有什么优点都无法使用。粗糙波动率之所以被采用，靠的是它的代理，而不是支持它的证据。

XVA 台将微分学习与伴随微分结合使用，因为第 9 章的各项调整是组合层面的量，需要成千上万次重估；而第 32 章表明，制约因素是风险计算而不是定价。

奇异期权台在摩擦占主导之处使用深度对冲：流动性差的标的、相对市场规模很大的头寸，以及第 34 与 35 章的障碍产品，这类产品恰恰在交易最贵时需要最多的对冲交易。例 34.6 中 delta 处处为负、在障碍处不连续的反向敲出期权，是最自然的应用，也是验证负担最高的情形。

供应商与基础设施提供方提供代理库，没有自建能力的交易台正是通过这一途径用上这些方法的。这一分销渠道值得按第 3 节的思路加以审视：以库的形式提供的代理，其训练盒并非使用者所选，使用者甚至可能根本看不到。

没有人在用这些方法发明新的衍生品。这一应用领域的头十年，使既有方法的成本变得可以承受，并提出了一个此前一直避而不谈的问题。这是实实在在的贡献，但比那套术语所暗示的要小。

16 中国市场的若干差异

在中国，本附注三项任务的可行性差别很大，原因却不在算力。

代理在境内几乎没有用武之地，因为没有需要加速的模型。第 30 与 31 章指出，境内没有可供校准的互换期权曲面、没有 CMS 报价，也没有波动率立方体。代理加速的是校准，而校准需要报价；在模型参数只能从历史数据估计的市场中，例 2.1 的 196 倍提速并无相应价值。唯一的例外是雪球：它用蒙特卡洛定价、需要每日重估，且发行量大，因此一个把“参数与条款映射为价格”的代理确实能节省可观的机时。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

深度对冲则相反：境内的问题形态比国际市场更适合它。第35章中券商对冲雪球时，面对的正是(TN39.1)所描述的问题：离散再平衡、可观的交易成本，以及在敲入线附近delta剧烈变化的收益。境内还有两项国际市场所没有的摩擦，恰好是经典理论最难处理、而这一框架最容易容纳的：**涨跌停板**使某些价位上根本无法成交，**融券约束**则使空头端受数量而非价格的限制。不交易带宽无法表达“这个价位不能成交”，(TN39.1)的模拟器却可以，只要把停板写进路径生成即可。

但第10节的警告在境内分量更重。例10.1表明，仅仅改变日度变动的形状（总波动率不变），就能抹去一半的优势。境内A股日收益率的峰度高于成熟市场，停板本身又会造成连续同向变动，因此在几何布朗运动上训练的策略，在境内的失配比该例更大。在境内，模拟器的选择不是技术细节，而是主要的建模决策。

估值备案要求与第12节的种子依赖直接冲突。第20与21章指出，境内估值方法须向报价系统备案，其效果是偏向可复核的方法。而例12.2表明，学习出的对冲策略在表现上可复现，在头寸上却不可复现：三次训练在现价105处相差1.7个delta点。要求“同样输入得到同样输出”的备案制度，对价格模型可以满足（固定权重即可）；对策略则要求把权重本身作为备案对象，这在境内尚无先例。

最后，境内还有一项独有的有利条件。第34.15节所述的场外期权交易商分层，把风险集中在少数一级交易商手中。集中在治理上是问题，在这里却是优势：深度对冲的验证负担高，需要明确设定模拟器并对权重做版本管理，而只有规模最大的机构才具备这些能力。因此，这类方法在境内的采用会比国际市场更集中、更缓慢，也更便于检查；三者是同一件事的三个方面。

17　这些结果是怎么来的

Hutchinson、Lo与Poggio（1994）是开创性的论文，值得一读的是它提出问题的方式：让网络从数据中学出定价函数，而真正有意思的问题是，网络成功时究竟学到了什么。

现代研究的目标与此不同。Buehler等（2019）学习的不是价格而是对冲策略，直接优化终端分布；这就是深度对冲的含义，也是它能容纳公式所无法容纳的成本与约束的原因。Huge与Savine（2020）除数值外还用导数来训练，这正是使希腊字母不仅可得、而且可靠的关键。Horvath等（2021）把代理模型的思路用于校准，本附注认为这是最有根据的应用，因为在那里网络插值的是一个已知、只是计算昂贵的函数。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

小结

三件事共用一个名字，一个检验可以把它们分开：改变的是答案，还是得到答案的时间？逼近已知的定价函数不改变任何答案；由路径估计条件期望也不改变，那只是第 20.11 节的回归换了一组基；只有在摩擦下选择对冲策略，才提出了经典理论无法陈述的问题。这一检验的结果同时预示了各自需要多少验证。

代理模型换来的是速度。小型网络能把 Heston 隐含波动率映射拟合得相当精确，求值远快于定价器，原本需要数秒的校准几乎瞬间完成。但训练集就是有效域：同一网络在从未见过的期限上严重退化，返回的却是一个看似合理的数字而不是报错。微分学习只用一小部分路径就能达到同样的精度。

深度对冲是唯一不属于提速的结果，因为在按比例成本下复制无法实现。与调好的不交易带宽相比，学习型策略的费用相当，期望损失却明显下降；与朴素的每日 delta 相比，改善看起来更大，但其中的成本节省是假象。目标函数就是设定：零成本时，该策略在期望损失上胜过 delta，在标准差上却不如 delta。模拟器则是一项假设：在跳跃路径上，优势大幅缩小，学习型策略退化最多。

出问题的是治理，不是数学。不同随机种子得到的期望损失几乎一致，所持 delta 却明显不同：形状可复现，头寸不可复现。即使在逐点误差很大之处，曲面仍保持无套利，因为网络是光滑的；也正是这种光滑性，让返回负看涨期权价格的定价器被网络悄悄掩盖了过去。

验证负担最低的方法，正是改变最少的方法，因为只让已知计算变快的方法，可以用该计算本身来核对。

在中国，三项任务的可行性差别很大，原因却不在算力。代理模型几乎没有用武之地，因为没有需要加速的模型：境内没有可供校准的互换期权曲面、没有 CMS 报价，也没有波动率立方体；唯一的例外是雪球，它用蒙特卡洛定价、需每日重估，且发行量大。深度对冲则相反，境内的问题形态比国际市场更适合它。券商对冲雪球时面对的正是 (TN39.1)；涨跌停板与融券约束，恰是经典理论最难处理、这一框架最容易容纳的两项摩擦：不交易带宽无法表达“这个价位不能成交”，模拟器却可以。但模拟器的警告在境内分量更重：A 股峰度更高，停板又造成连续同向变动，因此在几何布朗运动上训练的策略失配更大，模拟器的选择在境内是主要的建模决策，而不是技术细节。此外，估值备案要求与种子依赖直接冲突：备案偏向可复核的方法，而学习出的策略表现可复现、头寸不可复现，因此备案对象必须是权重本身，这在境内尚无先例。

配套笔记本 `ch39-ji-qi-xue-xi-zh.ipynb`

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

延伸阅读

Buehler 等人的深度对冲论文是第 6 节的来源，阐明了“为什么这是控制问题而不是定价问题”；读它是为了这一表述，而不是为了那些已经过时的网络结构。关于代理，值得追踪的是粗糙波动率的神经网络校准，这是该技术确实改变了市场所用模型的唯一实例。Huge 与 Savine 的微分机器学习论文提出了第 5 节的想法，并直截了当地指出这些导数本来就在计算。学习出的策略所重新发现的不交易区结果是经典结论，标准参考是 Whalley–Wilmott 的渐近展开；值得在读机器学习文献之前先读，因为它确定了答案应有的样子。关于验证，监管文献很少，有用的材料在为经典模型编写的模型风险管理指引中，阅读时要留意学习型模型违反了其中哪些假定。境内方面，各家券商关于场外衍生品估值方法备案的业务规则，以及雪球类产品对冲实践的披露，是第 16 节的一手依据。

练习题

1 说出共用“机器学习在衍生品中的应用”这一名称的三项活动，指出其中哪一项能给出经典方法所没有的结果，并说明这对各自所需的验证量意味着什么。

2 解释代理为什么在隐含波动率上而不是在价格上训练。

3 用例 2.1，说出代理的 RMSE 与校准加速倍数，并用一句话说明代理改变了什么、没有改变什么。

4 解释为什么要把时间价值不足现价 0.1% 的点剔除出训练集，以及保留这些点会出什么问题。

5 用例 3.1，说出训练盒内与五年期限上的 RMSE，并解释这种失效为什么比显眼的大误差更危险。

6 解释与闭式近似相比，代理的有效区域在什么意义上是一项优点，以及为什么实务中的困难在于组织而不在于数学。

7 在第 4 节的案例中，说出定价器修正前后的最差误差，并解释网络为什么使底层错误更难被发现。

8 用例 5.1，说出 4,096 条路径上导数标签带来的改善，并把它改述为模拟预算而不是 RMSE 上的节省。

9 解释为什么按比例交易成本使复制无法实现，而不只是代价高昂。

10 写出深度对冲目标 (TN39.1)，并解释是什么取代了“策略必须复制收益”这项要求。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

11 解释为什么考虑成本的对冲策略必须以当前持仓为输入。

12 用例 7.1，说出 50 bp 下调好的带宽与学习型策略的费用与期望损失，并用一句话说明学习型策略的优势从何而来。

13 用图 3，描述学习型策略与布莱克–斯科尔斯 delta 的两处差异，并解释它与经典不交易区的相似为什么令人安心而不是令人失望。

14 零交易成本时学习型策略把期望损失改善 10.1%、把标准差恶化 13.8%。解释这为什么不是缺陷，以及它对度量了错误对象的风险报告意味着什么。

15 解释为什么 delta 对冲从不需要陈述风险目标，并据此说明深度对冲中的任意性究竟从何而来。

16 解释为什么用于行权决策的神经基对百慕大互换期权毫无益处，并用例 11.1 说明挂钩五个标的的可赎回票据是否需要它。

17 用例 12.1，解释加密执行价网格为什么本该产生蝶式违反却没有，并准确说明光滑代理能保证哪些无套利条件、不能保证哪些。

18 解释为什么使拟合曲面保持无套利的性质，与使定价器错误难以被发现的性质是同一项。

19 用例 10.1，说出学习型策略在训练动态下与在跳跃下相对调好带宽的优势，并解释匹配总波动率为什么不使两个世界等价。

20 按例 10.1 中三种策略在跳跃下的退化幅度排序，并解释这个次序为什么如此。

21 某交易台向风险委员会提交一条深度对冲策略。说出必须随之一同提交的是什么，以及为什么这一项才是两者中更重要的。

22 用例 12.2，说出三个种子之间期望损失的跨度与现价 105 处持仓的跨度，并解释前者为什么令人安心而后者不然。

23 解释在例 12.2 中，跨训练轮次确实可复现的是什么，以及为什么这使种子依赖对对冲策略构成问题，而对定价代理不构成问题。

24 解释为什么“这个模型是否审慎？”对学习型模型无从回答，以及应当改问什么。

25 解释为什么代理在境内几乎没有用武之地，以及为什么雪球是那个例外。

26 解释涨跌停板与融券约束为什么是经典对冲规则难以表达、而 (TN39.1) 的模拟器容易容纳的摩擦。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！

27 解释估值备案要求与例 12.2 的种子依赖为什么直接冲突，以及对一条策略而言备案对象必须是什么。

进阶习题

28 例 3.1 显示代理在训练盒之外严重退化。设计一项随网络而非调用代码携带的边界检查，确定当某一个输入略微越界、其余输入居中时它应如何处理，并说明你会如何设定容差。

29 第 4 节的案例是靠把测试集按误差排序、检视最差点才找到坏标签的。设计一套在训练之前就能发现这些负价格的程序，说明其成本与生成训练集的成本相比如何，并解释为什么“价格必须超过内在价值”这一显然的检查本身并不充分。

30 例 7.1 为每个成本水平训练一条策略。设计一条以成本率为输入的单一策略，说明你预期它与三条专用策略相比表现如何，并据此说明交易台在执行成本变化时应当如何重新训练。

31 图 3 中学习出的策略重新发现了经典不交易区。对例 7.1 的参数推导 Whalley–Wilmott 带宽，与网格搜索所得的宽度比较，并判定学习型策略 19% 的期望损失优势在对着解析带宽而非网格搜索带宽时是否仍然存在。

32 第 9 节论证风险度量是设定的一部分。在方差与指数效用下训练同一条策略，比较三个对冲，并说明策略的哪些特征为三者共有、哪些是目标函数的产物。

33 深度对冲产出策略而不产出价格。由 (TN39.1) 的目标构造一个无差异价格，解释它如何依赖于风险度量与既有账簿，并说明这对两家为同一份奇异期权报价的交易台意味着什么。

34 把涨跌停板写进 (TN39.1) 的模拟器：设定停板下的路径生成与可成交集合，说明由此训练出的策略与不含停板训练出的策略应当有何差异，并判定这项差异在境内雪球对冲上是否大到值得为它单独训练。

索吾林：WSuo@Queensu.ca。仅供个人使用，请勿分发！